

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



CHÂU GIA BẢO

XÂY DỰNG DATA WAREHOUSE VÀ MÔ HÌNH
MACHINE LEARNING PHÂN TÍCH VÀ DỰ ĐOÁN
VIDEO TRENDING TRÊN YOUTUBE

ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Vĩnh Long, tháng 6 năm 2026

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ

**XÂY DỰNG DATA WAREHOUSE VÀ MÔ HÌNH
MACHINE LEARNING PHÂN TÍCH VÀ DỰ ĐOÁN
VIDEO TRENDING TRÊN YOUTUBE**

ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Sinh viên: **CHÂU GIA BẢO**

Lớp: **DA22TTA**

Mã số sinh viên: **110122034**

Giảng viên hướng dẫn: **ThS. PHẠM THỊ TRÚC MAI**

Vĩnh Long, tháng 6 năm 2026

LỜI CAM ĐOAN

Em xin cam đoan đồ án tốt nghiệp “Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” là công trình nghiên cứu của riêng em, được thực hiện dưới sự hướng dẫn của giảng viên hướng dẫn.

Toàn bộ dữ liệu, kết quả phân tích, kết quả thực nghiệm và mã nguồn trình bày trong báo cáo là trung thực, do em trực tiếp thu thập, xây dựng, xử lý và kiểm chứng từ dữ liệu được khai thác thông qua YouTube Data API v3. Những nội dung tham khảo từ sách, bài báo khoa học, tài liệu kỹ thuật và các nguồn tham khảo khác đều được trích dẫn và ghi nguồn đầy đủ trong danh mục tài liệu tham khảo.

Đề tài này chưa từng được sử dụng để bảo vệ hoặc công bố trong bất kỳ công trình nghiên cứu nào khác. Em xin hoàn toàn chịu trách nhiệm về tính trung thực, chính xác và khách quan của toàn bộ nội dung được trình bày trong đồ án.

Sinh viên thực hiện

Châu Gia Bảo

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn chân thành đến cô Phạm Thị Trúc Mai, giảng viên Khoa Công nghệ Thông tin, Trường Kỹ thuật và Công nghệ, Đại học Trà Vinh, người đã trực tiếp hướng dẫn em trong suốt quá trình thực hiện đề tài.

Trong thời gian thực hiện đề án, cô đã tận tình định hướng, góp ý và hỗ trợ em từ quá trình thu thập dữ liệu, xây dựng hệ thống Data Warehouse đến việc phát triển và đánh giá mô hình học máy dự đoán video Trending trên YouTube. Những kiến thức và kinh nghiệm mà cô chia sẻ đã giúp em hoàn thiện đề tài cũng như nâng cao kỹ năng nghiên cứu của bản thân.

Em xin chân thành cảm ơn quý thầy cô Khoa Công nghệ Thông tin đã truyền đạt những kiến thức quý báu trong suốt thời gian học tập tại trường. Đồng thời, em cũng xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ và tạo điều kiện thuận lợi để em hoàn thành đề án tốt nghiệp này. Do kiến thức và kinh nghiệm còn hạn chế, đề án khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp từ quý thầy cô để đề tài được hoàn thiện hơn.

Một lần nữa, em xin chân thành cảm ơn và kính chúc quý thầy cô luôn mạnh khỏe, hạnh phúc và thành công trong công tác giảng dạy.

Sinh viên thực hiện

Châu Gia Bảo

MỤC LỤC

LỜI CAM ĐOAN.....	i
LỜI CẢM ƠN.....	iii
CHƯƠNG 1: TỔNG QUAN.....	1
1.1 Tổng quan đề tài	1
1.2 Tổng quan về các vấn đề cần giải quyết.....	1
1.3 Công nghệ và công cụ sử dụng	2
1.4 Ý nghĩa thực tiễn đề tài	2
CHƯƠNG 2: NGHIÊN CỨU LÝ THUYẾT	3
2.1 Phân tích dữ liệu.....	3
2.2 Phân tích khám phá dữ liệu	3
2.3 Kho dữ liệu	4
2.3.1 Mô hình hình sao.....	4
2.3.2 Mô hình bông tuyết.....	5
2.3.3 Mô hình chòm sao sự kiện	5
2.4 Quy trình ETL	6
2.4.1 Giai đoạn trích xuất dữ liệu.....	6
2.4.2 Giai đoạn chuyển đổi dữ liệu	6
2.4.3 Giai đoạn nạp dữ liệu	7
2.5 Hệ quản trị cơ sở dữ liệu PostgreSQL.....	7
2.6 Phân tích cảm xúc.....	8
2.7 Machine Learning trong dự đoán Trending	9
2.7.1 Bài toán phân loại	9
2.7.2 Thuật toán XGBoost	9
2.7.3 Feature Engineering	11
2.7.4 Các chỉ số đánh giá mô hình	11
2.8 Trực quan hóa dữ liệu và Streamlit	12
2.8.1 Trực quan hóa dữ liệu	12
2.8.2 Streamlit	13
CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU	15
3.1 Quy trình nghiên cứu tổng thể.....	15
3.2. Thu thập dữ liệu.....	16
3.2.1. Nguồn dữ liệu.....	16
3.2.2. Phương pháp thu thập dữ liệu	17

3.2.3. Mô tả bộ dữ liệu thu thập	19
3.3 Xây dựng hệ thống Data Warehouse và quy trình ETL	24
3.3.1 Thiết kế Star Schema	24
3.3.2 Quy trình ETL	26
3.3.3 Lưu trữ dữ liệu trên PostgreSQL	28
3.4 Tiền xử lý và xây dựng đặc trưng	28
3.4.1 Làm sạch và chuẩn hóa dữ liệu	28
3.4.2 Phân tích cảm xúc bình luận	32
3.4.3 Xây dựng đặc trưng.....	34
3.5. Phân tích khám phá dữ liệu	36
3.5.1 Phân tích tổng quan dữ liệu.....	36
3.5.2 Phân tích đặc trưng tương tác	39
3.5.3 Phân tích tương quan dữ liệu	47
3.5.4 Nhận xét và lựa chọn đặc trưng	48
3.6 Xây dựng và đánh giá mô hình dự đoán Trending	50
3.6.1 Chuẩn bị dữ liệu huấn luyện	50
3.6.2 Chia tập dữ liệu	52
3.6.3 Xây dựng và huấn luyện mô hình XGBoost.....	53
3.6.4 Đánh giá kết quả mô hình	54
3.6.5 Phân tích mức độ quan trọng của đặc trưng.....	55
3.7 Xây dựng ứng dụng dự đoán Trending	57
3.7.1 Kiến trúc ứng dụng	57
3.7.2 Chức năng Trending Analytics	59
3.7.3 Chức năng dự đoán Trending.....	60
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU	62
4.1 Kết quả triển khai Dashboard	62
4.2 Kết quả triển khai trang Trending Analytics	63
4.3 Kết quả triển khai trang Predict.....	64
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	67
5.1 Kết quả đạt được.....	67
5.2 Hạn chế của đề tài	67
5.3 Hướng phát triển.....	68
DANH MỤC TÀI LIỆU THAM KHẢO	70

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Ý nghĩa
1	API	Application Programming Interface (Giao diện lập trình ứng dụng)
2	ETL	Extract – Transform – Load (Trích xuất – Chuyển đổi – Nạp dữ liệu)
3	EDA	Exploratory Data Analysis (Phân tích khám phá dữ liệu)
4	DW	Data Warehouse (Kho dữ liệu)
5	ML	Machine Learning (Học máy)
6	NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
7	SQL	Structured Query Language (Ngôn ngữ truy vấn có cấu trúc)
8	XLM-RoBERTa	Cross-lingual RoBERTa (Mô hình RoBERTa đa ngôn ngữ)
9	XGBoost	Extreme Gradient Boosting (Thuật toán tăng cường độ dốc cực đại)
10	ACL	Association for Computational Linguistics (Hiệp hội Ngôn ngữ học Tính toán)
11	CSV	Comma-Separated Values (Định dạng tệp giá trị phân tách bằng dấu phẩy)
12	KPI	Key Performance Indicator (Chỉ số đánh giá hiệu suất)
13	URL	Uniform Resource Locator (Định vị tài nguyên thống nhất)
14	RDBMS	Relational Database Management System (Hệ quản trị cơ sở dữ liệu quan hệ)
15	OLTP	Online Transaction Processing (Xử lý giao dịch trực tuyến)

STT	Từ viết tắt	Ý nghĩa
16	GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
17	JSON	JavaScript Object Notation (Định dạng trao đổi dữ liệu JavaScript)
18	HTML	HyperText Markup Language (Ngôn ngữ đánh dấu siêu văn bản)
19	PK	Primary Key (Khóa chính)
20	FK	Foreign Key (Khóa ngoại)
21	ROC-AUC	Receiver Operating Characteristic - Area Under Curve (Đường cong đặc trưng hoạt động của bộ phân loại – Diện tích dưới đường cong)

DANH MỤC BẢNG BIỂU

Bảng 3.1 Các nhóm dữ liệu được thu thập từ YouTube Data API v3.....	17
Bảng 3.2 Mô tả tập dữ liệu Video	20
Bảng 3.3 Chi tiết các thuộc tính của Video Dataset	20
Bảng 3.4 Mô tả tập dữ liệu Channel.....	21
Bảng 3.5 Chi tiết các thuộc tính của Channel Dataset	21
Bảng 3.6 Mô tả tập dữ liệu Video Statistics	22
Bảng 3.7 Chi tiết các thuộc tính của Video Statistics Dataset	22
Bảng 3.8 Mô tả tập dữ liệu Comment	23
Bảng 3.9 Chi tiết các thuộc tính của Comment Dataset	24
Bảng 3.10 Các bước tiền xử lý dữ liệu	30
Bảng 3.11 Thống kê mô tả các thuộc tính của bộ dữ liệu video sau tích hợp.....	31
Bảng 3.12 Dữ liệu Video sau bước tiền xử lý	31
Bảng 3.13 Các bước xử lý và mục đích của tiền xử lý văn bản	32
Bảng 3.14 Các thuộc tính của Comment Dataset sau phân tích cảm xúc	33
Bảng 3.15 Các đặc trưng cảm xúc được tổng hợp ở cấp độ video	34
Bảng 3.16 Các đặc trưng được xây dựng từ dữ liệu gốc	35
Bảng 3.17 Tỷ lệ cảm xúc trung bình theo trạng thái Trending	46
Bảng 3.18 Các đặc trưng được lựa chọn cho mô hình dự đoán Trending.....	49
Bảng 3.19 Các phép biến đổi dữ liệu trước khi huấn luyện	51
Bảng 3.20 Kết quả chia dữ liệu	52
Bảng 3.21 Các tham số huấn luyện mô hình XGBoost.....	53
Bảng 3.22 Kết quả đánh giá mô hình XGBoost	54

DANH MỤC HÌNH ẢNH

Hình 3.1 Kiến trúc hệ thống phân tích và dự đoán xu hướng video YouTube	16
Hình 3.2 Quy trình thu thập dữ liệu từ YouTube Data API v3	19
Hình 3.3 Sơ đồ Schema được xây dựng cho hệ thống	25
Hình 3.4 Sơ đồ quy trình ETL	27
Hình 3.5 Phân bố trạng thái Trending	37
Hình 3.6 Top 10 thể loại có nhiều video nhất	38
Hình 3.7 Phân bố cảm xúc bình luận.....	39
Hình 3.8 So sánh phân bố lượt xem giữa video Trending và Non-Trending.....	40
Hình 3.9 So sánh phân bố tỷ lệ lượt thích giữa video Trending và Non-Trending.....	41
Hình 3.10 So sánh phân bố tỷ lệ bình luận giữa video Trending và Non-Trending	43
Hình 3.11 So sánh phân bố thời lượng giữa video Trending và Non-Trending.....	44
Hình 3.12 So sánh phân bố lượng người đăng ký giữa video Trending và Non-Trending.....	45
Hình 3.13 Phân bố cảm xúc bình luận theo trạng thái Trending.....	46
Hình 3.14 Hệ số tương quan với biến Trending	47
Hình 3.15 Ma trận nhầm lẫn (Confusion Matrix)	55
Hình 3.16 Độ ảnh hưởng của các đặc trưng	56
Hình 3.17 Kiến trúc tổng thể của ứng dụng dự đoán Trending.....	58
Hình 3.18 Phác thảo bố cục trang Trending Analytics.....	60
Hình 3.19 Phác thảo bố cục trang Predict Trending Analytics	61
Hình 4.1 Giao diện Dashboard tổng quan dữ liệu YouTube.....	63
Hình 4.2. Giao diện trang Trending Analytics	63
Hình 4.3. Giao diện chức năng Predict và kết quả dự đoán Trending	65

TÓM TẮT ĐỒ ÁN TỐT NGHIỆP

Đồ án “Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” tập trung nghiên cứu việc khai thác và phân tích dữ liệu video từ nền tảng YouTube nhằm hỗ trợ dự đoán khả năng video trở thành Trending dựa trên các đặc trưng về nội dung, tương tác và cảm xúc người dùng. Trong bối cảnh dữ liệu mạng xã hội ngày càng phát triển mạnh mẽ, việc phân tích xu hướng video và hành vi người xem có ý nghĩa quan trọng đối với nhà sáng tạo nội dung, doanh nghiệp truyền thông và hoạt động marketing số.

Trong quá trình thực hiện, dữ liệu được thu thập thông qua YouTube Data API v3 từ nhiều lĩnh vực khác nhau như giải trí (Entertainment), trò chơi (Gaming), ẩm thực (Food), công nghệ (Technology) và Vlog. Dữ liệu bao gồm thông tin video, thống kê tương tác, thông tin kênh và bình luận người dùng. Sau khi thu thập, dữ liệu được tiền xử lý bằng Python nhằm loại bỏ dữ liệu trùng lặp, xử lý giá trị thiếu và chuẩn hóa dữ liệu trước khi đưa vào hệ thống lưu trữ.

Đồ án tiến hành xây dựng hệ thống Data Warehouse theo mô hình Star Schema, kết hợp quy trình ETL và lưu trữ dữ liệu trên PostgreSQL nhằm hỗ trợ truy vấn, phân tích và mở rộng dữ liệu hiệu quả. Song song đó, phân tích khám phá dữ liệu (EDA) được thực hiện để xác định các yếu tố ảnh hưởng đến xu hướng Trending của video như lượt xem, lượt thích, bình luận, thời gian đăng tải và mức độ tương tác của người dùng.

Bên cạnh đó, đồ án áp dụng mô hình xử lý ngôn ngữ tự nhiên XLM-RoBERTa để phân tích cảm xúc bình luận người dùng, từ đó xây dựng thêm các đặc trưng phục vụ bài toán dự đoán. Mô hình Machine Learning XGBoost được sử dụng để huấn luyện và dự đoán khả năng video trở thành Trending. Hiệu quả mô hình được đánh giá thông qua các chỉ số Accuracy, Precision, Recall và F1-score.

Kết quả cuối cùng của đồ án được trực quan hóa thông qua dashboard và ứng dụng Streamlit, hỗ trợ người dùng theo dõi dữ liệu, phân tích xu hướng và thử nghiệm dự đoán video Trending trên YouTube một cách trực quan và hiệu quả.

CHƯƠNG MỞ ĐẦU

Lý do chọn đề tài

Trong bối cảnh các nền tảng mạng xã hội phát triển mạnh mẽ, YouTube đã trở thành một trong những nền tảng chia sẻ video lớn nhất thế giới với lượng dữ liệu khổng lồ được tạo ra mỗi ngày. Các video Trending trên YouTube phản ánh xu hướng quan tâm của cộng đồng người dùng và đóng vai trò quan trọng trong hoạt động truyền thông, marketing số cũng như phát triển nội dung số. Việc khai thác và phân tích dữ liệu Trending không chỉ giúp hiểu rõ hành vi người dùng mà còn hỗ trợ nhà sáng tạo nội dung và doanh nghiệp đưa ra chiến lược phát triển phù hợp.

Đề tài “Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” được lựa chọn nhằm nghiên cứu và xây dựng hệ thống hỗ trợ phân tích dữ liệu video YouTube theo hướng kết hợp giữa Data Warehouse, phân tích dữ liệu và Machine Learning. Đề tài tập trung phân tích mối quan hệ giữa các yếu tố như lượt xem, lượt thích, bình luận, thời gian đăng tải và cảm xúc người dùng để đánh giá khả năng video trở thành Trending.

Python được sử dụng do sở hữu hệ sinh thái thư viện mạnh mẽ phục vụ cho quá trình thu thập, xử lý, phân tích dữ liệu và xây dựng mô hình học máy. PostgreSQL được sử dụng để xây dựng kho dữ liệu (Data Warehouse) theo mô hình ngôi sao (Star Schema) nhằm hỗ trợ lưu trữ và truy vấn dữ liệu hiệu quả. Bên cạnh đó, Streamlit được lựa chọn để phát triển ứng dụng trực quan hóa và demo hệ thống dự đoán, giúp trình bày kết quả một cách trực quan và dễ sử dụng.

Mục đích nghiên cứu

Mục đích nghiên cứu của đề tài nhằm thu thập, xử lý và phân tích dữ liệu video Trending trên YouTube, từ đó xác định các yếu tố ảnh hưởng đến khả năng video trở thành Trending, nhận diện xu hướng nội dung và mức độ tương tác của người dùng. Đồng thời, đề tài hướng đến việc xây dựng kho dữ liệu (Data Warehouse) kết hợp mô hình Machine Learning nhằm hỗ trợ dự đoán xu hướng video Trending và trực quan hóa kết quả phục vụ cho việc phân tích và ra quyết định.

Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm dữ liệu video, thông tin kênh và bình luận người dùng trên nền tảng YouTube, với các thông tin như lượt xem, lượt thích, lượt bình luận, thời gian đăng tải, danh mục video và nội dung bình luận.

Bên cạnh đó, đề tài còn nghiên cứu các công nghệ và phương pháp liên quan đến phân tích dữ liệu và xây dựng hệ thống dữ liệu, bao gồm Python trong thu thập và xử lý dữ liệu; Data Warehouse và mô hình Star Schema trong tổ chức lưu trữ dữ liệu; PostgreSQL trong quản lý cơ sở dữ liệu; các phương pháp phân tích cảm xúc bằng mô hình XLM-RoBERTa; cùng với các thuật toán Machine Learning như XGBoost trong bài toán dự đoán video Trending.

Phạm vi nghiên cứu

Nghiên cứu tập trung vào dữ liệu video Trending được thu thập từ YouTube Data API v3 trên nhiều lĩnh vực như Entertainment, Gaming, Food, Technology và Vlog. Phân tích chủ yếu xoay quanh các yếu tố liên quan đến mức độ tương tác của video như lượt xem, lượt thích, lượt bình luận, thời gian đăng tải và cảm xúc người dùng trong bình luận.

Đề tài tập trung xây dựng kho dữ liệu (Data Warehouse) và mô hình dự đoán Trending dựa trên dữ liệu đã thu thập, không đi sâu vào các bài toán xử lý video, nhận diện hình ảnh hoặc phân tích nội dung multimedia chuyên sâu.

Phương pháp nghiên cứu

Phương pháp nghiên cứu được triển khai theo hướng kết hợp giữa nghiên cứu lý thuyết và nghiên cứu thực nghiệm nhằm đảm bảo cả nền tảng khoa học lẫn tính ứng dụng thực tiễn. Cách tiếp cận này cho phép đối chiếu kiến thức đã nghiên cứu với dữ liệu thực tế thu thập từ YouTube, từ đó đánh giá hiệu quả của các mô hình và kỹ thuật được lựa chọn.

Phương pháp nghiên cứu lý thuyết

Nghiên cứu lý thuyết của đề tài được xây dựng dựa trên việc tổng hợp các kiến thức nền tảng trong lĩnh vực phân tích dữ liệu, Data Warehouse, xử lý ngôn ngữ tự nhiên và học máy. Nội dung nghiên cứu tập trung vào các thư viện xử lý dữ liệu trong Python như Pandas, NumPy, Scikit-learn; các kỹ thuật phân tích khám phá dữ liệu (EDA) và thống kê mô tả.

Bên cạnh đó, đề tài nghiên cứu các kiến thức liên quan đến Data Warehouse, mô hình Star Schema, quy trình ETL và hệ quản trị cơ sở dữ liệu PostgreSQL. Ngoài ra, đề tài còn tìm hiểu các phương pháp phân tích cảm xúc bằng mô hình ngôn ngữ tiên huấn luyện XLM-RoBERTa và các thuật toán Machine Learning như XGBoost phục vụ cho bài toán dự đoán video Trending.

Phương pháp nghiên cứu thực nghiệm

Nghiên cứu thực nghiệm được lựa chọn nhằm kiểm chứng các giả thuyết và đánh giá hiệu quả của hệ thống dựa trên dữ liệu thực tế thu thập từ YouTube. Phương pháp này cho phép đánh giá mối quan hệ giữa các yếu tố tương tác của video và khả năng trở thành Trending thông qua các kỹ thuật phân tích dữ liệu và học máy.

Quá trình thực nghiệm bao gồm các bước chính: thu thập dữ liệu từ YouTube Data API v3; tiền xử lý dữ liệu như xử lý giá trị thiếu, loại bỏ dữ liệu trùng lặp và chuẩn hóa dữ liệu; xây dựng kho dữ liệu (Data Warehouse) theo mô hình ngôi sao (Star Schema); thực hiện phân tích khám phá dữ liệu (EDA) để tìm insight và xu hướng; phân tích cảm xúc bình luận người dùng bằng mô hình XLM-RoBERTa; xây dựng và huấn luyện mô hình XGBoost để dự đoán video Trending; cuối cùng là trực quan hóa dữ liệu và triển khai ứng dụng demo bằng Streamlit nhằm hỗ trợ phân tích và đánh giá kết quả.

CHƯƠNG 1: TỔNG QUAN

1.1 Tổng quan đề tài

Đề tài hướng đến việc xây dựng hệ thống Data Warehouse kết hợp phân tích dữ liệu và mô hình Machine Learning nhằm phân tích và dự đoán khả năng video trở thành Trending trên nền tảng YouTube. Trong bối cảnh các nền tảng mạng xã hội và nội dung số phát triển mạnh mẽ, YouTube tạo ra lượng dữ liệu rất lớn liên quan đến video, hành vi người dùng và mức độ tương tác. Việc khai thác và phân tích dữ liệu này có ý nghĩa quan trọng đối với nhà sáng tạo nội dung, doanh nghiệp truyền thông và hoạt động marketing số.

Thông qua việc thu thập dữ liệu video, thông tin kênh và bình luận người dùng từ YouTube Data API v3, đề tài sử dụng Python để thực hiện quá trình xử lý dữ liệu, phân tích khám phá dữ liệu (EDA), phân tích cảm xúc bình luận và xây dựng mô hình học máy dự đoán Trending. Bên cạnh đó, hệ thống Data Warehouse được xây dựng theo mô hình Star Schema nhằm hỗ trợ lưu trữ và truy vấn dữ liệu hiệu quả. Kết quả phân tích và dự đoán được trực quan hóa thông qua dashboard và ứng dụng Streamlit nhằm hỗ trợ theo dõi và đánh giá xu hướng video một cách trực quan.

1.2 Tổng quan về các vấn đề cần giải quyết

Đề tài tập trung giải quyết các vấn đề chính sau:

- Thu thập dữ liệu video, thông tin kênh và bình luận từ YouTube thông qua YouTube Data API v3.
- Tiền xử lý dữ liệu như xử lý missing values, loại bỏ dữ liệu trùng lặp, tiền xử lý văn bản và chuẩn hóa dữ liệu phục vụ cho phân tích.
- Xây dựng hệ thống Data Warehouse theo mô hình Star Schema nhằm hỗ trợ lưu trữ và quản lý dữ liệu phân tích.
- Thực hiện phân tích khám phá dữ liệu (EDA) để xác định các yếu tố ảnh hưởng đến khả năng video trở thành Trending như lượt xem, lượt thích, lượt bình luận và thời gian đăng tải.
- Phân tích cảm xúc bình luận người dùng nhằm đánh giá mức độ phản hồi tích cực, tiêu cực hoặc trung lập đối với video.

- Tiến hành Feature Engineering và xây dựng mô hình Machine Learning để dự đoán khả năng video trở thành Trending.

1.3 Công nghệ và công cụ sử dụng

Các công nghệ và công cụ chính được sử dụng trong đề tài bao gồm:

- Ngôn ngữ lập trình: Python
- Hệ quản trị cơ sở dữ liệu: PostgreSQL
- Data Warehouse: Star Schema, ETL
- API thu thập dữ liệu: YouTube Data API v3
- Thư viện xử lý và phân tích dữ liệu: Pandas, NumPy
- Thư viện trực quan hóa dữ liệu: Matplotlib, Seaborn
- Thư viện Machine Learning: Scikit-learn, XGBoost
- Mô hình xử lý ngôn ngữ tự nhiên: XLM-RoBERTa
- Công cụ xây dựng ứng dụng và dashboard: Streamlit
- Kỹ thuật phân tích: EDA, Sentiment Analysis, Feature Engineering, Machine Learning

1.4 Ý nghĩa thực tiễn đề tài

Ý nghĩa thực tiễn của đề tài được thể hiện qua các khía cạnh sau:

- Hỗ trợ nhà sáng tạo nội dung và doanh nghiệp truyền thông hiểu rõ hơn về các yếu tố ảnh hưởng đến xu hướng Trending trên YouTube.
- Hỗ trợ phân tích hành vi và cảm xúc người dùng thông qua dữ liệu bình luận nhằm đánh giá mức độ quan tâm và phản hồi của cộng đồng.
- Góp phần xây dựng hệ thống lưu trữ và phân tích dữ liệu hiện đại dựa trên mô hình Data Warehouse.
- Hỗ trợ dự đoán xu hướng video Trending bằng các mô hình Machine Learning nhằm phục vụ cho hoạt động marketing và phát triển nội dung số.
- Giúp nâng cao khả năng trực quan hóa dữ liệu và hỗ trợ ra quyết định dựa trên dữ liệu thực tế thông qua dashboard và ứng dụng Streamlit.

CHƯƠNG 2: NGHIÊN CỨU LÝ THUYẾT

2.1 Phân tích dữ liệu

Phân tích dữ liệu (Data Analytics) là quá trình thu thập, xử lý, làm sạch, khám phá và diễn giải dữ liệu nhằm phát hiện các thông tin hữu ích và tri thức tiềm ẩn phục vụ cho việc ra quyết định. Quá trình này giúp biến dữ liệu thô thành các insight có ý nghĩa, hỗ trợ doanh nghiệp và tổ chức trong việc đánh giá hiện trạng, tối ưu hoạt động và xây dựng chiến lược hiệu quả. Trong thực tiễn, phân tích dữ liệu thường được chia thành các cấp độ chính [1]:

- Phân tích mô tả (Descriptive Analytics): tập trung vào việc mô tả và tóm tắt dữ liệu trong quá khứ thông qua các chỉ số thống kê như trung bình, trung vị, độ lệch chuẩn và các biểu đồ trực quan, nhằm trả lời câu hỏi “Điều gì đã xảy ra?”.

- Phân tích chẩn đoán (Diagnostic Analytics): đi sâu phân tích dữ liệu để tìm hiểu nguyên nhân dẫn đến các hiện tượng đã xảy ra, trả lời câu hỏi “Vì sao điều đó xảy ra?”.

- Phân tích dự đoán (Predictive Analytics): sử dụng các mô hình thống kê và học máy để dự đoán xu hướng hoặc kết quả trong tương lai dựa trên dữ liệu lịch sử, trả lời câu hỏi “Điều gì có thể xảy ra tiếp theo?”.

Trong phạm vi đề tài này, phân tích dữ liệu được áp dụng để nghiên cứu các yếu tố ảnh hưởng đến khả năng video xuất hiện trong danh sách Trending trên YouTube. Phân tích mô tả được sử dụng để tổng hợp và đánh giá các đặc điểm của dữ liệu như lượt xem, lượt thích, lượt bình luận, thời lượng video và số lượng người đăng ký kênh. Phân tích chẩn đoán giúp làm rõ mối quan hệ giữa các chỉ số tương tác và khả năng trở thành Trending của video. Trên cơ sở đó, phân tích dự đoán được áp dụng nhằm xây dựng các mô hình học máy dự đoán khả năng video trở thành Trending dựa trên các đặc trưng đầu vào đã phân tích.

2.2 Phân tích khám phá dữ liệu

Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA) là giai đoạn quan trọng và chiếm nhiều thời gian trong quy trình phân tích dữ liệu, được thực hiện nhằm hiểu rõ cấu trúc, đặc điểm và phân bố của tập dữ liệu trước khi xây dựng mô hình học máy. Thông qua phân tích khám phá dữ liệu (EDA), các vấn đề thường gặp như dữ liệu thiếu, dữ liệu nhiễu, các giá trị ngoại lai (outlier) và mối quan hệ giữa các biến có thể được phát hiện và xử lý sớm, góp phần nâng cao chất lượng dữ liệu đầu vào [2].

Các kỹ thuật phân tích khám phá dữ liệu (EDA) phổ biến bao gồm thống kê mô tả, phân tích phân bố dữ liệu, phân tích tương quan và các phương pháp trực quan hóa dữ liệu bằng biểu đồ. Trong đề tài này, phân tích khám phá dữ liệu (EDA) được áp dụng trên tập dữ liệu YouTube được thu thập thông qua YouTube Data API v3 nhằm phân tích đặc điểm của các biến như lượt xem, lượt thích, lượt bình luận, thời lượng video, số lượng người đăng ký kênh và các chỉ số tương tác khác.

Cụ thể, phân tích khám phá dữ liệu (EDA) được sử dụng để:

- Phân tích phân bố của các chỉ số như lượt xem, lượt thích và lượt bình luận nhằm nhận diện các giá trị bất thường;
- So sánh đặc điểm giữa nhóm video Trending và Non-Trending thông qua các biểu đồ trực quan và thống kê mô tả;
- Đánh giá mối quan hệ giữa các chỉ số tương tác, thông tin kênh và khả năng trở thành Trending của video;
- Xác định các đặc trưng có ảnh hưởng đáng kể đến kết quả dự đoán để phục vụ cho quá trình xây dựng mô hình học máy.

Kết quả từ bước phân tích khám phá dữ liệu (EDA) giúp hiểu rõ hơn về đặc điểm dữ liệu YouTube, đồng thời hỗ trợ quá trình lựa chọn đặc trưng, xây dựng mô hình và đánh giá các yếu tố ảnh hưởng đến khả năng video trở thành Trending trong các phần tiếp theo của đề tài.

2.3 Kho dữ liệu

Kho dữ liệu (Data Warehouse) là hệ thống lưu trữ dữ liệu tập trung được thiết kế nhằm hỗ trợ hoạt động phân tích, báo cáo và ra quyết định. Khác với các hệ thống xử lý giao dịch trực tuyến (OLTP), kho dữ liệu tập trung vào việc lưu trữ dữ liệu lịch sử đã được tích hợp từ nhiều nguồn khác nhau và được tối ưu hóa cho các truy vấn phân tích. Dữ liệu trong kho dữ liệu thường mang tính ổn định, được tổ chức theo chủ đề và có khả năng lưu trữ trong thời gian dài nhằm phục vụ cho việc đánh giá xu hướng và hỗ trợ ra quyết định [3].

2.3.1 Mô hình hình sao

Mô hình hình sao (Star Schema) là mô hình tổ chức dữ liệu phổ biến nhất trong các hệ thống kho dữ liệu. Mô hình này bao gồm một bảng sự kiện (Fact Table) ở trung tâm và các bảng chiều (Dimension Table) được liên kết trực tiếp xung quanh. Bảng sự kiện lưu trữ các dữ liệu định lượng như doanh thu, số lượng hoặc các chỉ số thống kê,

trong khi các bảng chiều lưu trữ thông tin mô tả giúp hỗ trợ quá trình phân tích dữ liệu [4].

Ưu điểm của Star Schema là cấu trúc đơn giản, dễ triển khai và dễ truy vấn. Do các bảng chiều được kết nối trực tiếp với bảng sự kiện nên số lượng phép kết nối (JOIN) được giảm đáng kể, giúp nâng cao hiệu năng truy vấn và phân tích dữ liệu.

2.3.2 Mô hình bông tuyết

Mô hình bông tuyết (Snowflake Schema) là phiên bản chuẩn hóa của mô hình hình sao. Trong mô hình này, các bảng chiều được tách thành nhiều bảng nhỏ hơn nhằm giảm sự dư thừa dữ liệu và tăng tính nhất quán trong quá trình lưu trữ [4].

Mặc dù giúp tiết kiệm không gian lưu trữ và giảm trùng lặp dữ liệu, Snowflake Schema làm tăng số lượng bảng cũng như số lượng phép kết nối khi truy vấn. Điều này có thể làm giảm hiệu năng xử lý đối với các tác vụ phân tích dữ liệu có khối lượng lớn.

2.3.3 Mô hình chòm sao sự kiện

Mô hình chòm sao sự kiện (Galaxy Schema), còn được gọi là Fact Constellation Schema, là mô hình mở rộng của Star Schema. Mô hình này sử dụng nhiều bảng sự kiện cùng chia sẻ các bảng chiều chung nhằm hỗ trợ các hệ thống có nhiều quy trình nghiệp vụ và yêu cầu phân tích phức tạp [4].

Galaxy Schema phù hợp với các hệ thống kho dữ liệu quy mô lớn, nơi dữ liệu được thu thập từ nhiều hoạt động khác nhau. Tuy nhiên, việc thiết kế và quản lý mô hình này thường phức tạp hơn so với Star Schema và Snowflake Schema.

Mỗi mô hình tổ chức dữ liệu trong kho dữ liệu đều có những ưu điểm và phạm vi ứng dụng riêng. Trong phạm vi đề tài này, mô hình hình sao (Star Schema) được lựa chọn để xây dựng kho dữ liệu cho hệ thống YouTube Data Warehouse. Nguyên nhân là do dữ liệu của đề tài chủ yếu phục vụ cho việc phân tích hiệu suất video, hành vi tương tác của người dùng và dự đoán khả năng video trở thành Trending. So với Snowflake Schema và Galaxy Schema, Star Schema có cấu trúc đơn giản, dễ triển khai và phù hợp với đặc điểm dữ liệu của đề tài. Đồng thời, mô hình này giúp giảm số lượng phép kết nối giữa các bảng khi truy vấn, từ đó nâng cao hiệu năng xử lý dữ liệu và hỗ trợ hiệu quả cho các hoạt động phân tích dữ liệu, trực quan hóa dữ liệu và huấn luyện mô hình học máy.

2.4 Quy trình ETL

ETL (Extract – Transform – Load) là quy trình trích xuất, chuyển đổi và nạp dữ liệu, đóng vai trò quan trọng trong các hệ thống kho dữ liệu. Mục tiêu của ETL là thu thập dữ liệu từ nhiều nguồn khác nhau, xử lý và chuẩn hóa dữ liệu trước khi đưa vào kho dữ liệu để phục vụ cho các hoạt động phân tích và ra quyết định [5].

2.4.1 Giai đoạn trích xuất dữ liệu

Giai đoạn trích xuất dữ liệu (Extract) là bước đầu tiên trong quy trình ETL, nhằm thu thập dữ liệu từ các nguồn khác nhau và đưa vào khu vực lưu trữ tạm thời để phục vụ cho quá trình xử lý tiếp theo. Trong đề tài này, dữ liệu được thu thập từ YouTube Data API v3, bao gồm thông tin video, kênh, thống kê tương tác và bình luận của người dùng. Quá trình trích xuất được thực hiện tự động bằng ngôn ngữ Python, giúp đảm bảo khả năng thu thập dữ liệu liên tục, giảm thiểu sai sót trong quá trình nhập liệu thủ công và đáp ứng yêu cầu về khối lượng dữ liệu lớn.

Bên cạnh việc thu thập dữ liệu, hệ thống còn thực hiện kiểm tra tính đầy đủ của dữ liệu đầu vào như định dạng thời gian, mã video, mã kênh và các chỉ số tương tác. Việc kiểm tra này giúp phát hiện sớm các bản ghi bị thiếu hoặc không hợp lệ trước khi chuyển sang giai đoạn xử lý dữ liệu, từ đó nâng cao chất lượng dữ liệu trong toàn bộ hệ thống kho dữ liệu. Theo các nghiên cứu gần đây, chất lượng của giai đoạn trích xuất có ảnh hưởng trực tiếp đến độ tin cậy của dữ liệu phục vụ phân tích và ra quyết định [5].

2.4.2 Giai đoạn chuyển đổi dữ liệu

Ở giai đoạn chuyển đổi dữ liệu (Transform) dữ liệu tiếp tục được xử lý và chuyển đổi nhằm đảm bảo tính nhất quán trước khi lưu trữ trong kho dữ liệu. Trong giai đoạn này, dữ liệu được làm sạch bằng cách loại bỏ các bản ghi trùng lặp, xử lý giá trị thiếu, chuẩn hóa định dạng ngày giờ và chuyển đổi các trường dữ liệu về kiểu dữ liệu phù hợp. Ngoài ra, các trường thời lượng video được chuyển đổi từ định dạng ISO 8601 sang đơn vị giây để thuận tiện cho việc phân tích và xây dựng mô hình học máy.

Bên cạnh việc làm sạch dữ liệu, quá trình chuyển đổi còn bao gồm việc tích hợp dữ liệu từ nhiều nguồn khác nhau để xây dựng các bảng chiều và bảng sự kiện trong kho dữ liệu. Các khóa thay thế (Surrogate Key) được tạo ra nhằm đảm bảo tính toàn vẹn dữ liệu giữa các bảng. Đồng thời, dữ liệu bình luận được xử lý cảm xúc bằng mô hình XLM-RoBERTa để xác định các nhận tích cực, trung tính và tiêu cực, từ đó hỗ trợ phân tích xu hướng nội dung trên nền tảng YouTube. Các nghiên cứu hiện nay cho thấy giai

đoạn chuyển đổi đóng vai trò quan trọng trong việc nâng cao chất lượng dữ liệu và hiệu quả của các hệ thống phân tích dữ liệu hiện đại [5].

2.4.3 Giai đoạn nạp dữ liệu

Sau khi hoàn thành quá trình chuyển đổi, dữ liệu được nạp (Load) vào kho dữ liệu PostgreSQL theo mô hình Star Schema. Các bảng chiều như `dim_video`, `dim_channel`, `dim_topic`, `dim_comment` và `dim_time` được nạp trước nhằm đảm bảo các khóa tham chiếu đã được thiết lập đầy đủ. Tiếp theo, dữ liệu được nạp vào các bảng sự kiện như `fact_video_metrics` để phục vụ cho việc truy vấn và phân tích.

Quá trình nạp dữ liệu được thực hiện theo từng lô (batch loading) nhằm tối ưu hiệu năng xử lý và giảm tải cho hệ thống cơ sở dữ liệu. Sau khi dữ liệu được nạp thành công, hệ thống tiến hành kiểm tra số lượng bản ghi, tính toàn vẹn khóa ngoại và độ chính xác của dữ liệu giữa nguồn và đích. Việc áp dụng quy trình nạp dữ liệu có kiểm soát giúp đảm bảo tính ổn định của kho dữ liệu, đồng thời tạo nền tảng cho các hoạt động phân tích, trực quan hóa dữ liệu và xây dựng mô hình dự đoán xu hướng video YouTube [5].

2.5 Hệ quản trị cơ sở dữ liệu PostgreSQL

PostgreSQL là hệ quản trị cơ sở dữ liệu quan hệ mã nguồn mở (Open Source Relational Database Management System - RDBMS) được sử dụng rộng rãi trong các hệ thống lưu trữ và phân tích dữ liệu nhờ tính ổn định, khả năng mở rộng và hiệu năng xử lý cao. PostgreSQL hỗ trợ chuẩn SQL và cung cấp nhiều tính năng nâng cao như quản lý giao dịch (Transaction), chỉ mục (Index), khóa ngoại (Foreign Key), thủ tục lưu trữ (Stored Procedure) và cơ chế đảm bảo tính toàn vẹn dữ liệu [6].

Một trong những ưu điểm nổi bật của PostgreSQL là khả năng xử lý hiệu quả các tập dữ liệu lớn và hỗ trợ nhiều kiểu dữ liệu khác nhau, bao gồm dữ liệu có cấu trúc và bán cấu trúc. Bên cạnh đó, PostgreSQL cho phép thực hiện các truy vấn phức tạp với hiệu năng cao, phù hợp cho các hệ thống kho dữ liệu và các ứng dụng phân tích dữ liệu.

Trong lĩnh vực phân tích dữ liệu, PostgreSQL thường được sử dụng làm nền tảng lưu trữ dữ liệu nhờ khả năng hỗ trợ các thao tác tổng hợp, thống kê và truy vấn dữ liệu hiệu quả. Ngoài ra, hệ quản trị này còn cung cấp cơ chế quản lý dữ liệu đáng tin cậy, hỗ trợ nhiều người dùng truy cập đồng thời và đảm bảo tính nhất quán của dữ liệu trong quá trình vận hành.

Trong phạm vi đề tài này, PostgreSQL được sử dụng làm hệ quản trị cơ sở dữ liệu cho hệ thống YouTube Data Warehouse. Dữ liệu sau khi trải qua quy trình ETL sẽ được

lưu trữ trong PostgreSQL theo mô hình hình sao (Star Schema). Việc sử dụng PostgreSQL giúp quản lý dữ liệu tập trung, hỗ trợ truy vấn nhanh chóng và tạo nền tảng cho các hoạt động phân tích dữ liệu, phân tích cảm xúc và xây dựng mô hình dự đoán khả năng video trở thành Trending.

2.6 Phân tích cảm xúc

Phân tích cảm xúc (Sentiment Analysis) là một bài toán thuộc lĩnh vực Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP), nhằm xác định cảm xúc hoặc thái độ của người dùng thông qua dữ liệu văn bản. Mục tiêu của phân tích cảm xúc là phân loại nội dung thành các nhóm như tích cực, tiêu cực hoặc trung tính [7].

Trong môi trường mạng xã hội và nền tảng video trực tuyến như YouTube, bình luận của người dùng phản ánh mức độ quan tâm, đánh giá và phản ứng của cộng đồng đối với nội dung video. Vì vậy, việc phân tích cảm xúc từ bình luận có thể cung cấp thêm nhiều thông tin hữu ích trong quá trình đánh giá mức độ phổ biến của video.

Trong đề tài này, dữ liệu bình luận được thu thập thông qua YouTube Data API v3, sau đó được tiền xử lý nhằm loại bỏ ký tự đặc biệt, URL, emoji và các thành phần nhiễu trước khi đưa vào mô hình phân tích cảm xúc. Kết quả phân tích cảm xúc được sử dụng như một đặc trưng bổ sung phục vụ cho bài toán dự đoán video Trending.

Mô hình XLM-RoBERTa là mô hình Transformer đa ngôn ngữ được phát triển dựa trên kiến trúc RoBERTa và được huấn luyện trên tập dữ liệu văn bản với nhiều ngôn ngữ khác nhau. Mô hình có khả năng hiểu ngữ cảnh và biểu diễn ngôn ngữ hiệu quả hơn so với các phương pháp truyền thống dựa trên từ khóa hoặc từ điển cảm xúc. Nhờ khả năng hỗ trợ đa ngôn ngữ, XLM-RoBERTa phù hợp với dữ liệu bình luận YouTube vì bình luận thường chứa nhiều ngôn ngữ khác nhau và có đặc điểm ngôn ngữ không chuẩn như viết tắt, slang hoặc emoji [8].

Trong đề tài này, mô hình XLM-RoBERTa được sử dụng để phân loại cảm xúc của bình luận người dùng thành các nhóm tích cực, tiêu cực và trung tính. Kết quả phân tích cảm xúc giúp bổ sung thêm thông tin về phản ứng của cộng đồng đối với video, từ đó hỗ trợ cải thiện hiệu quả của mô hình Machine Learning trong bài toán dự đoán video Trending trên YouTube.

2.7 Machine Learning trong dự đoán Trending

Học máy (Machine Learning) là một lĩnh vực thuộc trí tuệ nhân tạo (Artificial Intelligence - AI), cho phép hệ thống học từ dữ liệu và đưa ra dự đoán mà không cần lập trình tường minh cho từng trường hợp cụ thể. Thay vì xây dựng các quy tắc cố định, mô hình học máy có khả năng tự tìm ra các mẫu và mối quan hệ trong dữ liệu để đưa ra kết quả dự đoán [9].

2.7.1 Bài toán phân loại

Bài toán phân loại (Classification) là một trong những bài toán phổ biến của học máy, trong đó mô hình được huấn luyện để dự đoán nhãn của một đối tượng dựa trên các đặc trưng đầu vào. Kết quả dự đoán thường thuộc một hoặc nhiều lớp đã được xác định trước.

Trong đề tài này, bài toán được xây dựng dưới dạng phân loại nhị phân, với mục tiêu dự đoán liệu một video có trở thành Trending hay không. Dựa trên các đặc trưng thu thập từ dữ liệu YouTube, mô hình sẽ học các mẫu và mối quan hệ trong dữ liệu để đưa ra kết quả dự đoán cho từng video.

2.7.2 Thuật toán XGBoost

XGBoost (Extreme Gradient Boosting) là một thuật toán học máy thuộc nhóm Ensemble Learning, được phát triển dựa trên kỹ thuật Gradient Boosting. Thuật toán sử dụng cây quyết định (Decision Tree) làm mô hình cơ sở và xây dựng nhiều cây theo cơ chế tuần tự nhằm cải thiện độ chính xác dự đoán. Trong quá trình huấn luyện, mỗi cây mới được tạo ra để học các sai số còn lại của các cây trước đó, từ đó từng bước nâng cao hiệu quả dự đoán của toàn bộ mô hình.

Khác với các thuật toán học máy truyền thống chỉ sử dụng một mô hình duy nhất, XGBoost kết hợp kết quả của nhiều cây quyết định để tạo thành mô hình dự đoán cuối cùng. Nhờ cơ chế này, thuật toán có khả năng khai thác tốt các mối quan hệ phi tuyến giữa các đặc trưng đầu vào và biến mục tiêu, đồng thời giảm ảnh hưởng của sai số từ từng mô hình riêng lẻ.

Đối với XGBoost, giá trị dự đoán của một quan sát được xác định bằng tổng kết quả dự đoán của tất cả các cây quyết định trong mô hình. Công thức dự đoán được biểu diễn như sau:

Công thức dự đoán XGBoost [12]:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (2.1)$$

- $\hat{y}_i$ giá trị dự đoán của quan sát thứ (i).
- f_k cây quyết định thứ (K) trong mô hình.
- x_i là tập đặc trưng đầu vào của quan sát thứ (i).
- K là tổng số cây quyết định được xây dựng trong mô hình.

Công thức (2.1) cho thấy kết quả dự đoán cuối cùng được tạo thành từ sự kết hợp của nhiều cây quyết định. Mỗi cây mới được xây dựng nhằm hiệu chỉnh sai số của các cây trước đó, giúp mô hình đạt độ chính xác cao hơn so với việc sử dụng một cây quyết định đơn lẻ.

Một trong những ưu điểm nổi bật của XGBoost là việc bổ sung thành phần điều chuẩn (Regularization) vào hàm mục tiêu nhằm kiểm soát độ phức tạp của mô hình và hạn chế hiện tượng quá khớp (Overfitting). Hàm mục tiêu của XGBoost bao gồm hai thành phần chính là hàm mất mát (Loss Function) và thành phần điều chuẩn (Regularization Term). Dạng tổng quát của hàm mục tiêu được thể hiện như sau:

Hàm mục tiêu XGBoost [12]:

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (2.2)$$

- Obj là giá trị hàm mục tiêu (Objective Function) của mô hình XGBoost.
- $l(y_i, \hat{y}_i)$ là hàm mất mát dùng để đo lường sai lệch giữa giá trị thực tế và giá trị dự đoán.
- $\Omega(f_k)$ là thành phần điều chuẩn (Regularization Term) của cây quyết định thứ (K), giúp kiểm soát độ phức tạp của mô hình và hạn chế hiện tượng quá khớp.
- n là số lượng quan sát trong tập dữ liệu.
- K là tổng số cây quyết định được sử dụng trong mô hình.

Thông qua hàm mục tiêu này, XGBoost không chỉ tập trung vào việc giảm sai số dự đoán mà còn hướng đến việc xây dựng mô hình có khả năng tổng quát hóa tốt trên dữ liệu mới. Điều này giúp hạn chế hiện tượng mô hình học quá mức trên tập huấn luyện và cải thiện hiệu suất khi áp dụng vào dữ liệu thực tế.

Bên cạnh cơ chế Boosting và Regularization, XGBoost còn hỗ trợ nhiều kỹ thuật tối ưu khác như xử lý dữ liệu thiếu, cắt tỉa cây quyết định (Tree Pruning), tính toán song song và tối ưu hóa bộ nhớ. Nhờ đó, thuật toán có thể huấn luyện hiệu quả trên các tập dữ liệu lớn với thời gian xử lý ngắn hơn so với nhiều phương pháp Ensemble Learning khác.

Với những ưu điểm như khả năng dự đoán chính xác, xử lý tốt dữ liệu dạng bảng, hỗ trợ dữ liệu có nhiều đặc trưng và khả năng chống quá khớp hiệu quả, XGBoost được lựa chọn trong nghiên cứu này để xây dựng mô hình dự đoán khả năng video xuất hiện trong danh sách Trending trên nền tảng YouTube.

2.7.3 Feature Engineering

Feature Engineering là quá trình tạo mới, biến đổi hoặc lựa chọn các đặc trưng nhằm nâng cao chất lượng dữ liệu đầu vào cho mô hình học máy. Chất lượng của đặc trưng có ảnh hưởng trực tiếp đến hiệu quả dự đoán của mô hình.

Trong thực tế, dữ liệu thu thập được thường chưa phản ánh đầy đủ các đặc điểm cần thiết cho quá trình học. Do đó, việc xây dựng các đặc trưng mới giúp mô hình khai thác thông tin hiệu quả hơn và cải thiện khả năng dự đoán.

Trong đề tài này, một số đặc trưng được xây dựng từ dữ liệu gốc như tỷ lệ lượt thích trên lượt xem (Like Rate), tỷ lệ bình luận trên lượt xem (Comment Rate) và các đặc trưng liên quan đến thời gian đăng tải video. Ngoài ra, kết quả phân tích cảm xúc từ bình luận người dùng cũng được sử dụng như một đặc trưng bổ sung phục vụ cho quá trình huấn luyện mô hình.

2.7.4 Các chỉ số đánh giá mô hình

Đối với bài toán phân loại, việc đánh giá hiệu quả mô hình không chỉ dựa trên số lượng dự đoán đúng mà còn cần xem xét khả năng nhận diện chính xác từng lớp dữ liệu. Vì vậy, nhiều chỉ số đánh giá khác nhau được sử dụng nhằm phản ánh toàn diện hiệu suất của mô hình.

Độ chính xác (Accuracy) là tỷ lệ số lượng dự đoán đúng trên tổng số mẫu dữ liệu. Chỉ số này phản ánh mức độ chính xác tổng thể của mô hình. Tuy nhiên, Accuracy có thể không phản ánh đầy đủ hiệu quả mô hình khi dữ liệu bị mất cân bằng giữa các lớp. Ví dụ, nếu phần lớn dữ liệu thuộc lớp Non-Trending thì mô hình vẫn có thể đạt Accuracy cao mặc dù khả năng phát hiện video Trending không tốt.

Độ chính xác dương (Precision) là tỷ lệ các mẫu được dự đoán thuộc lớp Trending thực sự là Trending. Chỉ số này phản ánh độ tin cậy của các dự đoán do mô hình đưa ra. Precision cao cho thấy phần lớn các video được dự đoán là Trending đều thực sự có khả năng trở thành Trending.

Độ bao phủ (Recall) là tỷ lệ các video Trending thực tế được mô hình nhận diện đúng. Chỉ số này phản ánh khả năng phát hiện đầy đủ các video Trending trong tập dữ liệu. Recall cao giúp giảm số lượng video Trending bị bỏ sót bởi mô hình.

Điểm F1 (F1-score) là trung bình điều hòa giữa Precision và Recall. Chỉ số này được sử dụng khi cần đánh giá sự cân bằng giữa khả năng dự đoán chính xác và khả năng phát hiện đầy đủ các mẫu thuộc lớp mục tiêu. F1-score thường được sử dụng trong các bài toán phân loại khi cần xem xét đồng thời cả Precision và Recall.

Trong đề tài này, dữ liệu được xây dựng dưới dạng bài toán phân loại nhị phân giữa video Trending và Non-Trending. Do mục tiêu của hệ thống là nhận diện chính xác các video có khả năng trở thành Trending, bên cạnh Accuracy, các chỉ số Precision, Recall và F1-score cũng được đặc biệt quan tâm. Trong đó, Recall giúp đánh giá khả năng phát hiện các video Trending, Precision phản ánh độ tin cậy của các dự đoán Trending, còn F1-score được sử dụng như một chỉ số tổng hợp để đánh giá sự cân bằng giữa hai yếu tố này. Các chỉ số trên sẽ được sử dụng trong Chương 4 để đánh giá và so sánh hiệu quả giữa các mô hình Machine Learning, từ đó lựa chọn mô hình phù hợp nhất cho hệ thống.

2.8 Trực quan hóa dữ liệu và Streamlit

2.8.1 Trực quan hóa dữ liệu

Trực quan hóa dữ liệu (Data Visualization) là quá trình biểu diễn dữ liệu dưới dạng đồ họa nhằm giúp người dùng dễ dàng quan sát, phân tích và hiểu được các thông tin quan trọng từ dữ liệu. Thay vì trình bày dữ liệu dưới dạng các bảng số liệu phức tạp, trực quan hóa dữ liệu sử dụng các biểu đồ, đồ thị và dashboard để chuyển đổi dữ liệu thành các hình thức trực quan, giúp người dùng nhanh chóng nhận diện xu hướng, mối quan hệ giữa các biến và các giá trị bất thường trong tập dữ liệu [10].

Trong lĩnh vực phân tích dữ liệu, trực quan hóa dữ liệu đóng vai trò quan trọng trong toàn bộ quy trình nghiên cứu, từ giai đoạn khám phá dữ liệu (Exploratory Data Analysis - EDA) đến giai đoạn đánh giá và trình bày kết quả. Thông qua các biểu đồ trực quan, nhà phân tích có thể hiểu rõ đặc điểm phân bố của dữ liệu, xác định các ngoại

lệ (Outliers), phát hiện các mẫu dữ liệu tiềm ẩn và đánh giá mối quan hệ giữa các thuộc tính. Điều này giúp hỗ trợ quá trình lựa chọn đặc trưng, xây dựng mô hình và đưa ra các quyết định dựa trên dữ liệu một cách hiệu quả hơn.

Các kỹ thuật trực quan hóa dữ liệu phổ biến bao gồm biểu đồ cột (Bar Chart), biểu đồ đường (Line Chart), biểu đồ tròn (Pie Chart), biểu đồ phân phối (Histogram), biểu đồ hộp (Boxplot), biểu đồ phân tán (Scatter Plot) và bản đồ nhiệt (Heatmap). Mỗi loại biểu đồ được sử dụng cho những mục đích khác nhau. Ví dụ, biểu đồ cột thường được sử dụng để so sánh dữ liệu giữa các nhóm, biểu đồ đường giúp quan sát xu hướng theo thời gian, trong khi Heatmap hỗ trợ đánh giá mức độ tương quan giữa các biến trong tập dữ liệu.

Bên cạnh vai trò hỗ trợ phân tích, trực quan hóa dữ liệu còn là công cụ quan trọng trong việc truyền đạt kết quả nghiên cứu đến người dùng cuối. Các dashboard trực quan giúp tổng hợp nhiều chỉ số quan trọng trên cùng một giao diện, từ đó hỗ trợ quá trình giám sát, theo dõi và ra quyết định. Trong các hệ thống phân tích dữ liệu hiện đại, dashboard tương tác được sử dụng rộng rãi để cung cấp thông tin theo thời gian thực và hỗ trợ người dùng khai thác dữ liệu một cách trực quan. Trực quan hóa không chỉ đóng vai trò trình bày dữ liệu mà còn là cầu nối giữa dữ liệu, mô hình phân tích và quá trình ra quyết định [10].

Trong phạm vi đề tài này, trực quan hóa dữ liệu được áp dụng xuyên suốt quá trình nghiên cứu nhằm hỗ trợ phân tích dữ liệu YouTube và đánh giá các yếu tố ảnh hưởng đến khả năng video trở thành Trending. Các thư viện Matplotlib và Seaborn được sử dụng để xây dựng các biểu đồ phục vụ cho quá trình phân tích khám phá dữ liệu. Những biểu đồ này giúp đánh giá sự khác biệt giữa nhóm video Trending và Non-Trending thông qua các đặc trưng như lượt xem, tỷ lệ lượt thích, tỷ lệ bình luận, thời lượng video, số lượng người đăng ký kênh và các chỉ số cảm xúc từ bình luận người dùng.

2.8.2 Streamlit

Streamlit là một framework mã nguồn mở dành cho ngôn ngữ Python, được thiết kế nhằm hỗ trợ xây dựng các ứng dụng web và dashboard phục vụ cho phân tích dữ liệu, khoa học dữ liệu (Data Science) và học máy (Machine Learning) một cách nhanh chóng. Khác với các framework phát triển web truyền thống yêu cầu kiến thức về HTML, CSS

hoặc JavaScript, Streamlit cho phép lập trình viên xây dựng giao diện tương tác chỉ bằng Python, từ đó rút ngắn đáng kể thời gian phát triển ứng dụng [11].

Một trong những ưu điểm nổi bật của Streamlit là khả năng tích hợp trực tiếp với các thư viện xử lý dữ liệu và học máy phổ biến như Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn, XGBoost và PyTorch. Điều này giúp quá trình triển khai các mô hình phân tích dữ liệu và Machine Learning trở nên đơn giản hơn, đồng thời hỗ trợ hiển thị trực quan các kết quả phân tích ngay trên giao diện web.

Streamlit cung cấp nhiều thành phần giao diện tương tác như bảng dữ liệu, biểu đồ, bộ lọc dữ liệu, hộp nhập liệu, thanh trượt (Slider), nút bấm và các thành phần điều hướng. Các thành phần này cho phép người dùng tương tác trực tiếp với dữ liệu và mô hình mà không cần thực hiện các thao tác kỹ thuật phức tạp. Bên cạnh đó, Streamlit hỗ trợ cơ chế cập nhật giao diện theo thời gian thực, giúp kết quả thay đổi ngay khi người dùng điều chỉnh tham số đầu vào.

Trong các dự án phân tích dữ liệu và học máy, Streamlit thường được sử dụng để xây dựng dashboard phân tích, hệ thống báo cáo dữ liệu và các ứng dụng dự đoán phục vụ cho việc trình diễn mô hình. Nhờ khả năng triển khai nhanh, framework này được sử dụng rộng rãi trong cộng đồng Data Science nhằm chuyển đổi các mô hình nghiên cứu thành các ứng dụng có thể sử dụng trong thực tế.

Đối với đề tài này, Streamlit được lựa chọn làm nền tảng phát triển ứng dụng YouTube Trending Analytics & Prediction System. Ứng dụng được xây dựng nhằm hỗ trợ người dùng theo dõi dữ liệu Trending trên YouTube, trực quan hóa các chỉ số thống kê quan trọng và thực hiện dự đoán khả năng video trở thành Trending bằng mô hình XGBoost đã được huấn luyện trước.

Hệ thống được thiết kế với hai chức năng chính. Chức năng thứ nhất là phân tích (Trending Analytics), cho phép hiển thị các video đang thịnh hành theo từng quốc gia hoặc khu vực, đồng thời cung cấp các biểu đồ và dashboard phục vụ cho việc phân tích xu hướng nội dung trên YouTube. Chức năng thứ hai là dự đoán (Predict), cho phép người dùng nhập đường dẫn video hoặc cung cấp các thông số đầu vào để mô hình Machine Learning dự đoán khả năng video xuất hiện trong danh sách Trending.

Việc sử dụng Streamlit giúp kết nối giữa hệ thống Data Warehouse, các kết quả phân tích dữ liệu và mô hình học máy trong cùng một môi trường trực quan.

CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU

3.1 Quy trình nghiên cứu tổng thể

Đề tài được thực hiện nhằm xây dựng hệ thống phân tích và dự đoán khả năng video trở thành Trending trên nền tảng YouTube thông qua việc kết hợp giữa Data Warehouse, phân tích dữ liệu, xử lý ngôn ngữ tự nhiên và Machine Learning. Quy trình nghiên cứu được triển khai theo một chuỗi các giai đoạn liên kết với nhau, từ thu thập dữ liệu đến xây dựng mô hình dự đoán và triển khai ứng dụng.

Quy trình nghiên cứu gồm các bước chính như sau:


- Bước 1: Thu thập dữ liệu (Data Collection): Dữ liệu được thu thập từ YouTube Data API v3 bằng ngôn ngữ Python, bao gồm thông tin video, kênh và bình luận người dùng. Dữ liệu được lưu trữ dưới dạng dữ liệu thô để phục vụ cho các bước xử lý tiếp theo.

- Bước 2: Xây dựng hệ thống Data Warehouse (Data Engineering & Modeling): Dữ liệu thô được xử lý thông qua quy trình ETL nhằm làm sạch, chuẩn hóa và tích hợp dữ liệu. Sau đó dữ liệu được lưu trữ trong PostgreSQL theo mô hình Star Schema để phục vụ cho việc truy vấn và phân tích.

- Bước 3: Tiền xử lý và chuẩn bị dữ liệu (Data Transformation & Preparation): Dữ liệu được làm sạch, xử lý giá trị thiếu, phân tích cảm xúc bình luận bằng mô hình XLM-RoBERTa và xây dựng các đặc trưng phục vụ cho quá trình phân tích cũng như huấn luyện mô hình.

- Bước 4: Xây dựng mô hình dự đoán (Training & Prediction Pipeline): Tập dữ liệu sau khi hoàn thiện được chia thành tập huấn luyện và tập kiểm tra để xây dựng mô hình Machine Learning. Trong phạm vi đề tài, thuật toán XGBoost được lựa chọn do khả năng xử lý dữ liệu dạng bảng tốt, hiệu quả dự đoán cao và phù hợp với bài toán phân loại. Quá trình huấn luyện được thực hiện trên tập dữ liệu đã xử lý, sau đó đánh giá bằng các chỉ số độ chính xác (Accuracy), độ chính xác dự đoán dương (Precision), độ bao phủ dự đoán (Recall) và điểm điều hòa giữa Precision và Recall (F1-score) nhằm đo lường hiệu quả dự đoán của mô hình.

- Bước 5: Triển khai ứng dụng (Deployment & Application): Mô hình được tích hợp vào ứng dụng Streamlit nhằm cung cấp các chức năng trực quan hóa dữ liệu, phân tích xu hướng và dự đoán Trending cho người dùng.



Hình 3.1 Kiến trúc hệ thống phân tích và dự đoán xu hướng video YouTube

3.2. Thu thập dữ liệu

3.2.1. Nguồn dữ liệu

Nguồn dữ liệu chính được sử dụng trong đề tài là YouTube Data API v3. Đây là API chính thức do Google cung cấp, cho phép truy xuất các thông tin liên quan đến video, kênh và hoạt động tương tác của người dùng trên nền tảng YouTube. Việc sử dụng API giúp đảm bảo dữ liệu được thu thập tự động, có cấu trúc và độ tin cậy cao.

Thông qua YouTube Data API v3, đề tài tiến hành thu thập dữ liệu từ nhiều nhóm nội dung khác nhau nhằm đảm bảo tính đa dạng của tập dữ liệu. Các nhóm nội dung được lựa chọn bao gồm Entertainment, Gaming, Technology, Food và Vlog. Việc thu thập dữ liệu từ nhiều lĩnh vực giúp hạn chế hiện tượng dữ liệu tập trung vào một chủ đề cụ thể, từ đó nâng cao khả năng tổng quát hóa của mô hình dự đoán.

Quá trình thu thập dữ liệu được thực hiện trong khoảng thời gian từ ngày 01/05/2026 đến ngày 20/05/2026. Dữ liệu thu thập được chia thành năm nhóm chính gồm dữ liệu video, dữ liệu thống kê video, dữ liệu kênh, dữ liệu bình luận và dữ liệu Trending.

Sau khi thu thập, dữ liệu được lưu trữ dưới dạng các tệp CSV và được sử dụng làm dữ liệu đầu vào cho quá trình ETL, xây dựng kho dữ liệu (Data Warehouse), phân tích dữ liệu và huấn luyện mô hình học máy.

Bảng 3.1 Các nhóm dữ liệu được thu thập từ YouTube Data API v3

Nhóm dữ liệu	Nội dung
Dữ liệu video	Thông tin mô tả video như mã video, tiêu đề, mô tả, thời gian đăng tải và danh mục nội dung
Dữ liệu thống kê video	Các chỉ số tương tác như lượt xem, lượt thích và lượt bình luận
Dữ liệu kênh	Thông tin về kênh sở hữu video như tên kênh, số lượng người đăng ký và tổng số video
Dữ liệu bình luận	Nội dung bình luận của người dùng trên video
Dữ liệu Trending	Danh sách video thịnh hành dùng để xác định trạng thái Trending

3.2.2. Phương pháp thu thập dữ liệu


Quá trình thu thập dữ liệu được thực hiện bằng ngôn ngữ Python thông qua thư viện Google API Client kết hợp với YouTube Data API v3.

Để xây dựng tập dữ liệu phục vụ cho bài toán dự đoán khả năng video trở thành Trending, đề tài tiến hành thu thập dữ liệu từ hai nguồn khác nhau trên nền tảng YouTube. Đối với nhóm video Trending, dữ liệu được lấy từ danh sách các video thịnh hành của YouTube thông qua API Most Popular. Các video thuộc nhóm này được gán nhãn Trending = 1 và được sử dụng làm lớp mục tiêu trong bài toán phân loại.

Đối với nhóm video Non-Trending, dữ liệu được thu thập thông qua Search API bằng các từ khóa thuộc nhiều lĩnh vực khác nhau như giải trí (Entertainment), công nghệ (Technology), trò chơi giải trí (Gaming), thức ăn (Food) và Vlog. Những video không xuất hiện trong danh sách Trending tại thời điểm thu thập được gán nhãn Trending = 0.

Sau khi xác định danh sách video từ hai nguồn dữ liệu trên, hệ thống tiếp tục thu thập các thông tin chi tiết của video như tiêu đề, mô tả, thời gian đăng tải, số lượt xem, số lượt thích, số lượt bình luận và danh mục nội dung. Đồng thời, thông tin của kênh sở hữu video như tên kênh, số lượng người đăng ký và tổng số video cũng được thu thập để phục vụ quá trình phân tích dữ liệu.

Bên cạnh đó, dữ liệu bình luận của người dùng được thu thập từ các video trong tập dữ liệu nhằm phục vụ cho bài toán phân tích cảm xúc. Toàn bộ dữ liệu sau khi thu thập được lưu trữ dưới dạng các tệp CSV và được sử dụng làm đầu vào cho quá trình ETL, xây dựng kho dữ liệu và huấn luyện mô hình học máy.



Hình 3.2 Quy trình thu thập dữ liệu từ YouTube Data API v3

3.2.3. Mô tả bộ dữ liệu thu thập

Quá trình thu thập dữ liệu được thực hiện trong khoảng thời gian từ ngày 01/05/2026 đến ngày 20/05/2026 thông qua YouTube Data API v3. Dữ liệu được thu thập từ nhiều nhóm nội dung khác nhau như Entertainment, Gaming, Technology, Food và Vlog nhằm đảm bảo tính đa dạng của tập dữ liệu. Sau quá trình thu thập, dữ liệu được lưu trữ thành bốn tập dữ liệu riêng biệt gồm Video Dataset, Channel Dataset, Video Statistics Dataset và Comment Dataset trước khi được kết hợp ở trong quy trình ETL.

Bảng 3.2 Mô tả tập dữ liệu Video

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	159,483
Số cột	11

Video Dataset bao gồm 159.483 bản ghi chứa thông tin cơ bản của các video được thu thập từ YouTube. Bộ dữ liệu này lưu trữ các thông tin định danh, nội dung mô tả và thông tin phân loại của video, làm cơ sở để liên kết với các tập dữ liệu khác trong quá trình xây dựng kho dữ liệu.

Bảng 3.3 Chi tiết các thuộc tính của Video Dataset

Tên biến	Kiểu dữ liệu	Ý nghĩa
video_id	VARCHAR	Mã video
title	TEXT	Tiêu đề video
description	TEXT	Mô tả video
channel_id	VARCHAR	Mã kênh
channel_title	VARCHAR	Tên kênh
publish_time	TIMESTAMP	Thời gian đăng tải
thumbnail	TEXT	Ảnh đại diện video
country_code	VARCHAR	Mã quốc gia
keyword	VARCHAR	Từ khóa thu thập
topic	VARCHAR	Chủ đề nội dung

Tên biến	Kiểu dữ liệu	Ý nghĩa
source	VARCHAR	Nguồn thu thập

Các thuộc tính trong Video Dataset chủ yếu mô tả đặc điểm nhận dạng và nội dung của video như tiêu đề, mô tả, thời gian đăng tải, chủ đề và từ khóa thu thập. Những thuộc tính này được sử dụng để xây dựng bảng chiều dim_video trong mô hình kho dữ liệu Data Warehouse.

Bảng 3.4 Mô tả tập dữ liệu Channel

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	83,173
Số cột	9

Channel Dataset gồm 83.173 bản ghi, cung cấp thông tin về các kênh sở hữu video trong tập dữ liệu. Dữ liệu này hỗ trợ phân tích mức độ ảnh hưởng của kênh đối với khả năng trở thành Trending của video.

Bảng 3.5 Chi tiết các thuộc tính của Channel Dataset

Tên biến	Kiểu dữ liệu	Ý nghĩa
channel_id	VARCHAR	Mã kênh
channel_title	VARCHAR	Tên kênh
custom_url	VARCHAR	Đường dẫn của kênh
channel_description	TEXT	Mô tả kênh
published_at	TIMESTAMP	Ngày tạo kênh

Tên biến	Kiểu dữ liệu	Ý nghĩa
country	VARCHAR	Quốc gia của kênh
subscriber_count	BIGINT	Số lượng người đăng ký
view_count	BIGINT	Tổng số lượt xem của kênh
video_count	INT	Tổng số video đã đăng tải

Các thuộc tính của Channel Dataset phản ánh quy mô và mức độ hoạt động của kênh thông qua số lượng người đăng ký, lượt xem và số video đã đăng tải. Đây là các đặc trưng quan trọng phục vụ cho quá trình phân tích và xây dựng mô hình dự đoán.

Bảng 3.6 Mô tả tập dữ liệu Video Statistics

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	1,171,067
Số cột	14

Video Statistics Dataset được ghi nhận theo từng thời điểm thu thập nhằm theo dõi sự thay đổi của các chỉ số tương tác như lượt xem, lượt thích và bình luận. Bộ dữ liệu này chiếm tỷ trọng lớn nhất trong hệ thống và là nguồn dữ liệu chính phục vụ phân tích xu hướng video.

Bảng 3.7 Chi tiết các thuộc tính của Video Statistics Dataset

Tên biến	Kiểu dữ liệu	Ý nghĩa
video_id	VARCHAR	Mã video
is_trending	INT	Nhãn Trending (1: Trending, 0: Non-Trending)

Tên biến	Kiểu dữ liệu	Ý nghĩa
views	BIGINT	Số lượt xem
likes	BIGINT	Số lượt thích
comments	BIGINT	Số lượt bình luận
duration_seconds	INT	Thời lượng video (giây)
definition	VARCHAR	Chất lượng video (HD/SD)
caption	VARCHAR	Trạng thái phụ đề
licensed_content	BOOLEAN	Nội dung có bản quyền
category_id	INT	Mã danh mục video
default_language	VARCHAR	Ngôn ngữ mặc định
default_audio_language	VARCHAR	Ngôn ngữ âm thanh mặc định
tags	TEXT	Các thẻ (tags) của video
snapshot_time	TIMESTAMP	Thời điểm ghi nhận thống kê

Bảng 3.8 Mô tả tập dữ liệu Comment

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	7,351,883
Số cột	7

Comment Dataset lưu trữ hơn 7 triệu bình luận của người dùng trên YouTube. Dữ liệu này được sử dụng cho quá trình phân tích cảm xúc nhằm đánh giá phản hồi của người xem đối với từng video.

Bảng 3.9 Chi tiết các thuộc tính của Comment Dataset


Tên biến	Kiểu dữ liệu	Ý nghĩa
comment_id	VARCHAR	Mã định danh bình luận
video_id	VARCHAR	Mã video chứa bình luận
author_name	VARCHAR	Tên người bình luận
comment_text	TEXT	Nội dung bình luận
like_count	INT	Số lượt thích của bình luận
published_at	TIMESTAMP	Thời gian đăng bình luận
updated_at	TIMESTAMP	Thời gian cập nhật bình luận

3.3 Xây dựng hệ thống Data Warehouse và quy trình ETL

Dữ liệu thu thập từ YouTube bao gồm nhiều nhóm thông tin khác nhau như video, kênh và bình luận. Để phục vụ cho các bước phân tích dữ liệu và xây dựng mô hình dự đoán, đề tài xây dựng hệ thống Data Warehouse theo mô hình Star Schema kết hợp với quy trình ETL. Việc tổ chức dữ liệu theo mô hình này giúp giảm sự phân tán dữ liệu, hỗ trợ truy vấn nhanh hơn và tạo nguồn dữ liệu ổn định cho các giai đoạn xử lý tiếp theo.

3.3.1 Thiết kế Star Schema

Để phục vụ cho nhu cầu lưu trữ và phân tích dữ liệu YouTube, đề tài xây dựng Data Warehouse theo mô hình Star Schema. Đây là mô hình được sử dụng phổ biến trong các hệ thống kho dữ liệu nhờ cấu trúc đơn giản, dễ mở rộng và tối ưu cho các truy vấn phân tích. Trong mô hình này, dữ liệu được tổ chức thành một bảng sự kiện (Fact Table) nằm ở trung tâm và các bảng chiều (Dimension Tables) bao quanh, giúp giảm độ phức tạp khi truy vấn và hỗ trợ tổng hợp dữ liệu hiệu quả.



Hình 3.3 Sơ đồ Schema được xây dựng cho hệ thống

Bảng **fact_video_metrics** trong hệ thống đóng vai trò là bảng sự kiện trung tâm. Bảng này lưu trữ các chỉ số phản ánh hiệu suất hoạt động của video tại thời điểm thu thập dữ liệu như số lượt xem, số lượt thích, số lượt bình luận và trạng thái Trending của video. Ngoài ra, bảng còn lưu thông tin về thời điểm ghi nhận dữ liệu và nguồn dữ liệu phục vụ cho quá trình phân tích sau này. Các khóa ngoại trong bảng được sử dụng để liên kết với các bảng chiều tương ứng.

Bảng **dim_video** lưu trữ các thông tin mô tả liên quan đến video. Dữ liệu bao gồm tiêu đề video, mô tả, thời gian đăng tải, thời lượng, danh mục nội dung, ngôn ngữ mặc định và các thông tin đặc trưng khác của video. Đây là bảng chiều có số lượng thuộc tính lớn nhất trong hệ thống vì chứa phần lớn thông tin mô tả phục vụ cho quá trình phân tích nội dung video.

Bảng **dim_channel** lưu trữ thông tin về kênh sở hữu video như tên kênh, mô tả kênh, ngày tạo kênh, số lượng người đăng ký, tổng số lượt xem và số lượng video đã công bố. Các thông tin này được sử dụng để đánh giá mức độ ảnh hưởng của kênh đối với khả năng xuất hiện trong danh sách Trending.

Bảng `dim_time` được xây dựng nhằm hỗ trợ phân tích dữ liệu theo yếu tố thời gian. Thay vì lưu trực tiếp các thuộc tính thời gian trong bảng sự kiện, hệ thống tách riêng thành bảng chiều thời gian với các thuộc tính như năm, quý, tháng, tuần, ngày và giờ. Cách tổ chức này giúp thực hiện các truy vấn thống kê theo từng mốc thời gian thuận tiện hơn.


Bảng `dim_topic` lưu trữ thông tin về chủ đề nội dung của video. Việc tách riêng chủ đề thành một bảng chiều giúp hệ thống dễ dàng mở rộng số lượng chủ đề trong tương lai và hỗ trợ phân tích mức độ phổ biến của từng nhóm nội dung trên nền tảng YouTube.

Bảng `dim_comment` lưu trữ thông tin liên quan đến các bình luận của người dùng trên video YouTube. Dữ liệu bao gồm nội dung bình luận, thông tin tác giả, số lượng lượt thích và thời gian đăng bình luận. Bảng này được sử dụng làm nguồn dữ liệu cho quá trình phân tích cảm xúc nhằm đánh giá phản hồi của người xem đối với từng video, đồng thời hỗ trợ xây dựng các đặc trưng phục vụ cho mô hình dự đoán Trending.

Thông qua mô hình Star Schema, dữ liệu được tổ chức theo hướng tách biệt giữa dữ liệu mô tả và dữ liệu sự kiện, giúp giảm sự dư thừa dữ liệu và nâng cao hiệu quả truy vấn. Cấu trúc này cũng tạo điều kiện thuận lợi cho các bước phân tích khám phá dữ liệu, phân tích cảm xúc và xây dựng mô hình Machine Learning được trình bày trong các phần tiếp theo của đề tài.

3.3.2 Quy trình ETL

Sau khi dữ liệu được thu thập từ YouTube Data API v3, các dữ liệu thô được lưu trữ dưới dạng các tệp CSV bao gồm thông tin video, kênh, thống kê video và bình luận. Để dữ liệu có thể sử dụng trong hệ thống Data Warehouse, đề tài xây dựng quy trình ETL (Extract – Transform – Load) nhằm chuyển đổi dữ liệu từ dạng thu thập ban đầu sang cấu trúc Star Schema đã thiết kế.



Hình 3.4 Sơ đồ quy trình ETL

Ở giai đoạn Extract, dữ liệu được trích xuất từ các tệp dữ liệu nguồn gồm raw_video.csv, raw_channel.csv, raw_comment.csv và raw_video_stats.csv. Đây là các tệp dữ liệu được tạo ra sau quá trình thu thập dữ liệu từ YouTube Data API v3 và đóng vai trò là nguồn dữ liệu đầu vào cho toàn bộ hệ thống.

Tiếp theo, dữ liệu được đưa vào giai đoạn Transform. Tại bước này, các tiến trình chuyển đổi được xây dựng nhằm tạo ra các bảng chiều và bảng sự kiện phục vụ cho Data Warehouse. Dữ liệu video được xử lý để xây dựng bảng dim_video, dữ liệu kênh được chuyển đổi thành bảng dim_channel, dữ liệu thời gian được tách thành bảng dim_time, thông tin chủ đề nội dung được sử dụng để xây dựng bảng dim_topic và dữ liệu bình luận được chuyển đổi thành bảng dim_comment. Đồng thời, dữ liệu thống kê video được tổng hợp để tạo thành bảng fact_video_metrics.

Trong quá trình chuyển đổi, hệ thống thực hiện một số thao tác xử lý dữ liệu như loại bỏ các bản ghi trùng lặp, chuẩn hóa kiểu dữ liệu, chuyển đổi định dạng thời gian và kiểm tra tính hợp lệ của dữ liệu trước khi tạo các bảng trong kho dữ liệu. Các bước này giúp đảm bảo tính nhất quán giữa các bảng và hạn chế sai lệch trong quá trình phân tích.

Sau khi hoàn thành việc xây dựng các bảng chiều và bảng sự kiện, dữ liệu được nạp vào PostgreSQL ở giai đoạn Load. Các bảng được lưu trữ theo cấu trúc Star Schema

và được sử dụng làm nguồn dữ liệu chính cho các hoạt động phân tích, trực quan hóa và xây dựng mô hình dự đoán.

Việc tổ chức dữ liệu thông qua quy trình ETL giúp tách biệt dữ liệu thu thập ban đầu với dữ liệu phục vụ phân tích, đồng thời tạo ra một cấu trúc dữ liệu thống nhất cho toàn bộ hệ thống.

3.3.3 Lưu trữ dữ liệu trên PostgreSQL

Sau khi hoàn thành quá trình xây dựng các bảng chiều và bảng sự kiện thông qua quy trình ETL, dữ liệu được nạp vào hệ quản trị cơ sở dữ liệu PostgreSQL để hình thành kho dữ liệu phục vụ cho đề tài.

PostgreSQL được lựa chọn do là hệ quản trị cơ sở dữ liệu mã nguồn mở, có khả năng lưu trữ dữ liệu lớn, hỗ trợ tốt các truy vấn phân tích và dễ dàng tích hợp với các công cụ xử lý dữ liệu trong Python. Bên cạnh đó, PostgreSQL cũng hỗ trợ đầy đủ các cơ chế khóa chính, khóa ngoại và chỉ mục, giúp đảm bảo tính toàn vẹn dữ liệu trong quá trình vận hành hệ thống.

Dữ liệu sau khi xử lý được nạp vào các bảng tương ứng trong Data Warehouse bao gồm các bảng chiều `dim_video`, `dim_channel`, `dim_time`, `dim_topic`, `dim_comment` và bảng sự kiện `fact_video_metrics`. Dữ liệu bình luận được lưu trữ trong bảng `dim_comment` nhằm phục vụ cho các bài toán phân tích cảm xúc và khai thác phản hồi của người dùng.

Việc tổ chức dữ liệu theo mô hình Star Schema giúp đơn giản hóa các truy vấn phân tích và giảm mức độ dư thừa dữ liệu. Thông qua các mối quan hệ giữa bảng sự kiện và các bảng chiều, hệ thống có thể dễ dàng thực hiện các truy vấn thống kê theo thời gian, chủ đề nội dung, kênh YouTube hoặc các chỉ số tương tác của video.

Sau khi được lưu trữ trong PostgreSQL, dữ liệu trở thành nguồn dữ liệu tập trung cho toàn bộ hệ thống. Các bước phân tích khám phá dữ liệu, phân tích cảm xúc bình luận và xây dựng mô hình Machine Learning đều sử dụng dữ liệu được truy xuất trực tiếp từ Data Warehouse.

3.4 Tiền xử lý và xây dựng đặc trưng

3.4.1 Làm sạch và chuẩn hóa dữ liệu

Dữ liệu thu thập từ YouTube Data API v3 được lưu trữ dưới nhiều nguồn khác nhau bao gồm dữ liệu video, dữ liệu kênh, dữ liệu thống kê video và dữ liệu bình luận. Trước khi được sử dụng cho quá trình phân tích và xây dựng mô hình Machine Learning,

dữ liệu cần trải qua bước làm sạch và chuẩn hóa nhằm đảm bảo tính nhất quán, độ tin cậy và khả năng khai thác hiệu quả trong các giai đoạn tiếp theo.

Trước hết, dữ liệu được kiểm tra nhằm phát hiện các bản ghi trùng lặp và các giá trị không hợp lệ có thể phát sinh trong quá trình thu thập. Đồng thời, các thuộc tính dạng văn bản như mô tả video, thẻ từ khóa, thông tin kênh hoặc quốc gia được xử lý giá trị thiếu bằng cách thay thế bằng giá trị mặc định "Unknown", giúp duy trì tính đầy đủ của tập dữ liệu và hạn chế ảnh hưởng đến quá trình phân tích.

Tiếp theo, các thuộc tính định lượng như số lượt xem (view_count), số lượt thích (like_count), số lượt bình luận (comment_count), số lượng người đăng ký kênh (subscriber_count) và số lượng video của kênh (video_count) được chuyển đổi sang kiểu dữ liệu số phù hợp nhằm đảm bảo khả năng tính toán và thống kê. Các thuộc tính thời gian như publish_time, snapshot_time và date được chuẩn hóa về định dạng datetime để hỗ trợ phân tích dữ liệu theo các chiều thời gian khác nhau.

Đối với thuộc tính thời lượng video (duration), dữ liệu được YouTube cung cấp dưới định dạng ISO 8601. Trong quá trình tiền xử lý, thuộc tính này được chuyển đổi sang đơn vị giây (duration_seconds) nhằm tạo điều kiện thuận lợi cho việc phân tích và xây dựng mô hình học máy. Bên cạnh đó, các thông tin quốc gia và ngôn ngữ cũng được chuẩn hóa thành các nhóm khu vực địa lý (country_region) nhằm hỗ trợ phân tích dữ liệu theo từng khu vực và giảm độ phức tạp của dữ liệu phân loại.

Để đảm bảo chất lượng dữ liệu, các bản ghi bất thường như video có số lượt xem bằng 0 hoặc số lượt thích lớn hơn số lượt xem được loại bỏ khỏi tập dữ liệu. Đồng thời, trạng thái Trending của video được xác định dựa trên nguồn dữ liệu thu thập, trong đó các video thuộc danh sách Trending của YouTube được gán nhãn 1 và các video thu thập từ Search API được gán nhãn 0. Nhãn này được sử dụng làm biến mục tiêu cho bài toán dự đoán khả năng trở thành Trending của video.

Sau khi hoàn tất quá trình làm sạch và chuẩn hóa, dữ liệu từ Video Dataset, Channel Dataset và Video Statistics Dataset được liên kết thông qua các khóa định danh như video_id và channel_id để tạo thành tập dữ liệu thống nhất phục vụ cho quá trình phân tích dữ liệu, xây dựng đặc trưng và huấn luyện mô hình dự đoán.

Bảng 3.10 Các bước tiền xử lý dữ liệu

Bước xử lý	Mô tả
Xử lý giá trị thiếu	Thay thế các giá trị thiếu trong các thuộc tính dạng văn bản như description, tags, channel_title, channel_description, country bằng giá trị "Unknown".
Loại bỏ dữ liệu trùng lặp	Kiểm tra và loại bỏ các bản ghi trùng lặp dựa trên các khóa định danh như video_id, channel_id và comment_id.
Chuẩn hóa kiểu dữ liệu	Chuyển đổi các thuộc tính số như view_count, like_count, comment_count, subscriber_count và video_count sang kiểu dữ liệu số phù hợp.
Chuẩn hóa dữ liệu thời gian	Chuyển đổi các thuộc tính publish_time, snapshot_time và date về định dạng datetime.
Chuẩn hóa thời lượng video	Chuyển đổi trường duration từ định dạng ISO 8601 sang duration_seconds để phục vụ phân tích và xây dựng mô hình.
Chuẩn hóa thông tin địa lý	Ánh xạ mã quốc gia (country_code) thành các khu vực địa lý (country_region) nhằm hỗ trợ phân tích theo khu vực.
Kiểm tra dữ liệu bất thường	Loại bỏ các bản ghi không hợp lệ như video có lượt xem bằng 0 hoặc số lượt thích lớn hơn số lượt xem.

Các bước tiền xử lý được thực hiện nhằm đảm bảo tính nhất quán giữa các nguồn dữ liệu và nâng cao chất lượng dữ liệu đầu vào. Sau quá trình này, dữ liệu được chuẩn hóa về cấu trúc, kiểu dữ liệu và định dạng thời gian, đồng thời loại bỏ các bản ghi không hợp lệ trước khi tiến hành phân tích.

Bảng 3.11 Thống kê mô tả các thuộc tính của bộ dữ liệu video sau tích hợp

Chỉ số	Views	Likes	Comments	Duration (s)	Subscriber Count
Count	1,171,067	1,171,067	1,171,067	1,171,067	1,171,067
Mean	8,456,134	91,403	2,534	1,565.43	2,094,982
Std	94,405,940	624,425	69,065	5,729.79	10,192,749
Min	1	0	0	0	0
25%	6,583	70	2	34	4,580
50%	83,182	1,594	59	161	97,800
75%	1,223,812	18,915	467	1,084	909,000
Max	9,025,777,000	56,253,090	15,924,940	416,704	490,000,000

Kết quả thống kê mô tả cho thấy các chỉ số tương tác của video có độ phân tán lớn, đặc biệt là lượt xem và lượt thích. Điều này phản ánh sự khác biệt đáng kể về mức độ phổ biến giữa các video trong tập dữ liệu, đồng thời cho thấy sự đa dạng của dữ liệu được sử dụng trong nghiên cứu.

Bảng 3.12 Dữ liệu Video sau bước tiền xử lý

Thành phần	Giá trị
Dataset nguồn	Video, Channel, Video Statistics
Khóa liên kết	video_id, channel_id
Tổng số bản ghi	1.171.067
Số thuộc tính sau xử lý	45
Video unique	158,068

Thành phần	Giá trị
Channel unique	83.173

3.4.2 Phân tích cảm xúc bình luận

3.4.2.1 Tiền xử lý văn bản

Trước khi thực hiện phân tích cảm xúc, dữ liệu bình luận được tiền xử lý nhằm loại bỏ các thành phần không cần thiết và chuẩn hóa nội dung văn bản. Bước này giúp giảm nhiễu trong dữ liệu đầu vào và cải thiện chất lượng dự đoán của mô hình.

Các bình luận được chuẩn hóa Unicode về định dạng NFC để đảm bảo tính nhất quán trong quá trình xử lý văn bản. Bên cạnh đó, các ký tự HTML, đường dẫn URL và ký hiệu đề cập người dùng được loại bỏ khỏi nội dung bình luận. Những ký tự điều khiển không hiển thị cũng được loại bỏ nhằm hạn chế các trường hợp gây ảnh hưởng đến quá trình phân tích.

Sau khi làm sạch dữ liệu, các khoảng trắng dư thừa được chuẩn hóa về một khoảng trắng duy nhất. Những bình luận quá ngắn hoặc không còn đủ nội dung sau khi xử lý sẽ bị loại bỏ khỏi tập dữ liệu. Kết quả của bước này là tập dữ liệu văn bản đã được chuẩn hóa và sẵn sàng cho quá trình phân tích cảm xúc.

Bảng 3.13 Các bước xử lý và mục đích của tiền xử lý văn bản

Bước xử lý	Mục đích
Chuẩn hóa Unicode NFC	Đồng nhất cách biểu diễn ký tự
Loại bỏ HTML entities	Loại bỏ ký tự sinh ra từ HTML
Loại bỏ URL	Giảm nhiễu dữ liệu
Loại bỏ Mention	Loại bỏ thông tin không mang ý nghĩa cảm xúc
Chuẩn hóa khoảng trắng	Chuẩn hóa văn bản
Loại bỏ bình luận quá ngắn	Giảm dữ liệu ít giá trị

3.4.2.2 Phân loại cảm xúc bằng XLM-RoBERTa

Sau khi hoàn thành bước tiền xử lý, dữ liệu bình luận được đưa vào mô hình XLM-RoBERTa để thực hiện phân loại cảm xúc. Mô hình được lựa chọn do bộ dữ liệu bình luận YouTube trong nghiên cứu bao gồm nhiều ngôn ngữ khác nhau đến từ nhiều quốc gia và khu vực. So với các mô hình chỉ hỗ trợ một ngôn ngữ hoặc các phương pháp dựa trên từ điển, XLM-RoBERTa có khả năng xử lý dữ liệu đa ngôn ngữ tốt hơn và duy trì độ chính xác cao trong các tác vụ phân loại cảm xúc.

Quá trình phân loại được thực hiện trên Google Colab nhằm tận dụng tài nguyên GPU để xử lý khối lượng lớn dữ liệu bình luận. Đối với mỗi bình luận, mô hình dự đoán một trong ba nhãn cảm xúc gồm tích cực (Positive), trung lập (Neutral) hoặc tiêu cực (Negative), đồng thời trả về xác suất dự đoán tương ứng.

Kết quả phân loại cảm xúc được sử dụng để xây dựng các chỉ số tổng hợp ở cấp độ video như tỷ lệ bình luận tích cực, tỷ lệ bình luận trung lập và tỷ lệ bình luận tiêu cực. Các chỉ số này sau đó được tích hợp vào Video Dataset và được sử dụng như các đặc trưng đầu vào trong quá trình phân tích dữ liệu và xây dựng mô hình dự đoán video Trending.

3.4.2.3 Kết quả phân tích cảm xúc

Sau khi hoàn thành quá trình suy luận, tập dữ liệu bình luận được bổ sung thêm hai thuộc tính mới gồm sentiment_label và sentiment_score. Trong đó, sentiment_label thể hiện nhãn cảm xúc do mô hình dự đoán, còn sentiment_score biểu diễn độ tin cậy tương ứng của kết quả dự đoán.

Bảng 3.14 Các thuộc tính của Comment Dataset sau phân tích cảm xúc

Thuộc tính	Kiểu dữ liệu	Mô tả
comment_id	VARCHAR	Mã định danh bình luận
video_id	VARCHAR	Mã định danh video
comment_text	TEXT	Nội dung bình luận
like_count	BIGINT	Số lượt thích của bình luận

Thuộc tính	Kiểu dữ liệu	Mô tả
published_at	TIMESTAMP	Thời gian đăng bình luận
sentiment_label	VARCHAR	Nhãn cảm xúc dự đoán
sentiment_score	FLOAT	Độ tin cậy của dự đoán

Dựa trên kết quả phân loại, tỷ lệ bình luận tích cực, trung lập và tiêu cực được tính toán cho từng video thông qua khóa video_id. Các chỉ số này được tích hợp vào Video Dataset để phản ánh phản hồi của người xem đối với từng nội dung video.

Bảng 3.15 Các đặc trưng cảm xúc được tổng hợp ở cấp độ video

Đặc trưng	Kiểu dữ liệu	Mô tả
positive_ratio	FLOAT	Tỷ lệ bình luận tích cực trên tổng số bình luận của video
neutral_ratio	FLOAT	Tỷ lệ bình luận trung lập trên tổng số bình luận của video
negative_ratio	FLOAT	Tỷ lệ bình luận tiêu cực trên tổng số bình luận của video

3.4.3 Xây dựng đặc trưng

Sau khi hoàn thành quá trình làm sạch dữ liệu và phân tích cảm xúc bình luận, các đặc trưng mới được xây dựng nhằm khai thác thêm thông tin từ dữ liệu gốc và phản ánh đầy đủ hơn các yếu tố có khả năng ảnh hưởng đến trạng thái Trending của video. Quá trình xây dựng đặc trưng được thực hiện dựa trên các nhóm thông tin chính bao gồm nội dung video, mức độ tương tác của người dùng, đặc điểm của kênh đăng tải và phản hồi của cộng đồng thông qua bình luận.

Đối với nhóm đặc trưng nội dung, thuộc tính duration_seconds được sử dụng để biểu diễn thời lượng video dưới dạng số nguyên. Bên cạnh đó, thông tin chủ đề nội dung (topic) được giữ lại nhằm phản ánh lĩnh vực mà video thuộc về, chẳng hạn như giải trí,

âm nhạc, thể thao hoặc tin tức. Các đặc trưng này giúp mô hình nhận diện sự khác biệt về đặc điểm nội dung giữa các video.

Đối với nhóm đặc trưng địa lý, thuộc tính `country_region` được xây dựng từ thông tin quốc gia và ngôn ngữ của video. Việc nhóm dữ liệu theo khu vực địa lý giúp phản ánh sự khác biệt về xu hướng nội dung giữa các quốc gia và khu vực khác nhau trên nền tảng YouTube.

Đối với nhóm đặc trưng tương tác, ngoài các chỉ số gốc như số lượt xem (`view_count`), số lượt thích (`like_count`) và số lượt bình luận (`comment_count`), đề tài xây dựng thêm các đặc trưng tỷ lệ tương tác bao gồm `like_rate` và `comment_rate`. Các đặc trưng này được tính dựa trên tỷ lệ giữa số lượt tương tác và số lượt xem của video, qua đó phản ánh mức độ quan tâm của người dùng đối với nội dung một cách khách quan hơn so với việc sử dụng các giá trị tuyệt đối.

Đối với nhóm đặc trưng kênh, các thuộc tính `subscriber_count` và `video_count` được sử dụng để mô tả quy mô và mức độ hoạt động của kênh đăng tải. Những đặc trưng này giúp mô hình xem xét ảnh hưởng của độ phổ biến và kinh nghiệm hoạt động của kênh đối với khả năng trở thành Trending của video.

Bên cạnh đó, kết quả phân tích cảm xúc bình luận được tổng hợp ở cấp độ video để xây dựng nhóm đặc trưng cảm xúc. Cụ thể, tỷ lệ bình luận tích cực (`positive_ratio`), tỷ lệ bình luận trung lập (`neutral_ratio`) và tỷ lệ bình luận tiêu cực (`negative_ratio`) được tính toán dựa trên tổng số bình luận của mỗi video. Các đặc trưng này phản ánh phản ứng của cộng đồng người xem đối với nội dung video và được sử dụng như nguồn thông tin bổ sung cho quá trình dự đoán.

Các đặc trưng được xây dựng trong giai đoạn này là cơ sở cho quá trình phân tích khám phá dữ liệu và lựa chọn đặc trưng ở các bước tiếp theo trước khi tiến hành huấn luyện mô hình Machine Learning.

Bảng 3.16 Các đặc trưng được xây dựng từ dữ liệu gốc

Đặc trưng	Kiểu dữ liệu	Ý nghĩa
<code>duration_seconds</code>	INTEGER	Thời lượng video

Đặc trưng	Kiểu dữ liệu	Ý nghĩa
topic	VARCHAR	Chủ đề nội dung
country_region	VARCHAR	Khu vực địa lý
view_count	BIGINT	Tổng số lượt xem
like_rate	FLOAT	Tỷ lệ lượt thích trên lượt xem
comment_rate	FLOAT	Tỷ lệ bình luận trên lượt xem
subscriber_count	BIGINT	Số người đăng ký kênh
video_count	BIGINT	Tổng số video của kênh
positive_ratio	FLOAT	Tỷ lệ bình luận tích cực
neutral_ratio	FLOAT	Tỷ lệ bình luận trung lập
negative_ratio	FLOAT	Tỷ lệ bình luận tiêu cực

3.5. Phân tích khám phá dữ liệu


3.5.1 Phân tích tổng quan dữ liệu

3.5.1.1 Phân bố trạng thái Trending

Biến mục tiêu `is_trending` được sử dụng để xác định một video có thuộc danh sách Trending hay không. Việc khảo sát phân bố của biến này giúp đánh giá mức độ cân bằng giữa các lớp trong tập dữ liệu trước khi tiến hành xây dựng mô hình phân loại.

Kết quả cho thấy số lượng video không thuộc danh sách Trending chiếm tỷ lệ lớn hơn so với nhóm video Trending. Cụ thể, nhóm Non-Trending chiếm khoảng 76.7% tổng số video, trong khi nhóm Trending chiếm khoảng 23.3%. Mặc dù tồn tại sự chênh lệch giữa hai lớp, tỷ lệ này chưa tạo ra tình trạng mất cân bằng nghiêm trọng và vẫn đảm bảo đủ dữ liệu cho mô hình học được đặc điểm của cả hai nhóm.

Phân bố này phản ánh đúng thực tế khi chỉ một phần nhỏ video trên nền tảng YouTube có khả năng xuất hiện trong danh sách Trending, trong khi phần lớn video còn lại không đạt được mức độ phổ biến tương ứng.




Hình 3.5 Phân bố trạng thái Trending

3.5.1.2 Phân bố chủ đề video

Chủ đề nội dung là một trong những yếu tố quan trọng ảnh hưởng đến khả năng tiếp cận và mức độ tương tác của video trên nền tảng YouTube. Việc phân tích phân bố chủ đề giúp đánh giá mức độ đa dạng của tập dữ liệu cũng như xác định các nhóm nội dung chiếm ưu thế trong quá trình thu thập dữ liệu.

Kết quả thống kê cho thấy tập dữ liệu bao gồm nhiều nhóm nội dung khác nhau như Gaming, Music, Entertainment, Education, Vlog, Food, Fitness, Sports, Technology và Beauty. Trong đó, Gaming là chủ đề xuất hiện nhiều nhất, tiếp theo là Music và Entertainment. Đây đều là những nhóm nội dung có lượng người xem lớn và mức độ tương tác cao trên nền tảng YouTube.

Bên cạnh các nhóm giải trí, tập dữ liệu còn bao gồm các chủ đề thuộc lĩnh vực giáo dục, công nghệ, thể thao, sức khỏe và đời sống. Điều này cho thấy dữ liệu được thu thập từ nhiều lĩnh vực khác nhau thay vì chỉ tập trung vào một nhóm nội dung cụ thể. Sự đa dạng về chủ đề giúp mô hình có khả năng học được nhiều đặc điểm khác nhau của video, từ đó nâng cao khả năng tổng quát hóa khi dự đoán xu hướng Trending.



Hình 3.6 Top 10 thể loại có nhiều video nhất


3.5.1.3 Phân bố cảm xúc bình luận

Bên cạnh các chỉ số tương tác của video, phản hồi của người dùng trong phần bình luận cũng là một nguồn thông tin quan trọng phản ánh mức độ tiếp nhận nội dung trên nền tảng YouTube. Để khai thác yếu tố này, các bình luận được phân loại thành ba nhóm cảm xúc gồm tích cực (Positive), trung lập (Neutral) và tiêu cực (Negative).

Kết quả phân tích cho thấy nhóm bình luận mang cảm xúc tích cực chiếm tỷ lệ lớn nhất trong tập dữ liệu. Điều này cho thấy phần lớn người dùng có xu hướng phản hồi theo hướng tích cực đối với các video được thu thập. Nhóm bình luận trung lập đứng thứ hai, trong khi nhóm bình luận tiêu cực chiếm tỷ lệ thấp hơn đáng kể.

Sự phân bố này phản ánh đặc điểm phổ biến của các nền tảng chia sẻ nội dung, nơi người dùng thường thể hiện sự yêu thích, đồng tình hoặc ủng hộ đối với những nội dung mà họ lựa chọn tương tác. Đồng thời, sự tồn tại của cả ba nhóm cảm xúc cho thấy dữ liệu bình luận có tính đa dạng và chứa nhiều thông tin hữu ích về phản ứng của người xem.

Kết quả phân tích cảm xúc là cơ sở để xây dựng các đặc trưng liên quan đến tỷ lệ bình luận tích cực, trung lập và tiêu cực. Những đặc trưng này sẽ được sử dụng trong các bước phân tích tiếp theo nhằm đánh giá mức độ ảnh hưởng của phản hồi người dùng đến khả năng trở thành video Trending.



Hình 3.7 Phân bố cảm xúc bình luận


3.5.2 Phân tích đặc trưng tương tác

3.5.2.1 Phân tích View Count theo trạng thái Trending

Số lượt xem (View Count) là một trong những chỉ số quan trọng phản ánh mức độ tiếp cận và phổ biến của video trên nền tảng YouTube. Do dữ liệu View Count có sự chênh lệch rất lớn giữa các video, với nhiều giá trị ngoại lệ có số lượt xem cực cao, nghiên cứu sử dụng phép biến đổi logarit cơ số 10 theo công thức $\log_{10}(\text{View Count} + 1)$ trước khi trực quan hóa. Việc cộng thêm 1 giúp xử lý các trường hợp video có số lượt xem bằng 0 và tránh lỗi khi thực hiện phép biến đổi logarit.

Kết quả cho thấy nhóm video Trending có phân bố View Count cao hơn so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 89.6 triệu lượt xem, cao hơn đáng kể so với nhóm Non-Trending với khoảng 24.8 triệu lượt xem. Đồng thời, phần lớn các quan sát của nhóm Trending cũng tập trung ở mức lượt xem cao hơn. Điều này cho thấy các video xuất hiện trong danh sách Trending thường đạt được khả năng tiếp cận và thu hút người xem tốt hơn so với các video thông thường.

Mặc dù vẫn tồn tại sự chồng lấp giữa hai nhóm dữ liệu, sự khác biệt về phân bố cho thấy số lượt xem (View Count) có mối liên hệ nhất định với trạng thái Trending của video. Do đó, đặc trưng này được xem là một trong những yếu tố quan trọng và được giữ lại trong quá trình xây dựng mô hình dự đoán.




Hình 3.8 So sánh phân bố lượt xem giữa video Trending và Non-Trending

3.5.2.2 Phân bố Like Rate theo trạng thái Trending

Phân bố chỉ số tỷ lệ lượt thích (Like Rate) giữa nhóm video Trending và Non-Trending. Khác với các biến đếm như lượt xem (View Count) hay đăng ký (Subscriber Count) có phạm vi giá trị rất lớn và phân bố lệch phải mạnh, tỷ lệ lượt thích (Like Rate) là biến tỷ lệ được giới hạn trong khoảng từ 0 đến 1 nên không cần áp dụng phép biến đổi logarit. Việc giữ nguyên giá trị gốc giúp kết quả trực quan và dễ diễn giải hơn dưới dạng phần trăm tương tác của người dùng.

Để cải thiện khả năng quan sát sự khác biệt giữa hai nhóm dữ liệu, các giá trị nằm trên phân vị thứ 99 (99th percentile) được loại bỏ khỏi biểu đồ. Những giá trị này chiếm tỷ lệ rất nhỏ nhưng có độ lớn bất thường, làm thu hẹp phần lớn dữ liệu còn lại và gây khó khăn cho việc quan sát phân bố trung tâm. Việc loại bỏ chỉ được thực hiện trong quá trình trực quan hóa nhằm giảm ảnh hưởng của các ngoại lệ (outliers), không làm thay đổi tập dữ liệu gốc và không ảnh hưởng đến quá trình huấn luyện hay đánh giá mô hình.

Kết quả cho thấy nhóm video Trending có phân bố tỷ lệ lượt thích (Like Rate) cao hơn rõ rệt so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 2.62%, trong khi nhóm Non-Trending chỉ đạt khoảng 1.65%. Đồng thời, khoảng tứ phân vị của nhóm Trending cũng rộng hơn, cho thấy các video Trending thường nhận được mức độ yêu thích và tương tác tích cực từ người xem cao hơn. Điều này cho thấy tỷ lệ lượt thích (Like Rate) là một chỉ số phản ánh mức độ hấp dẫn của nội dung và có khả năng đóng góp vào việc nhận diện các video có xu hướng xuất hiện trong danh sách Trending.



Hình 3.9 So sánh phân bố tỷ lệ lượt thích giữa video Trending và Non-Trending


3.5.2.3 Phân bố Comment Rate theo trạng thái Trending

Comment Rate được tính bằng tỷ lệ số lượng bình luận trên tổng lượt xem của video, phản ánh mức độ tham gia thảo luận của người xem đối với nội dung được đăng tải. Do đây là biến tỷ lệ có giá trị tương đối nhỏ và dễ diễn giải dưới dạng phần trăm nên không áp dụng phép biến đổi logarit trong quá trình trực quan hóa dữ liệu đồng thời loại bỏ các giá trị nằm trên phân vị thứ 99 của Comment Rate.

Kết quả cho thấy nhóm video Trending có Comment Rate cao hơn đáng kể so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 0.1402%, trong khi nhóm Non-Trending chỉ đạt khoảng 0.0262%. Điều này cho thấy tỷ lệ bình luận trên lượt xem của các video Trending cao hơn hơn năm lần so với các video không thuộc danh sách Trending.

Ngoài ra, khoảng tứ phân vị của nhóm Trending cũng lớn hơn, phản ánh mức độ tương tác thảo luận sôi nổi hơn từ cộng đồng người xem. Khác với lượt thích chỉ thể hiện phản hồi tích cực đơn giản, hành vi bình luận thường đòi hỏi người dùng dành nhiều thời gian và sự quan tâm hơn đối với nội dung video. Do đó, Comment Rate không chỉ phản ánh mức độ tương tác mà còn cho thấy khả năng thu hút sự chú ý và kích thích trao đổi của video trên nền tảng YouTube.

Kết quả này cho thấy các video có khả năng tạo ra nhiều cuộc thảo luận từ người xem thường có xu hướng xuất hiện trong danh sách Trending nhiều hơn, qua đó khẳng định vai trò của Comment Rate như một đặc trưng quan trọng trong bài toán dự đoán video Trending.



Hình 3.10 So sánh phân bố tỷ lệ bình luận giữa video Trending và Non-Trending


3.5.2.4 Phân bố Duration theo trạng thái Trending

Thuộc tính Duration được làm sạch bằng cách loại bỏ các bản ghi có thời lượng bằng 0 giây và các video có thời lượng vượt quá 30 ngày nhằm hạn chế ảnh hưởng của các giá trị bất thường trong dữ liệu. Sau đó, phép biến đổi logarit cơ số 10 được áp dụng để giảm độ lệch của phân bố và hỗ trợ việc so sánh giữa hai nhóm video.

Kết quả cho thấy thời lượng video có sự khác biệt rõ rệt giữa nhóm Trending và Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 1.044 giây (17 phút), trong khi nhóm Non-Trending chỉ đạt khoảng 60 giây (1 phút). Đồng thời, khoảng tứ phân vị của nhóm Trending cũng cao hơn đáng kể, cho thấy phần lớn các video Trending đều có thời lượng dài hơn so với các video không thuộc danh sách Trending.

Sự khác biệt này cho thấy các video Trending thường chứa lượng nội dung lớn hơn và có khả năng duy trì sự quan tâm của người xem trong thời gian dài hơn. Nhiều nội dung phổ biến trên YouTube như podcast, chương trình giải trí, video giáo dục, phỏng vấn hoặc livestream thường có thời lượng tương đối dài và có xu hướng xuất hiện trong danh sách Trending nhiều hơn so với các video ngắn.

Qua kết quả phân tích cho thấy đây là một đặc trưng có khả năng phân biệt tốt giữa hai nhóm dữ liệu. Do đó, Duration được xem là một thuộc tính quan trọng và có tiềm năng đóng góp tích cực vào hiệu quả của mô hình dự đoán video Trending.



Hình 3.11 So sánh phân bố thời lượng giữa video Trending và Non-Trending

3.5.2.5 Phân bố Subscriber Count theo trạng thái Trending


Thuộc tính số lượng người đăng ký (Subscriber Count) có phạm vi giá trị rất lớn, dao động từ vài người đăng ký đến hàng trăm triệu người đăng ký. Do đó, phép biến đổi logarit cơ số 10 được áp dụng nhằm giảm độ lệch của dữ liệu và hỗ trợ việc so sánh phân bố giữa hai nhóm video. Trước khi thực hiện biến đổi logarit, các bản ghi có số lượng người đăng ký bằng 0 được loại bỏ. Nhóm dữ liệu này chỉ chiếm khoảng 0.2% tổng số quan sát nên không ảnh hưởng đáng kể đến phân bố chung của tập dữ liệu.

Kết quả cho thấy các video thuộc nhóm Trending thường đến từ những kênh có quy mô người đăng ký lớn hơn. Giá trị trung vị của nhóm Trending đạt khoảng 224.000 người đăng ký, trong khi nhóm Non-Trending chỉ đạt khoảng 63.400 người đăng ký. Sự khác biệt này cho thấy các kênh sở hữu lượng người theo dõi lớn thường có lợi thế trong việc tiếp cận người xem và tạo ra mức độ lan truyền cao hơn cho nội dung được đăng tải.

Tuy nhiên, sự phân bố giữa hai số lượng người đăng ký (Subscriber Count) không phải là yếu tố duy nhất quyết định khả năng xuất hiện trong danh sách Trending. Trên

thực tế vẫn tồn tại nhiều video Trending đến từ các kênh có quy mô nhỏ, phản ánh vai trò quan trọng của các yếu tố khác như chất lượng nội dung, mức độ tương tác của người xem và khả năng lan truyền của video.

Nhìn chung, số lượng người đăng ký (Subscriber Count) thể hiện sự khác biệt tương đối rõ giữa hai nhóm dữ liệu và có thể được xem là một đặc trưng có thể cân nhắc trong bài toán dự đoán video Trending trên nền tảng YouTube.




Hình 3.12 So sánh phân bố lượng người đăng ký giữa video Trending và Non-Trending

3.5.2.6 Phân bố Sentiment theo trạng thái Trending

Để đánh giá mối quan hệ giữa cảm xúc bình luận và khả năng trở thành Trending của video, nghiên cứu tiến hành tổng hợp tỷ lệ bình luận tích cực (Positive), trung tính (Neutral) và tiêu cực (Negative) cho từng video dựa trên kết quả phân loại cảm xúc từ mô hình XLM-RoBERTa. Quá trình phân tích được thực hiện trên 124.293 video có dữ liệu bình luận, sau khi loại bỏ các video không có dữ liệu sentiment.

Bảng 3.17 Tỷ lệ cảm xúc trung bình theo trạng thái Trending

Trạng thái	Positive Ratio	Neutral Ratio	Negative Ratio	Avg Sentiment Score
Non-Trending	0.529	0.270	0.200	0.678
Trending	0.476	0.323	0.201	0.661



Hình 3.13 Phân bố cảm xúc bình luận theo trạng thái Trending


Kết quả cho thấy nhóm video không Trending có tỷ lệ bình luận tích cực trung bình đạt khoảng 52.9%, cao hơn so với nhóm Trending với 47.6%. Ngược lại, tỷ lệ bình luận trung tính của nhóm Trending đạt 32.3%, cao hơn mức 27.0% của nhóm không Trending. Tỷ lệ bình luận tiêu cực giữa hai nhóm gần như tương đương, dao động quanh mức 20%.

Bên cạnh đó, chỉ số cảm xúc trung bình (Average Sentiment Score) của nhóm không Trending đạt 0.678, trong khi nhóm Trending đạt 0.661. Mức chênh lệch chỉ khoảng 0.017 điểm cho thấy sự khác biệt về cảm xúc tổng thể giữa hai nhóm là không lớn.

Kết quả này cho thấy các video Trending không nhất thiết nhận được tỷ lệ phản hồi tích cực cao hơn các video thông thường. Thay vào đó, nhóm video Trending có xu hướng thu hút nhiều đối tượng người xem với các quan điểm đa dạng hơn, làm gia tăng tỷ lệ bình luận trung tính. Điều này cho thấy cảm xúc bình luận có thể phản ánh một phần mức độ tương tác của người xem, tuy nhiên không phải là yếu tố quyết định trực tiếp đến khả năng trở thành Trending của video.

3.5.3 Phân tích tương quan dữ liệu

Để đánh giá mức độ liên hệ giữa các đặc trưng và trạng thái Trending của video, nghiên cứu tiến hành tính toán hệ số tương quan Pearson giữa các biến định lượng trong tập dữ liệu.



Hình 3.14 Hệ số tương quan với biến Trending

Kết quả phân tích tương quan cho thấy phần lớn các đặc trưng có mức tương quan thấp đến trung bình với trạng thái Trending. Trong số các biến được khảo sát, thời lượng video (log_duration) có hệ số tương quan cao nhất với biến mục tiêu đạt 0.47. Điều này

cho thấy các video có thời lượng dài hơn có xu hướng xuất hiện trong danh sách Trending nhiều hơn so với các video có thời lượng ngắn.

Bên cạnh đó, tỷ lệ lượt thích (Like Rate) cũng thể hiện mối tương quan dương với trạng thái Trending ($r = 0.23$), phản ánh rằng những video nhận được mức độ yêu thích cao từ người xem có khả năng trở thành Trending lớn hơn. Số lượng người đăng ký kênh ($\log_subscriber_count$) có hệ số tương quan dương ở mức thấp ($r = 0.17$), cho thấy quy mô kênh có ảnh hưởng nhất định đến khả năng tiếp cận và lan tỏa nội dung.

Ngược lại, điểm cảm xúc trung bình của bình luận (Average Sentiment Score) có hệ số tương quan rất thấp với trạng thái Trending ($r = -0.08$). Kết quả này phù hợp với phân tích ở mục 4.1.2.6, khi sự khác biệt về cảm xúc bình luận giữa nhóm Trending và Non-Trending không đáng kể. Ngoài ra, Comment Rate gần như không có mối tương quan với biến mục tiêu ($r = 0.01$), cho thấy mức độ bình luận trên mỗi lượt xem không phải là yếu tố quyết định trực tiếp đến khả năng trở thành Trending của video.

3.5.4 Nhận xét và lựa chọn đặc trưng

Kết quả phân tích khám phá dữ liệu cho thấy các đặc trưng trong tập dữ liệu có mức độ ảnh hưởng khác nhau đến khả năng video xuất hiện trong danh sách Trending. Thông qua việc phân tích phân bố dữ liệu, so sánh giữa hai nhóm Trending và Non-Trending, cũng như đánh giá hệ số tương quan với biến mục tiêu, nghiên cứu đã xác định được các đặc trưng có tiềm năng đóng góp cho quá trình dự đoán.

Đối với nhóm đặc trưng tương tác, View Count, Like Rate và Duration thể hiện sự khác biệt rõ rệt giữa hai nhóm video. Các video thuộc danh sách Trending thường có số lượt xem cao hơn, tỷ lệ lượt thích lớn hơn và thời lượng dài hơn so với các video không Trending. Kết quả phân tích tương quan cũng cho thấy Duration là đặc trưng có hệ số tương quan cao nhất với biến mục tiêu trong số các biến được khảo sát.

Đối với nhóm đặc trưng kênh, Subscriber Count và Video Count phản ánh quy mô và mức độ hoạt động của kênh đăng tải. Kết quả EDA cho thấy các video Trending thường được đăng tải bởi những kênh có số lượng người đăng ký cao hơn. Tuy nhiên, mức độ chồng lấp giữa hai nhóm dữ liệu cho thấy đây không phải là yếu tố quyết định duy nhất đến khả năng trở thành Trending của video.

Đối với nhóm đặc trưng nội dung, Topic và Country Region được giữ lại nhằm phản ánh sự khác biệt về chủ đề nội dung và khu vực địa lý. Kết quả phân tích cho thấy

tập dữ liệu có sự phân bố đa dạng giữa nhiều nhóm chủ đề khác nhau, đồng thời xu hướng Trending có thể thay đổi theo từng quốc gia hoặc khu vực.

Đối với nhóm đặc trưng cảm xúc, mặc dù các chỉ số Positive Ratio, Neutral Ratio và Negative Ratio không thể hiện mức tương quan mạnh với biến mục tiêu, các đặc trưng này vẫn được giữ lại trong nghiên cứu nhằm đánh giá vai trò của phản hồi người dùng đối với khả năng lan truyền của video. Việc bổ sung thông tin cảm xúc giúp mô hình khai thác thêm khía cạnh hành vi và phản ứng của cộng đồng bên cạnh các chỉ số tương tác truyền thống.

Trên cơ sở kết quả phân tích khám phá dữ liệu, nghiên cứu lựa chọn tập đặc trưng cuối cùng gồm: Duration Seconds, Topic, Country Region, View Count, Subscriber Count, Video Count, Like Rate, Comment Rate, Positive Ratio, Neutral Ratio và Negative Ratio. Tập đặc trưng này được sử dụng làm dữ liệu đầu vào cho mô hình XGBoost trong giai đoạn huấn luyện và dự đoán khả năng video xuất hiện trong danh sách Trending được trình bày ở mục tiếp theo.

Bảng 3.18 Các đặc trưng được lựa chọn cho mô hình dự đoán Trending

Đặc trưng	Kiểu dữ liệu	Nhóm đặc trưng
duration_seconds	INTEGER	Nội dung video
topic	VARCHAR	Nội dung video
country_region	VARCHAR	Địa lý
view_count	BIGINT	Tương tác
like_rate	FLOAT	Tương tác
comment_rate	FLOAT	Tương tác
subscriber_count	BIGINT	Kênh
video_count	BIGINT	Kênh

3.6 Xây dựng và đánh giá mô hình dự đoán Trending

Sau khi hoàn thành quá trình tiền xử lý dữ liệu, phân tích cảm xúc và xây dựng đặc trưng, đề tài tiến hành xây dựng mô hình Machine Learning nhằm dự đoán khả năng video xuất hiện trong danh sách Trending trên nền tảng YouTube. Đây là bài toán phân loại nhị phân, trong đó mô hình cần xác định một video thuộc nhóm Trending hay Non-Trending dựa trên các đặc trưng đã được xây dựng từ dữ liệu video, dữ liệu kênh và dữ liệu cảm xúc người dùng.

3.6.1 Chuẩn bị dữ liệu huấn luyện

Sau khi hoàn thành quá trình xây dựng đặc trưng, tập dữ liệu được sử dụng làm đầu vào cho mô hình dự đoán khả năng video xuất hiện trong danh sách Trending. Mục tiêu của giai đoạn này là chuyển đổi dữ liệu về định dạng phù hợp với thuật toán học máy, đồng thời đảm bảo các đặc trưng có thể phản ánh được những yếu tố ảnh hưởng đến khả năng trở thành Trending của video.

Biến mục tiêu được sử dụng trong nghiên cứu là `is_trending`. Đây là biến nhị phân được xây dựng trong giai đoạn thu thập dữ liệu, trong đó giá trị 1 đại diện cho các video thuộc danh sách Trending của YouTube và giá trị 0 đại diện cho các video không thuộc danh sách Trending. Việc sử dụng biến mục tiêu dạng nhị phân giúp bài toán được xây dựng dưới dạng bài toán phân loại hai lớp.

Tập dữ liệu đầu vào bao gồm các đặc trưng được xây dựng từ nhiều nguồn dữ liệu khác nhau như thông tin video, thông tin kênh và kết quả phân tích cảm xúc bình luận. Các đặc trưng này phản ánh nhiều khía cạnh liên quan đến video, bao gồm nội dung, mức độ tương tác của người dùng, quy mô kênh đăng tải và phản hồi của cộng đồng người xem. Việc kết hợp các nhóm đặc trưng giúp mô hình có khả năng khai thác được nhiều thông tin hơn thay vì chỉ dựa trên một nhóm chỉ số riêng lẻ.

Đối với các thuộc tính dạng phân loại như `topic` và `country_region`, dữ liệu được chuyển đổi sang dạng số bằng phương pháp Label Encoding. Quá trình mã hóa này giúp mô hình có thể xử lý các thuộc tính phân loại trong quá trình huấn luyện mà vẫn giữ được sự khác biệt giữa các nhóm dữ liệu. Kết quả mã hóa được lưu lại để sử dụng nhất quán trong giai đoạn dự đoán của ứng dụng.

Bên cạnh đó, dữ liệu thu thập từ YouTube có sự chênh lệch khá lớn giữa các video. Một số video chỉ đạt vài nghìn lượt xem, trong khi nhiều video khác có thể đạt hàng triệu hoặc hàng chục triệu lượt xem. Tương tự, số lượng người đăng ký kênh và số lượng

video của mỗi kênh cũng có sự khác biệt đáng kể. Nếu sử dụng trực tiếp các giá trị này, mô hình có thể bị ảnh hưởng bởi các giá trị quá lớn và khó học được mối quan hệ thực sự giữa các đặc trưng.

Để giảm ảnh hưởng của hiện tượng phân bố lệch và các giá trị ngoại lệ, đề tài áp dụng phép biến đổi logarit tự nhiên thông qua hàm `log1p()` đối với các thuộc tính `view_count`, `subscriber_count`, `video_count` và `duration_seconds`. Phương pháp này giúp thu hẹp khoảng cách giữa các giá trị lớn và nhỏ, đồng thời làm cho phân bố dữ liệu trở nên ổn định hơn. Nhờ đó, mô hình có thể học hiệu quả hơn và giảm nguy cơ bị chi phối bởi một số ít bản ghi có giá trị quá lớn.

Bảng 3.19 Các phép biến đổi dữ liệu trước khi huấn luyện

Thuộc tính	Phương pháp xử lý
topic	LABEL ENCODING
country_region	LABEL ENCODING
view_count	LOG1P
subscriber_count	LOG1P
video_count	LOG1P
duration_seconds	LOG1P

Sau khi hoàn thành các bước tiền xử lý, tập dữ liệu được tách thành hai phần gồm tập huấn luyện và tập kiểm tra theo tỷ lệ 80:20. Trong đó, 80% dữ liệu được sử dụng để huấn luyện mô hình và 20% dữ liệu còn lại được sử dụng để đánh giá hiệu suất sau khi huấn luyện. Việc tách riêng dữ liệu kiểm tra giúp đánh giá khách quan khả năng dự đoán của mô hình trên các dữ liệu chưa từng xuất hiện trong quá trình học.

Do số lượng video Trending và Non-Trending trong tập dữ liệu không hoàn toàn cân bằng, quá trình chia dữ liệu được thực hiện theo phương pháp phân tầng (Stratified Sampling). Phương pháp này giúp duy trì tỷ lệ phân bố giữa hai lớp trên cả tập huấn luyện và tập kiểm tra, từ đó hạn chế hiện tượng thiên lệch dữ liệu và đảm bảo kết quả đánh giá phản ánh đúng năng lực của mô hình.

Kết quả của giai đoạn chuẩn bị dữ liệu là hai tập dữ liệu X_{train} , y_{train} và X_{test} , y_{test} sẵn sàng cho quá trình huấn luyện mô hình XGBoost được trình bày trong mục tiếp theo.

3.6.2 Chia tập dữ liệu

Sau khi hoàn thành quá trình chuẩn bị dữ liệu, tập dữ liệu được chia thành hai phần gồm tập huấn luyện (Training Set) và tập kiểm tra (Test Set) nhằm phục vụ cho quá trình xây dựng và đánh giá mô hình dự đoán Trending. Việc tách dữ liệu giúp đánh giá khách quan khả năng dự đoán của mô hình trên các dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

Trong nghiên cứu này, tập dữ liệu được chia theo tỷ lệ 80:20, trong đó 80% số bản ghi được sử dụng để huấn luyện mô hình và 20% số bản ghi còn lại được sử dụng để kiểm tra hiệu suất sau khi huấn luyện. Tỷ lệ này được sử dụng phổ biến trong các bài toán học máy vì vừa đảm bảo đủ dữ liệu cho quá trình học, vừa duy trì một tập dữ liệu độc lập để đánh giá mô hình.

Do phân bố giữa hai lớp Trending và Non-Trending có sự chênh lệch về số lượng, phương pháp lấy mẫu phân tầng (Stratified Sampling) được áp dụng trong quá trình chia dữ liệu. Phương pháp này giúp duy trì tỷ lệ phân bố của hai lớp trên cả tập huấn luyện và tập kiểm tra, từ đó hạn chế hiện tượng thiên lệch dữ liệu và đảm bảo kết quả đánh giá phản ánh chính xác khả năng tổng quát hóa của mô hình.

Kết quả của quá trình chia dữ liệu tạo ra hai tập dữ liệu đầu vào gồm X_{train} , y_{train} và X_{test} , y_{test} . Trong đó, X_{train} và y_{train} được sử dụng để huấn luyện mô hình, còn X_{test} và y_{test} được sử dụng để đánh giá hiệu suất dự đoán trên dữ liệu chưa từng được sử dụng trong quá trình học.

Bảng 3.20 Kết quả chia dữ liệu

Tập dữ liệu	Số lượng mẫu	Tỷ lệ
Training Set	126,458	80%
Test Set	31,615	20%
Tổng cộng	158,073	100%

3.6.3 Xây dựng và huấn luyện mô hình XGBoost

Sau khi hoàn thành quá trình chia dữ liệu, mô hình XGBoost được lựa chọn để xây dựng hệ thống dự đoán khả năng video xuất hiện trong danh sách Trending của YouTube, mô hình XGBoost được lựa chọn để xây dựng hệ thống dự đoán khả năng video xuất hiện trong danh sách Trending của YouTube. XGBoost (Extreme Gradient Boosting) là một thuật toán học máy thuộc nhóm Gradient Boosting, được phát triển nhằm nâng cao hiệu quả dự đoán thông qua việc kết hợp nhiều cây quyết định yếu (Weak Learners) thành một mô hình mạnh hơn. Thuật toán này được đánh giá cao nhờ khả năng xử lý dữ liệu có kích thước lớn, tốc độ huấn luyện nhanh và hiệu suất tốt trên các bài toán phân loại cũng như dự đoán.

Trong nghiên cứu này, bài toán dự đoán Trending được xây dựng dưới dạng bài toán phân loại nhị phân, trong đó giá trị 1 đại diện cho video Trending và giá trị 0 đại diện cho video Non-Trending. Mô hình XGBoost được huấn luyện trên tập dữ liệu huấn luyện nhằm học các mối quan hệ giữa các đặc trưng đầu vào và trạng thái Trending của video.

Do tập dữ liệu có sự chênh lệch giữa số lượng video Trending và Non-Trending, tham số `scale_pos_weight` được sử dụng nhằm giảm ảnh hưởng của hiện tượng mất cân bằng dữ liệu. Việc điều chỉnh trọng số giúp mô hình chú ý nhiều hơn đến lớp thiểu số, từ đó cải thiện khả năng nhận diện các video Trending trong quá trình dự đoán.

Bảng 3.21 Các tham số huấn luyện mô hình XGBoost

Tham số	Giá trị
n_estimators	300
max_depth	5
learning_rate	0.05
subsample	0.8
colsample_bytree	0.8
scale_pos_weight	Tính toán từ tỷ lệ dữ liệu

Tham số	Giá trị
random_state	42

Trong đó, tham số `n_estimators` xác định số lượng cây quyết định được xây dựng trong mô hình; `max_depth` kiểm soát độ sâu tối đa của mỗi cây nhằm hạn chế hiện tượng overfitting; `learning_rate` điều chỉnh tốc độ học của mô hình; `subsample` và `colsample_bytree` giúp tăng khả năng tổng quát hóa bằng cách lấy mẫu dữ liệu và đặc trưng trong quá trình huấn luyện.

Sau khi hoàn thành quá trình huấn luyện, mô hình được lưu dưới định dạng `xgb_trending_model.json` để phục vụ cho quá trình triển khai và tích hợp vào ứng dụng Streamlit. Mô hình này được sử dụng để dự đoán xác suất Trending của video dựa trên các đặc trưng đầu vào được cung cấp từ người dùng.

3.6.4 Đánh giá kết quả mô hình

Sau khi hoàn thành quá trình huấn luyện, mô hình XGBoost được đánh giá trên tập dữ liệu kiểm tra nhằm đo lường khả năng dự đoán đối với các dữ liệu chưa từng xuất hiện trong quá trình học. Việc đánh giá được thực hiện thông qua các chỉ số phổ biến trong bài toán phân loại bao gồm Accuracy, Precision, Recall, F1-score và ROC-AUC.

Bảng 3.22 Kết quả đánh giá mô hình XGBoost


Chỉ số	Giá trị
Accuracy	0.9318
Precision	0.8070
Recall	0.9666
F1-score	0.8796
ROC-AUC	0.9872

Kết quả cho thấy mô hình đạt độ chính xác (Accuracy) 93.18%, phản ánh khả năng phân loại chính xác phần lớn các video trong tập dữ liệu kiểm tra. Chỉ số Precision đạt 80.70%, cho thấy phần lớn các video được dự đoán là Trending thực sự thuộc nhóm

Trending. Đồng thời, Recall đạt 96.66%, chứng tỏ mô hình có khả năng nhận diện rất tốt các video Trending và bỏ sót rất ít trường hợp thuộc lớp này.

Chỉ số F1-score đạt 87.96%, thể hiện sự cân bằng tốt giữa Precision và Recall. Ngoài ra, giá trị ROC-AUC đạt 0.9872 cho thấy mô hình có khả năng phân biệt rất tốt giữa hai lớp Trending và Non-Trending. Theo thang đánh giá thông thường, giá trị ROC-AUC gần bằng 1 cho thấy mô hình có hiệu suất phân loại ở mức rất cao.

Để đánh giá chi tiết hơn kết quả dự đoán, nghiên cứu sử dụng ma trận nhầm lẫn (Confusion Matrix). Ma trận nhầm lẫn cho phép quan sát số lượng mẫu được phân loại đúng và phân loại sai của từng lớp, từ đó đánh giá khả năng nhận diện video Trending của mô hình.




Hình 3.15 Ma trận nhầm lẫn (Confusion Matrix)

Nhìn chung, các chỉ số đánh giá và kết quả từ ma trận nhầm lẫn cho thấy mô hình XGBoost đạt hiệu suất cao trong bài toán dự đoán Trending. Mô hình không chỉ đạt độ chính xác cao mà còn duy trì khả năng nhận diện tốt các video Trending.

3.6.5 Phân tích mức độ quan trọng của đặc trưng

Bên cạnh việc đánh giá hiệu suất dự đoán, nghiên cứu thực hiện phân tích mức độ quan trọng của các đặc trưng nhằm xác định những yếu tố có ảnh hưởng lớn đến khả năng xuất hiện trong danh sách Trending của video. Việc phân tích này giúp tăng khả năng giải thích của mô hình và hỗ trợ hiểu rõ hơn các yếu tố tác động đến kết quả dự đoán.



Hình 3.16 Độ ảnh hưởng của các đặc trưng

Kết quả cho thấy đặc trưng `duration_seconds` có mức độ ảnh hưởng cao nhất đến mô hình, chiếm tỷ trọng lớn trong tổng mức độ quan trọng của các đặc trưng. Điều này cho thấy thời lượng video là một trong những yếu tố quan trọng giúp phân biệt giữa các video Trending và Non-Trending trong tập dữ liệu nghiên cứu.

Đặc trưng `topic` đứng thứ hai về mức độ quan trọng, cho thấy nội dung và chủ đề của video có ảnh hưởng đáng kể đến khả năng trở thành Trending. Bên cạnh đó, đặc trưng `country_region` cũng đóng góp đáng kể vào kết quả dự đoán, phản ánh sự khác biệt về xu hướng nội dung giữa các khu vực địa lý khác nhau.

Các đặc trưng liên quan đến mức độ tương tác của người dùng như `comment_rate`, `like_rate` và `view_count` vẫn có vai trò trong quá trình dự đoán, tuy nhiên mức độ ảnh hưởng thấp hơn so với các đặc trưng về nội dung và khu vực phát hành. Điều này cho thấy khả năng trở thành Trending không chỉ phụ thuộc vào số lượng tương tác mà còn chịu tác động bởi đặc điểm nội dung của video.

Ngoài ra, các đặc trưng phản ánh quy mô và mức độ hoạt động của kênh như `subscriber_count` và `video_count` có mức độ ảnh hưởng thấp hơn trong mô hình. Kết quả này cho thấy mặc dù quy mô kênh có liên quan đến khả năng tiếp cận người xem, nhưng không phải là yếu tố quyết định trong việc dự đoán trạng thái Trending của video.

Nhìn chung, kết quả phân tích cho thấy thời lượng video (`duration_seconds`) là đặc trưng có ảnh hưởng lớn nhất đến khả năng dự đoán Trending của mô hình. Bên cạnh đó, chủ đề video (`topic`) và khu vực phát hành (`country_region`) cũng đóng vai trò quan trọng trong việc phân biệt giữa các video Trending và Non-Trending.


3.7 Xây dựng ứng dụng dự đoán Trending

Sau khi hoàn thành quá trình xây dựng Data Warehouse, tiền xử lý dữ liệu và huấn luyện mô hình dự đoán, đề tài tiến hành xây dựng ứng dụng dự đoán Trending nhằm hỗ trợ người dùng khai thác kết quả nghiên cứu một cách trực quan. Ứng dụng được phát triển bằng thư viện Streamlit trong Python, cho phép tích hợp mô hình Machine Learning với giao diện web tương tác mà không yêu cầu triển khai các framework web phức tạp.

Mục tiêu của ứng dụng là cung cấp môi trường trực quan để người dùng theo dõi dữ liệu Trending, phân tích các đặc trưng của video và thực hiện dự đoán khả năng xuất hiện trong danh sách Trending dựa trên các thông tin đầu vào.

3.7.1 Kiến trúc ứng dụng

Ứng dụng phân tích và dự đoán video Trending được phát triển bằng thư viện Streamlit, cho phép xây dựng giao diện web tương tác trực tiếp với người dùng. Hệ thống được thiết kế theo mô hình phân chia chức năng thành các module độc lập nhằm hỗ trợ việc theo dõi xu hướng video Trending và dự đoán khả năng xuất hiện trong danh sách Trending của YouTube.



Hình 3.17 Kiến trúc tổng thể của ứng dụng dự đoán Trending

Người dùng tương tác với hệ thống thông qua giao diện Streamlit Web Application. Từ giao diện chính, người dùng có thể truy cập các chức năng Home, Trending Analytics và Predict.

Phân hệ Home đóng vai trò là trang giới thiệu hệ thống, cung cấp thông tin tổng quan về mục tiêu, chức năng và phạm vi dữ liệu được sử dụng trong ứng dụng. Đây là điểm truy cập đầu tiên giúp người dùng làm quen với hệ thống trước khi sử dụng các chức năng phân tích và dự đoán.

Phân hệ Trending Analytics sử dụng YouTube Data API v3 để truy xuất danh sách video đang thịnh hành theo từng quốc gia hoặc khu vực. Dữ liệu được lấy trực tiếp từ nền tảng YouTube và được sử dụng để xây dựng các chỉ số thống kê, biểu đồ trực quan và bảng xếp hạng video Trending. Thông qua chức năng này, người dùng có thể theo dõi các video nổi bật, kênh phổ biến, danh mục nội dung thịnh hành và các chỉ số tương tác theo thời gian thực.

Đối với chức năng Predict, người dùng cung cấp đường dẫn của video YouTube cần dự đoán. Hệ thống sử dụng YouTube Data API v3 để thu thập các thông tin liên quan đến video như số lượt xem, lượt thích, số bình luận, thời lượng video, chủ đề nội dung và thông tin kênh. Sau đó, các đặc trưng đầu vào được xử lý và đưa vào mô hình

XGBoost đã được huấn luyện trước để dự đoán khả năng video xuất hiện trong danh sách Trending.

Kết quả dự đoán được trả về dưới dạng nhãn phân loại Trending hoặc Not Trending cùng với xác suất dự đoán tương ứng. Điều này giúp người dùng đánh giá tiềm năng lan truyền của video dựa trên các đặc trưng đã được mô hình học từ dữ liệu lịch sử.

3.7.2 Chức năng Trending Analytics


Chức năng Trending Analytics được xây dựng nhằm hỗ trợ người dùng theo dõi và phân tích các video đang thịnh hành trên nền tảng YouTube theo thời gian thực. Dữ liệu được truy xuất trực tiếp từ YouTube Data API v3, cho phép hệ thống cập nhật danh sách video Trending mới nhất theo từng quốc gia hoặc khu vực.

Người dùng có thể lựa chọn quốc gia hoặc khu vực cần theo dõi thông qua bộ lọc ở phía trên giao diện. Đồng thời, hệ thống cho phép lựa chọn số lượng video Trending hiển thị như Top 10, Top 20 hoặc Top 30.

Sau khi dữ liệu được tải về từ YouTube Data API, hệ thống thực hiện tổng hợp và trực quan hóa các chỉ số quan trọng bao gồm tổng số video Trending, tổng lượt xem, tổng lượt thích, tổng lượt bình luận và mức độ tăng trưởng tương tác. Các chỉ số này được hiển thị dưới dạng KPI Cards nhằm giúp người dùng nhanh chóng nắm bắt tình hình xu hướng hiện tại.

Bên cạnh các chỉ số tổng quan, hệ thống còn cung cấp bảng xếp hạng các video Trending với đầy đủ thông tin như tiêu đề video, tên kênh, số lượt xem, số lượt thích và số lượt bình luận. Danh sách này giúp người dùng xác định các nội dung đang nhận được sự quan tâm lớn từ cộng đồng người xem.

Ngoài ra, chức năng Trending Analytics còn cung cấp các biểu đồ trực quan nhằm hỗ trợ phân tích dữ liệu. Biểu đồ phân bố danh mục nội dung giúp người dùng nhận biết các chủ đề đang chiếm ưu thế trong danh sách Trending. Biểu đồ xu hướng theo thời gian thể hiện sự thay đổi của mức độ tương tác giữa các video Trending. Đồng thời, hệ thống cũng hiển thị danh sách các kênh nổi bật và bản đồ khu vực nhằm cung cấp góc nhìn tổng quan về sự phân bố của các nội dung thịnh hành.



Hình 3.18 Phác thảo bố cục trang Trending Analytics

3.7.3 Chức năng dự đoán Trending

Chức năng dự đoán Trending được xây dựng nhằm hỗ trợ người dùng đánh giá khả năng một video xuất hiện trong danh sách Trending của YouTube dựa trên mô hình học máy XGBoost đã được huấn luyện từ dữ liệu lịch sử.

Khi truy cập trang Predict, người dùng có thể lựa chọn hai phương thức dự đoán:

- Dự đoán bằng URL video YouTube.
- Dự đoán bằng cách nhập thủ công các thông số của video.


Đối với phương thức nhập URL, hệ thống sử dụng YouTube Data API v3 để tự động thu thập các thông tin cần thiết của video và kênh như lượt xem, lượt thích, số bình luận, thời lượng video, số lượng người đăng ký kênh và các thông tin liên quan khác. Sau khi dữ liệu được thu thập, hệ thống tiến hành tiền xử lý và tính toán các đặc trưng đầu vào tương ứng với mô hình.

Đối với phương thức nhập thủ công, người dùng có thể trực tiếp cung cấp các giá trị của các đặc trưng được sử dụng trong mô hình dự đoán. Cách tiếp cận này cho phép người dùng đánh giá khả năng Trending của một video giả định trước khi đăng tải hoặc khi chưa có đủ dữ liệu thực tế từ YouTube.

Sau khi nhận dữ liệu đầu vào, hệ thống thực hiện các bước xử lý gồm chuẩn hóa dữ liệu, mã hóa các thuộc tính phân loại và xây dựng vector đặc trưng đầu vào cho mô hình XGBoost. Kết quả dự đoán được trả về dưới dạng xác suất xuất hiện trong danh sách Trending cùng với nhãn phân loại Trending hoặc Non-Trending.

Ngoài việc hiển thị kết quả dự đoán, hệ thống còn cung cấp cơ chế giải thích kết quả dựa trên mức độ ảnh hưởng của các đặc trưng trong mô hình. Các đặc trưng quan trọng như tỷ lệ lượt thích (Like Rate), tỷ lệ bình luận (Comment Rate), số lượng người đăng ký kênh (Subscriber Count), chủ đề video (Topic) và khu vực quốc gia (Country Region) được hiển thị dưới dạng biểu đồ mức độ ảnh hưởng nhằm giúp người dùng hiểu rõ nguyên nhân dẫn đến kết quả dự đoán.

Bên cạnh đó, hệ thống cũng đưa ra các gợi ý cải thiện dựa trên các đặc trưng đầu vào của video. Các đề xuất này giúp nhà sáng tạo nội dung có thể điều chỉnh chiến lược phát triển video nhằm nâng cao khả năng xuất hiện trong danh sách Trending của YouTube.



Hình 3.19 Phác thảo bố cục trang Predict Trending Analytics

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1 Kết quả triển khai Dashboard

Dashboard hiển thị các chỉ số tổng quan của tập dữ liệu thông qua bốn thẻ thông tin (KPI Cards), bao gồm tổng số video, tổng số kênh, tổng số bình luận và tỷ lệ video Trending. Các chỉ số này được tổng hợp từ dữ liệu đã thu thập thông qua YouTube Data API v3 và lưu trữ trong kho dữ liệu PostgreSQL. Việc hiển thị các chỉ số tổng quan giúp người dùng nhanh chóng nắm bắt quy mô của tập dữ liệu nghiên cứu.

Bên cạnh các chỉ số tổng quan, hệ thống còn cung cấp nhiều biểu đồ trực quan nhằm hỗ trợ phân tích dữ liệu. Biểu đồ phân bố Trending và Non-Trending cho thấy tỷ lệ giữa các video xuất hiện trong danh sách thịnh hành và các video thông thường. Kết quả cho thấy số lượng video Non-Trending chiếm tỷ trọng lớn hơn đáng kể so với nhóm Trending, phản ánh đúng đặc điểm thực tế của nền tảng YouTube.


Dashboard cũng cung cấp biểu đồ Top 10 chủ đề video nhằm thể hiện sự phân bố nội dung trong tập dữ liệu. Các chủ đề như Âm nhạc, Trò chơi điện tử và Giải trí chiếm tỷ lệ cao, cho thấy đây là những nhóm nội dung phổ biến và xuất hiện thường xuyên trên nền tảng YouTube.

Ngoài ra, hệ thống còn hỗ trợ phân tích hành vi đăng tải video thông qua biểu đồ phân bố video theo ngày trong tuần và theo giờ đăng. Các biểu đồ này cho phép người dùng quan sát xu hướng đăng tải nội dung của các nhà sáng tạo, từ đó nhận diện các khoảng thời gian có mật độ xuất bản video cao.

Cuối cùng, Dashboard cung cấp ma trận tương quan giữa các đặc trưng quan trọng như lượt xem, lượt thích, lượt bình luận, số lượng người đăng ký và thời lượng video. Biểu đồ này hỗ trợ người dùng đánh giá mối quan hệ giữa các biến, đồng thời cung cấp cơ sở cho quá trình lựa chọn đặc trưng trong mô hình dự đoán Trending.

Nhìn chung, Dashboard đóng vai trò là trung tâm trực quan hóa dữ liệu của hệ thống, giúp người dùng nhanh chóng khám phá và phân tích các đặc điểm quan trọng của dữ liệu YouTube trước khi thực hiện các chức năng phân tích chuyên sâu hoặc dự đoán khả năng xuất hiện trong danh sách Trending.


Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube



Hình 4.1 Giao diện Dashboard tổng quan dữ liệu YouTube

4.2 Kết quả triển khai trang Trending Analytics

Trang Trending Analytics được xây dựng nhằm hỗ trợ người dùng theo dõi và phân tích các video đang thịnh hành trên nền tảng YouTube theo thời gian thực. Dữ liệu được thu thập thông qua YouTube Data API v3 và được xử lý trước khi hiển thị dưới dạng các chỉ số thống kê và biểu đồ trực quan trên giao diện ứng dụng.



Hình 4.2. Giao diện trang Trending Analytics

ại phần đầu giao diện, hệ thống hiển thị các chỉ số tổng quan của danh sách video Trending hiện tại, bao gồm số lượng video đang thịnh hành, tổng lượt xem, tổng lượt thích, tổng lượt bình luận và mức tăng trưởng xu hướng. Các chỉ số này giúp người dùng nhanh chóng nắm bắt mức độ phổ biến cũng như hiệu suất tương tác của các video đang xuất hiện trong danh sách Trending.

Bên dưới khu vực thống kê, hệ thống hiển thị danh sách Top 10 Trending Now. Mỗi video được trình bày kèm hình thu nhỏ, tiêu đề, tên kênh, số lượt xem, thời gian đăng tải và các chỉ số tương tác. Thông tin này giúp người dùng dễ dàng theo dõi những nội dung đang nhận được sự quan tâm lớn nhất trên nền tảng YouTube tại thời điểm truy cập.

Ngoài danh sách video thịnh hành, hệ thống còn cung cấp biểu đồ Trending theo danh mục nhằm thể hiện tỷ lệ phân bố của các nhóm nội dung xuất hiện trong danh sách Trending. Thông qua biểu đồ này, người dùng có thể nhận biết các chủ đề đang chiếm ưu thế như Âm nhạc, Gaming, Phim ảnh hoặc Giải trí.

Để hỗ trợ đánh giá xu hướng theo thời gian, trang Trending Analytics hiển thị biểu đồ Trending theo thời gian. Biểu đồ thể hiện sự thay đổi về mức độ quan tâm đối với các video Trending trong khoảng thời gian quan sát, giúp người dùng nhận biết các giai đoạn tăng trưởng hoặc suy giảm của xu hướng nội dung.


Hệ thống cũng cung cấp danh sách Top Channels, cho phép xác định các kênh YouTube có nhiều video xuất hiện trong danh sách Trending nhất. Chức năng này hỗ trợ người dùng đánh giá mức độ ảnh hưởng của từng nhà sáng tạo nội dung cũng như khả năng duy trì sức hút của các kênh trên nền tảng.

Nhìn chung, trang Trending Analytics đóng vai trò là trung tâm phân tích xu hướng của hệ thống, cung cấp thông tin trực quan về các video đang thịnh hành, mức độ tương tác của người dùng, sự phân bố nội dung theo danh mục và đặc điểm xu hướng theo khu vực. Qua đó, người dùng có thể nhanh chóng nắm bắt các xu hướng nổi bật trên YouTube và hỗ trợ cho quá trình phân tích dữ liệu hoặc nghiên cứu hành vi người xem.

4.3 Kết quả triển khai trang Predict

Chức năng Predict được xây dựng nhằm hỗ trợ người dùng dự đoán khả năng một video YouTube xuất hiện trong danh sách Trending dựa trên mô hình học máy XGBoost đã được huấn luyện từ dữ liệu thu thập. Người dùng chỉ cần nhập URL video YouTube,

hệ thống sẽ tự động thu thập các thông tin cần thiết thông qua YouTube Data API v3, thực hiện tiền xử lý dữ liệu và đưa vào mô hình để dự đoán.



Hình 4.3. Giao diện chức năng Predict và kết quả dự đoán Trending

Sau khi người dùng nhập URL video, hệ thống hiển thị các thông tin cơ bản của video bao gồm hình thu nhỏ (thumbnail), tiêu đề, tên kênh, số lượng người đăng ký, chủ đề nội dung, khu vực và thời lượng video. Đồng thời, các chỉ số quan trọng như lượt xem, lượt thích, lượt bình luận và số lượng người đăng ký của kênh cũng được trình bày trực quan trên giao diện.

Kết quả dự đoán được hiển thị thông qua biểu đồ phần trăm xác suất Trending. Trong ví dụ minh họa, mô hình dự đoán video có xác suất đạt Trending là 44,3%, tương ứng với mức đánh giá "Trung bình". Điều này giúp người dùng dễ dàng đánh giá tiềm năng lan truyền của video trước khi xuất hiện trong danh sách Trending.

Bên cạnh kết quả dự đoán, hệ thống còn hiển thị mức độ quan trọng của các đặc trưng (Feature Importance) được trích xuất từ mô hình XGBoost. Các đặc trưng như thời lượng video (duration_seconds), chủ đề nội dung (topic), khu vực (country_region), tỷ lệ bình luận (comment_rate), tỷ lệ thích (like_rate) và lượt xem (view_count) được sắp xếp theo mức độ ảnh hưởng đến kết quả dự đoán. Chức năng này giúp tăng khả năng giải thích của mô hình và hỗ trợ người dùng hiểu được các yếu tố tác động đến khả năng trở thành Trending.

Ngoài ra, hệ thống cung cấp bảng dữ liệu phân tích gồm tám đặc trưng đầu vào được sử dụng trong quá trình dự đoán. Các đặc trưng bao gồm thời lượng video, chủ đề

nội dung, khu vực phát hành, tỷ lệ thích, tỷ lệ bình luận, lượt xem, số lượng người đăng ký và số lượng video của kênh. Việc hiển thị các đặc trưng này giúp người dùng kiểm tra và xác nhận dữ liệu đầu vào trước khi xem kết quả dự đoán.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết quả đạt được

Sau quá trình nghiên cứu và thực hiện, đề tài đã hoàn thành các mục tiêu đặt ra ban đầu về xây dựng hệ thống Data Warehouse cho dữ liệu YouTube và ứng dụng Machine Learning trong dự đoán khả năng video trở thành Trending.

Thứ nhất, đề tài đã xây dựng thành công quy trình thu thập dữ liệu từ YouTube Data API v3, bao gồm dữ liệu video, kênh và bình luận. Hệ thống đã thu thập được hơn 158 nghìn video, 83 nghìn kênh và hàng triệu bình luận từ nhiều quốc gia và khu vực khác nhau.

Thứ hai, đề tài đã thiết kế và triển khai kho dữ liệu (Data Warehouse) trên PostgreSQL theo mô hình Star Schema, hỗ trợ lưu trữ và quản lý dữ liệu một cách tập trung, tạo nền tảng cho các hoạt động phân tích và khai thác dữ liệu.

Thứ ba, đề tài đã thực hiện quá trình tiền xử lý dữ liệu, xây dựng đặc trưng và phân tích dữ liệu khám phá (EDA), giúp làm rõ các đặc điểm và xu hướng của dữ liệu YouTube.

Thứ tư, đề tài đã xây dựng thành công mô hình XGBoost để dự đoán khả năng video trở thành Trending. Kết quả thực nghiệm cho thấy mô hình đạt Accuracy 93,18%, Precision 80,70%, Recall 96,66%, F1-score 87,96% và ROC-AUC 98,72%, thể hiện khả năng dự đoán tốt trên tập dữ liệu nghiên cứu.

Cuối cùng, đề tài đã phát triển ứng dụng trực quan hóa và dự đoán bằng Streamlit với các chức năng chính gồm Dashboard, Trending Analytics và Predict. Ứng dụng cho phép người dùng theo dõi dữ liệu Trending theo thời gian thực và dự đoán khả năng Trending của video YouTube thông qua giao diện trực quan

5.2 Hạn chế của đề tài

Mặc dù đạt được các mục tiêu đề ra, đề tài vẫn còn một số hạn chế nhất định.

Thứ nhất, dữ liệu được thu thập thông qua YouTube Data API v3 nên chịu ảnh hưởng bởi các giới hạn về quota và số lượng dữ liệu có thể truy xuất trong một khoảng thời gian nhất định.

Thứ hai, dữ liệu Trending của YouTube chỉ phản ánh một phần thuật toán đề xuất thực tế của nền tảng. Nhiều yếu tố nội bộ của YouTube như thời gian xem (Watch Time),

tỷ lệ giữ chân người xem (Audience Retention) hoặc dữ liệu đề xuất không được công khai nên chưa thể đưa vào mô hình.

Thứ ba, mô hình dự đoán hiện tại chủ yếu sử dụng các đặc trưng thống kê của video và kênh. Các yếu tố liên quan đến nội dung như hình ảnh thumbnail, tiêu đề video hoặc nội dung bình luận chưa được khai thác sâu.

Thứ tư, ứng dụng hiện chỉ hỗ trợ dự đoán trên từng video riêng lẻ và chưa hỗ trợ phân tích hàng loạt hoặc theo dõi xu hướng dài hạn.

Thứ năm, YouTube Data API v3 không cung cấp danh sách video Trending theo từng danh mục nội dung (category) đối với nhiều quốc gia và khu vực. Do đó, hệ thống chỉ có thể thu thập danh sách Trending tổng thể và thực hiện phân tích dựa trên dữ liệu hiện có. Việc phân tích xu hướng thịnh hành theo từng danh mục cụ thể như Gaming, Giáo dục hoặc Thể thao vẫn còn hạn chế và chưa phản ánh đầy đủ đặc điểm của từng nhóm nội dung trên nền tảng YouTube

Ngoài ra, việc thu thập dữ liệu theo thời gian thực còn phụ thuộc vào kết nối mạng và khả năng truy cập API, do đó có thể ảnh hưởng đến tốc độ cập nhật dữ liệu của hệ thống.

5.3 Hướng phát triển

Trong tương lai, đề tài có thể được mở rộng theo một số hướng sau.

Thứ nhất, mở rộng phạm vi thu thập dữ liệu từ nhiều quốc gia và trong khoảng thời gian dài hơn nhằm nâng cao tính đại diện của dữ liệu và cải thiện khả năng tổng quát của mô hình.

Thứ hai, tích hợp thêm các đặc trưng liên quan đến nội dung video như phân tích thumbnail bằng Computer Vision, phân tích tiêu đề video bằng Natural Language Processing (NLP) hoặc khai thác cảm xúc từ bình luận người dùng để nâng cao độ chính xác của mô hình dự đoán.

Thứ ba, nghiên cứu và so sánh thêm các mô hình học máy và học sâu như LightGBM, CatBoost hoặc Neural Network nhằm tối ưu hiệu quả dự đoán.

Thứ tư, phát triển hệ thống theo hướng tự động hóa hoàn toàn quy trình thu thập dữ liệu, ETL và cập nhật kho dữ liệu theo thời gian thực.

Cuối cùng, ứng dụng có thể được mở rộng thành một nền tảng phân tích xu hướng YouTube hoàn chỉnh, hỗ trợ nhà sáng tạo nội dung và doanh nghiệp theo dõi xu hướng, đánh giá hiệu quả video và đưa ra quyết định dựa trên dữ liệu.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] J. Han, M. Kamber and J. Pei (2022), "Data Mining: Concepts and Techniques", 4th ed., Morgan Kaufmann, Cambridge, MA, USA.
- [2] J. W. Tukey (1977), "Exploratory Data Analysis", Addison-Wesley, Reading, MA, USA.
- [3] W. H. Inmon (2005), "Building the Data Warehouse", 4th ed., Wiley, Hoboken, NJ, USA.
- [4] R. Kimball and M. Ross (2013), "The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling", 3rd ed., Wiley, Hoboken, NJ, USA.
- [5] Microsoft (2025), "What is ETL (Extract, Transform, Load)?", Microsoft Azure Architecture Center. [Online]. Available: <https://learn.microsoft.com/azure/architecture/data-guide/relational-data/etl>. [Accessed: Jun. 2026].
- [6] PostgreSQL Global Development Group (2026), "PostgreSQL Documentation". [Online]. Available: <https://www.postgresql.org/docs/>. [Accessed: Jun. 2026].
- [7] B. Liu (2012), "Sentiment Analysis and Opinion Mining", Morgan & Claypool Publishers, San Rafael, CA, USA.
- [8] A. Conneau et al. (2020), "Unsupervised Cross-lingual Representation Learning at Scale", Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), pp. 8440–8451.
- [9] T. M. Mitchell (1997), "Machine Learning", McGraw-Hill, New York, NY, USA.
- [10] C. Ware (2020), "Information Visualization: Perception for Design", 4th ed., Morgan Kaufmann, Burlington, MA, USA.
- [11] Streamlit Inc. (2026), "Streamlit Documentation". [Online]. Available: <https://docs.streamlit.io/>. [Accessed: Jun. 2026].
- [12] T. Chen and C. Guestrin (2016), "XGBoost: A Scalable Tree Boosting System", Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, pp. 785–794.