

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



ĐỒ ÁN TỐT NGHIỆP
XÂY DỰNG DATA WAREHOUSE VÀ MÔ HÌNH
MACHINE LEARNING PHÂN TÍCH VÀ DỰ ĐOÁN
VIDEO TRENDING TRÊN YOUTUBE

Giảng viên hướng dẫn: **ThS. PHẠM THỊ TRÚC MAI**

Sinh viên thực hiện: **Châu Gia Bảo**

Mã số sinh viên: **110122034**

Lớp: **DA22TTA**

Khoá: **2022**

Vĩnh Long, tháng 6 năm 2022

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN	1
1.1 Tổng quan đề tài	1
1.2 Tổng quan về các vấn đề cần giải quyết	1
1.3 Công nghệ và công cụ sử dụng	2
1.4 Ý nghĩa thực tiễn đề tài	2
CHƯƠNG 2: NGHIÊN CỨU LÝ THUYẾT	3
2.1 Phân tích dữ liệu	3
2.2 Phân tích khám phá dữ liệu (Exploratory Data Analysis)	3
2.3 Kho dữ liệu (Data Warehouse).....	4
2.3.1 Mô hình hình sao (Star Schema).....	4
2.3.2 Mô hình bông tuyết (Snowflake Schema)	5
2.3.3 Mô hình chòm sao sự kiện (Galaxy Schema)	5
2.4 Quy trình (Extract – Transform – Load).....	6
2.4.1 Giai đoạn Extract (Trích xuất dữ liệu)	6
2.4.2 Giai đoạn Transform (Chuyển đổi dữ liệu).....	6
2.4.3 Giai đoạn Load (Nạp dữ liệu)	6
2.5 Hệ quản trị cơ sở dữ liệu PostgreSQL.....	7
2.6 Phân tích cảm xúc.....	7
2.6.1 XLM-RoBERTa.....	8
2.7 Machine Learning trong dự đoán Trending.....	8
2.7.1 Bài toán phân loại	8
2.7.2 Thuật toán XGBoost	9
2.7.3 Feature Engineering	11
2.7.4 Các chỉ số đánh giá mô hình	11
2.8 Trực quan hóa dữ liệu và Streamlit.....	12
2.8.1 Trực quan hóa dữ liệu	12
2.8.2 Streamlit	12
CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU	14
3.1 Quy trình nghiên cứu tổng thể	14
3.2. Thu thập dữ liệu	16
3.2.1. Nguồn dữ liệu.....	16
3.2.2. Phương pháp thu thập dữ liệu	17
3.2.3. Thống kê bộ dữ liệu thu thập	18

3.3 Xây dựng hệ thống Data Warehouse và quy trình ETL.....	23
3.3.1 Thiết kế Star Schema	23
3.3.2 Quy trình ETL	25
3.3.3 Lưu trữ dữ liệu trên PostgreSQL	27
3.4 Tiền xử lý và xây dựng đặc trưng	27
3.4.1 Làm sạch và chuẩn hóa dữ liệu	28
3.4.2 Phân tích cảm xúc bình luận	29
3.4.2.1 Tiền xử lý văn bản.....	29
3.4.2.2 Phân loại cảm xúc bằng XLM-RoBERTa	30
3.4.2.3 Kết quả phân tích cảm xúc	31
3.4.3 Xây dựng đặc trưng.....	31
3.5 Phân tích khám phá dữ liệu (EDA)	33
3.5.1 Phân tích tổng quan dữ liệu.....	33
3.5.2 Phân tích đặc trưng tương tác	34
3.5.3 Phân tích cảm xúc người dùng.....	34
3.5.4 Phân tích tương quan dữ liệu	35
3.5.5 Nhận xét và lựa chọn đặc trưng	35
3.6 Xây dựng và đánh giá mô hình dự đoán Trending	36
3.6.1 Chuẩn bị dữ liệu huấn luyện	36
3.6.2 Xây dựng mô hình XGBoost	38
3.6.2.1 Áp dụng mô hình XGBoost trong bài toán dự đoán	38
3.7 Xây dựng ứng dụng dự đoán Trending.....	39
3.7.1 Kiến trúc ứng dụng	40
3.7.2 Chức năng Trending Analytics	41
3.7.3 Chức năng dự đoán Trending.....	43
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU	45
4.1. Kết quả phân tích khám phá dữ liệu (EDA).....	45
4.1.1 Phân tích tổng quan dữ liệu.....	45
4.1.1.1 Phân bố trạng thái Trending	45
4.1.1.2 Phân bố chủ đề video.....	46
4.1.1.2 Phân bố cảm xúc bình luận	47
4.1.2 Phân tích đặc trưng tương tác	48
4.1.2.1 Phân tích View Count theo trạng thái Trending	48
4.1.2.2 Phân bố Like Rate theo trạng thái Trending	49
4.1.2.3 Phân bố Comment Rate theo trạng thái Trending.....	50

4.1.2.4 Phân bố Duration theo trạng thái Trending.....	51
4.1.2.5 Phân bố Subscriber Count theo trạng thái Trending	52
4.1.2.6 Phân bố Sentiment theo trạng thái Trending	54
4.1.3 Phân tích tương quan dữ liệu	56
4.1.3.1 Ma trận tương quan giữa các biến	56
4.2 Xây dựng mô hình dự đoán video Trending.....	57
4.2.1 Chuẩn bị dữ liệu cho mô hình.....	57
4.2.2 Chia tập dữ liệu	57
4.2.3 Xây dựng và huấn luyện mô hình	57
4.2.4 Đánh giá kết quả mô hình	57
4.2.5 Phân tích mức độ quan trọng của đặc trưng.....	57
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	58
DANH MỤC TÀI LIỆU THAM KHẢO	59

LỜI CAM ĐOAN

Em xin cam đoan đề án tốt nghiệp “Xây Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” là công trình nghiên cứu của riêng em, được thực hiện dưới sự hướng dẫn của giảng viên hướng dẫn.

Toàn bộ dữ liệu, kết quả phân tích, kết quả thực nghiệm và mã nguồn trình bày trong báo cáo là trung thực, do em trực tiếp thu thập, xây dựng, xử lý và kiểm chứng từ dữ liệu được khai thác thông qua YouTube Data API v3. Những nội dung tham khảo từ sách, bài báo khoa học, tài liệu kỹ thuật và các nguồn tham khảo khác đều được trích dẫn và ghi nguồn đầy đủ trong danh mục tài liệu tham khảo.

Đề tài này chưa từng được sử dụng để bảo vệ hoặc công bố trong bất kỳ công trình nghiên cứu nào khác. Em xin hoàn toàn chịu trách nhiệm về tính trung thực, chính xác và khách quan của toàn bộ nội dung được trình bày trong đề án.

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn chân thành đến cô Phạm Thị Trúc Mai, giảng viên Khoa Công nghệ Thông tin, Trường Kỹ thuật và Công nghệ, Đại học Trà Vinh, người đã trực tiếp hướng dẫn em trong suốt quá trình thực hiện đề tài.

Trong thời gian thực hiện đề án, cô đã tận tình định hướng, góp ý và hỗ trợ em từ quá trình thu thập dữ liệu, xây dựng hệ thống Data Warehouse đến việc phát triển và đánh giá mô hình học máy dự đoán video Trending trên YouTube. Những kiến thức và kinh nghiệm mà cô chia sẻ đã giúp em hoàn thiện đề tài cũng như nâng cao kỹ năng nghiên cứu của bản thân.

Em xin chân thành cảm ơn quý thầy cô Khoa Công nghệ Thông tin đã truyền đạt những kiến thức quý báu trong suốt thời gian học tập tại trường. Đồng thời, em cũng xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ và tạo điều kiện thuận lợi để em hoàn thành đề án tốt nghiệp này. Do kiến thức và kinh nghiệm còn hạn chế, đề án khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp từ quý thầy cô để đề tài được hoàn thiện hơn.

Một lần nữa, em xin chân thành cảm ơn và kính chúc quý thầy cô luôn mạnh khỏe, hạnh phúc và thành công trong công tác giảng dạy.

Sinh viên thực hiện

Châu Gia Bảo

NHẬN XÉT
(Của giảng viên hướng dẫn trong đề án, khoá luận của sinh viên)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giảng viên hướng dẫn
(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP
(Của giảng viên hướng dẫn)

Họ và tên sinh viên: Châu Gia Bảo

MSSV: 110122034

Ngành: Công nghệ thông tin

Khóa: 2022

Tên đề tài: Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên Youtube

Họ và tên Giáo viên hướng dẫn: Phạm Thị Trúc Mai

Chức danh: Giảng viên

Học vị: Thạc sĩ

NHẬN XÉT

1. Nội dung đề tài:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

2. Ưu điểm:

.....

.....

.....

3. Khuyết điểm:

.....

.....

.....

4. Điểm mới đề tài:

.....

.....

.....

NHẬN XÉT
(Của giảng viên chấm trong đề án, khoá luận của sinh viên)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giảng viên chấm
(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP
(Của cán bộ chấm đồ án, khóa luận)

Họ và tên người nhận xét:
Chức danh: Học vị:
Chuyên ngành:
Cơ quan công tác:
Tên sinh viên: Châu Gia Bảo
Tên đề tài đồ án, khóa luận tốt nghiệp: Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên Youtube.

I. Ý KIẾN NHẬN XÉT

1. Nội dung:
-
.....
.....
.....
.....
.....
.....
.....
.....
2. Điểm mới các kết quả của đồ án, khóa luận:
-
.....
.....
3. Ứng dụng thực tế:
-
.....
.....
.....
.....
.....
.....

II. CÁC VẤN ĐỀ CẦN LÀM RÕ

(Các câu hỏi của giáo viên phản biện)

[illegible]

III. KẾT LUẬN

(Ghi rõ đồng ý hay không đồng ý cho bảo vệ đồ án khóa luận tốt nghiệp)

.....

.....

.....

.....

.....

....., ngày tháng năm 20...

Người nhận xét

(Ký & ghi rõ họ tên)

DANH MỤC CÁC BẢNG BIỂU

DANH MỤC HÌNH ẢNH

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

SXKD: (size 13)
CTM :
QTKD.....
.....

Sản xuất kinh doanh
Chế tạo máy
Quản trị kinh doanh

Ghi chú:

Cụm từ viết tắt là các chữ cái và các ký hiệu thay chữ được viết liền nhau, để thay cho một cụm từ có nghĩa thường được lặp nhiều lần trong văn bản hoặc được mọi người mặc nhiên chấp nhận.

TÓM TẮT ĐỒ ÁN TỐT NGHIỆP

Đồ án “Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” tập trung nghiên cứu việc khai thác và phân tích dữ liệu video từ nền tảng YouTube nhằm hỗ trợ dự đoán khả năng video trở thành Trending dựa trên các đặc trưng về nội dung, tương tác và cảm xúc người dùng. Trong bối cảnh dữ liệu mạng xã hội ngày càng phát triển mạnh mẽ, việc phân tích xu hướng video và hành vi người xem có ý nghĩa quan trọng đối với nhà sáng tạo nội dung, doanh nghiệp truyền thông và hoạt động marketing số.

Trong quá trình thực hiện, dữ liệu được thu thập thông qua YouTube Data API v3 từ nhiều lĩnh vực khác nhau như Entertainment, Gaming, Food, Technology và Vlog. Dữ liệu bao gồm thông tin video, thống kê tương tác, thông tin kênh và bình luận người dùng. Sau khi thu thập, dữ liệu được tiền xử lý bằng Python nhằm loại bỏ dữ liệu trùng lặp, xử lý giá trị thiếu và chuẩn hóa dữ liệu trước khi đưa vào hệ thống lưu trữ.

Đồ án tiến hành xây dựng hệ thống Data Warehouse theo mô hình Star Schema, kết hợp quy trình ETL và lưu trữ dữ liệu trên PostgreSQL nhằm hỗ trợ truy vấn, phân tích và mở rộng dữ liệu hiệu quả. Song song đó, phân tích khám phá dữ liệu (EDA) được thực hiện để xác định các yếu tố ảnh hưởng đến xu hướng Trending của video như lượt xem, lượt thích, bình luận, thời gian đăng tải và mức độ tương tác của người dùng.

Bên cạnh đó, đồ án áp dụng mô hình xử lý ngôn ngữ tự nhiên XLM-RoBERTa để phân tích cảm xúc bình luận người dùng, từ đó xây dựng thêm các đặc trưng phục vụ bài toán dự đoán. Mô hình Machine Learning XGBoost được sử dụng để huấn luyện và dự đoán khả năng video trở thành Trending. Hiệu quả mô hình được đánh giá thông qua các chỉ số Accuracy, Precision, Recall và F1-score.

Kết quả cuối cùng của đồ án được trực quan hóa thông qua dashboard và ứng dụng Streamlit, hỗ trợ người dùng theo dõi dữ liệu, phân tích xu hướng và thử nghiệm dự đoán video Trending trên YouTube một cách trực quan và hiệu quả.

CHƯƠNG MỞ ĐẦU

Lý do chọn đề tài

Trong bối cảnh các nền tảng mạng xã hội phát triển mạnh mẽ, YouTube đã trở thành một trong những nền tảng chia sẻ video lớn nhất thế giới với lượng dữ liệu khổng lồ được tạo ra mỗi ngày. Các video Trending trên YouTube phản ánh xu hướng quan tâm của cộng đồng người dùng và đóng vai trò quan trọng trong hoạt động truyền thông, marketing số cũng như phát triển nội dung số. Việc khai thác và phân tích dữ liệu Trending không chỉ giúp hiểu rõ hành vi người dùng mà còn hỗ trợ nhà sáng tạo nội dung và doanh nghiệp đưa ra chiến lược phát triển phù hợp.

Đề tài “Xây dựng Data Warehouse và mô hình Machine Learning phân tích và dự đoán video Trending trên YouTube” được lựa chọn nhằm nghiên cứu và xây dựng hệ thống hỗ trợ phân tích dữ liệu video YouTube theo hướng kết hợp giữa Data Warehouse, phân tích dữ liệu và Machine Learning. Đề tài tập trung phân tích mối quan hệ giữa các yếu tố như lượt xem, lượt thích, bình luận, thời gian đăng tải và cảm xúc người dùng để đánh giá khả năng video trở thành Trending.

Python được sử dụng do sở hữu hệ sinh thái thư viện mạnh mẽ phục vụ cho quá trình thu thập, xử lý, phân tích dữ liệu và xây dựng mô hình học máy. PostgreSQL được sử dụng để xây dựng kho dữ liệu (Data Warehouse) theo mô hình ngôi sao (Star Schema) nhằm hỗ trợ lưu trữ và truy vấn dữ liệu hiệu quả. Bên cạnh đó, Streamlit được lựa chọn để phát triển ứng dụng trực quan hóa và demo hệ thống dự đoán, giúp trình bày kết quả một cách trực quan và dễ sử dụng.

Mục đích nghiên cứu

Mục đích nghiên cứu của đề tài nhằm thu thập, xử lý và phân tích dữ liệu video Trending trên YouTube, từ đó xác định các yếu tố ảnh hưởng đến khả năng video trở thành Trending, nhận diện xu hướng nội dung và mức độ tương tác của người dùng. Đồng thời, đề tài hướng đến việc xây dựng kho dữ liệu (Data Warehouse) kết hợp mô hình Machine Learning nhằm hỗ trợ dự đoán xu hướng video Trending và trực quan hóa kết quả phục vụ cho việc phân tích và ra quyết định.

Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm dữ liệu video, thông tin kênh và bình luận người dùng trên nền tảng YouTube, với các thông tin như lượt xem, lượt thích, lượt bình luận, thời gian đăng tải, danh mục video và nội dung bình luận.

Bên cạnh đó, đề tài còn nghiên cứu các công nghệ và phương pháp liên quan đến phân tích dữ liệu và xây dựng hệ thống dữ liệu, bao gồm Python trong thu thập và xử lý dữ liệu; Data Warehouse và mô hình Star Schema trong tổ chức lưu trữ dữ liệu; PostgreSQL trong quản lý cơ sở dữ liệu; các phương pháp phân tích cảm xúc bằng mô hình XLM-RoBERTa; cùng với các thuật toán Machine Learning như XGBoost trong bài toán dự đoán video Trending.

Phạm vi nghiên cứu

Nghiên cứu tập trung vào dữ liệu video Trending được thu thập từ YouTube Data API v3 trên nhiều lĩnh vực như Entertainment, Gaming, Food, Technology và Vlog. Phân tích chủ yếu xoay quanh các yếu tố liên quan đến mức độ tương tác của video như lượt xem, lượt thích, lượt bình luận, thời gian đăng tải và cảm xúc người dùng trong bình luận.

Đề tài tập trung xây dựng kho dữ liệu (Data Warehouse) và mô hình dự đoán Trending dựa trên dữ liệu đã thu thập, không đi sâu vào các bài toán xử lý video, nhận diện hình ảnh hoặc phân tích nội dung multimedia chuyên sâu.

Phương pháp nghiên cứu

Phương pháp nghiên cứu được triển khai theo hướng kết hợp giữa nghiên cứu lý thuyết và nghiên cứu thực nghiệm nhằm đảm bảo cả nền tảng khoa học lẫn tính ứng dụng thực tiễn. Cách tiếp cận này cho phép đôi chiều kiến thức đã nghiên cứu với dữ liệu thực tế thu thập từ YouTube, từ đó đánh giá hiệu quả của các mô hình và kỹ thuật được lựa chọn.

Phương pháp nghiên cứu lý thuyết

Nghiên cứu lý thuyết của đề tài được xây dựng dựa trên việc tổng hợp các kiến thức nền tảng trong lĩnh vực phân tích dữ liệu, Data Warehouse, xử lý ngôn ngữ tự nhiên và học máy. Nội dung nghiên cứu tập trung vào các thư viện xử lý dữ liệu trong Python như Pandas, NumPy, Scikit-learn; các kỹ thuật phân tích khám phá dữ liệu (EDA) và thống kê mô tả.

Bên cạnh đó, đề tài nghiên cứu các kiến thức liên quan đến Data Warehouse, mô hình Star Schema, quy trình ETL và hệ quản trị cơ sở dữ liệu PostgreSQL. Ngoài ra, đề tài còn tìm hiểu các phương pháp phân tích cảm xúc bằng mô hình ngôn ngữ tiên huấn luyện XLM-RoBERTa và các thuật toán Machine Learning như XGBoost phục vụ cho bài toán dự đoán video Trending.

Phương pháp nghiên cứu thực nghiệm

Nghiên cứu thực nghiệm được lựa chọn nhằm kiểm chứng các giả thuyết và đánh giá hiệu quả của hệ thống dựa trên dữ liệu thực tế thu thập từ YouTube. Phương pháp này cho phép đánh giá mối quan hệ giữa các yếu tố tương tác của video và khả năng trở thành Trending thông qua các kỹ thuật phân tích dữ liệu và học máy.

Quá trình thực nghiệm bao gồm các bước chính: thu thập dữ liệu từ YouTube Data API v3; tiền xử lý dữ liệu như xử lý giá trị thiếu, loại bỏ dữ liệu trùng lặp và chuẩn hóa dữ liệu; xây dựng kho dữ liệu (Data Warehouse) theo mô hình ngôi sao (Star Schema); thực hiện phân tích khám phá dữ liệu (EDA) để tìm insight và xu hướng; phân tích cảm xúc bình luận người dùng bằng mô hình XLM-RoBERTa; xây dựng và huấn luyện mô hình XGBoost để dự đoán video Trending; cuối cùng là trực quan hóa dữ liệu và triển khai ứng dụng demo bằng Streamlit nhằm hỗ trợ phân tích và đánh giá kết quả.

CHƯƠNG 1: TỔNG QUAN

1.1 Tổng quan đề tài

Đề tài hướng đến việc xây dựng hệ thống Data Warehouse kết hợp phân tích dữ liệu và mô hình Machine Learning nhằm phân tích và dự đoán khả năng video trở thành Trending trên nền tảng YouTube. Trong bối cảnh các nền tảng mạng xã hội và nội dung số phát triển mạnh mẽ, YouTube tạo ra lượng dữ liệu rất lớn liên quan đến video, hành vi người dùng và mức độ tương tác. Việc khai thác và phân tích dữ liệu này có ý nghĩa quan trọng đối với nhà sáng tạo nội dung, doanh nghiệp truyền thông và hoạt động marketing số.

Thông qua việc thu thập dữ liệu video, thông tin kênh và bình luận người dùng từ YouTube Data API v3, đề tài sử dụng Python để thực hiện quá trình xử lý dữ liệu, phân tích khám phá dữ liệu (EDA), phân tích cảm xúc bình luận và xây dựng mô hình học máy dự đoán Trending. Bên cạnh đó, hệ thống Data Warehouse được xây dựng theo mô hình Star Schema nhằm hỗ trợ lưu trữ và truy vấn dữ liệu hiệu quả. Kết quả phân tích và dự đoán được trực quan hóa thông qua dashboard và ứng dụng Streamlit nhằm hỗ trợ theo dõi và đánh giá xu hướng video một cách trực quan.

1.2 Tổng quan về các vấn đề cần giải quyết

Đề tài tập trung giải quyết các vấn đề chính sau:

- Thu thập dữ liệu video, thông tin kênh và bình luận từ YouTube thông qua YouTube Data API v3.
- Tiền xử lý dữ liệu như xử lý missing values, loại bỏ dữ liệu trùng lặp, tiền xử lý văn bản và chuẩn hóa dữ liệu phục vụ cho phân tích.
- Xây dựng hệ thống Data Warehouse theo mô hình Star Schema nhằm hỗ trợ lưu trữ và quản lý dữ liệu phân tích.
- Thực hiện phân tích khám phá dữ liệu (EDA) để xác định các yếu tố ảnh hưởng đến khả năng video trở thành Trending như lượt xem, lượt thích, lượt bình luận và thời gian đăng tải.
- Phân tích cảm xúc bình luận người dùng nhằm đánh giá mức độ phản hồi tích cực, tiêu cực hoặc trung lập đối với video.
- Tiến hành Feature Engineering và xây dựng mô hình Machine Learning để dự đoán khả năng video trở thành Trending.

- Trực quan hóa kết quả phân tích và dự đoán thông qua dashboard và ứng dụng Streamlit nhằm hỗ trợ phân tích và ra quyết định.

1.3 Công nghệ và công cụ sử dụng

Các công nghệ và công cụ chính được sử dụng trong đề tài bao gồm:

- Ngôn ngữ lập trình: Python
- Hệ quản trị cơ sở dữ liệu: PostgreSQL
- Data Warehouse: Star Schema, ETL
- API thu thập dữ liệu: YouTube Data API v3
- Thư viện xử lý và phân tích dữ liệu: Pandas, NumPy
- Thư viện trực quan hóa dữ liệu: Matplotlib, Seaborn
- Thư viện Machine Learning: Scikit-learn, XGBoost
- Mô hình xử lý ngôn ngữ tự nhiên: XLM-RoBERTa
- Công cụ xây dựng ứng dụng và dashboard: Streamlit
- Kỹ thuật phân tích: EDA, Sentiment Analysis, Feature Engineering, Machine Learning

1.4 Ý nghĩa thực tiễn đề tài

Ý nghĩa thực tiễn của đề tài được thể hiện qua các khía cạnh sau:

- Hỗ trợ nhà sáng tạo nội dung và doanh nghiệp truyền thông hiểu rõ hơn về các yếu tố ảnh hưởng đến xu hướng Trending trên YouTube.
- Hỗ trợ phân tích hành vi và cảm xúc người dùng thông qua dữ liệu bình luận nhằm đánh giá mức độ quan tâm và phản hồi của cộng đồng.
- Góp phần xây dựng hệ thống lưu trữ và phân tích dữ liệu hiện đại dựa trên mô hình Data Warehouse.
- Hỗ trợ dự đoán xu hướng video Trending bằng các mô hình Machine Learning nhằm phục vụ cho hoạt động marketing và phát triển nội dung số.
- Giúp nâng cao khả năng trực quan hóa dữ liệu và hỗ trợ ra quyết định dựa trên dữ liệu thực tế thông qua dashboard và ứng dụng Streamlit.
- Tạo tiền đề cho các nghiên cứu mở rộng liên quan đến phân tích mạng xã hội, phân tích xu hướng nội dung và hệ thống gợi ý trong tương lai.

CHƯƠNG 2: NGHIÊN CỨU LÝ THUYẾT

2.1 Phân tích dữ liệu

Phân tích dữ liệu (Data Analytics) là quá trình thu thập, xử lý, làm sạch, khám phá và diễn giải dữ liệu nhằm phát hiện các thông tin hữu ích và tri thức tiềm ẩn phục vụ cho việc ra quyết định. Quá trình này giúp biến dữ liệu thô thành các insight có ý nghĩa, hỗ trợ doanh nghiệp và tổ chức trong việc đánh giá hiện trạng, tối ưu hoạt động và xây dựng chiến lược hiệu quả. Trong thực tiễn, phân tích dữ liệu thường được chia thành các cấp độ chính [1]:

- Phân tích mô tả (Descriptive Analytics): tập trung vào việc mô tả và tóm tắt dữ liệu trong quá khứ thông qua các chỉ số thống kê như trung bình, trung vị, độ lệch chuẩn và các biểu đồ trực quan, nhằm trả lời câu hỏi “Điều gì đã xảy ra?”.

- Phân tích chẩn đoán (Diagnostic Analytics): đi sâu phân tích dữ liệu để tìm hiểu nguyên nhân dẫn đến các hiện tượng đã xảy ra, trả lời câu hỏi “Vì sao điều đó xảy ra?”.

- Phân tích dự đoán (Predictive Analytics): sử dụng các mô hình thống kê và học máy để dự đoán xu hướng hoặc kết quả trong tương lai dựa trên dữ liệu lịch sử, trả lời câu hỏi “Điều gì có thể xảy ra tiếp theo?”.

Trong phạm vi đề tài này, phân tích dữ liệu được áp dụng để nghiên cứu các yếu tố ảnh hưởng đến khả năng video xuất hiện trong danh sách Trending trên YouTube. Phân tích mô tả được sử dụng để tổng hợp và đánh giá các đặc điểm của dữ liệu như lượt xem, lượt thích, lượt bình luận, thời lượng video và số lượng người đăng ký kênh. Phân tích chẩn đoán giúp làm rõ mối quan hệ giữa các chỉ số tương tác và khả năng trở thành Trending của video. Trên cơ sở đó, phân tích dự đoán được áp dụng nhằm xây dựng các mô hình học máy dự đoán khả năng video trở thành Trending dựa trên các đặc trưng đầu vào đã phân tích.

2.2 Phân tích khám phá dữ liệu (Exploratory Data Analysis)

Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA) là giai đoạn quan trọng và chiếm nhiều thời gian trong quy trình phân tích dữ liệu, được thực hiện nhằm hiểu rõ cấu trúc, đặc điểm và phân bố của tập dữ liệu trước khi xây dựng mô hình học máy. Thông qua EDA, các vấn đề thường gặp như dữ liệu thiếu, dữ liệu nhiễu, các giá trị ngoại lai (outlier) và mối quan hệ giữa các biến có thể được phát hiện và xử lý sớm, góp phần nâng cao chất lượng dữ liệu đầu vào [2].

Các kỹ thuật EDA phổ biến bao gồm thống kê mô tả, phân tích phân bố dữ liệu, phân tích tương quan và các phương pháp trực quan hóa dữ liệu bằng biểu đồ. Trong đề tài này, EDA được áp dụng trên tập dữ liệu YouTube được thu thập thông qua YouTube Data API v3 nhằm phân tích đặc điểm của các biến như lượt xem, lượt thích, lượt bình luận, thời lượng video, số lượng người đăng ký kênh và các chỉ số tương tác khác.

Cụ thể, EDA được sử dụng để:

- Phân tích phân bố của các chỉ số như lượt xem, lượt thích và lượt bình luận nhằm nhận diện các giá trị bất thường;
- So sánh đặc điểm giữa nhóm video Trending và Non-Trending thông qua các biểu đồ trực quan và thống kê mô tả;
- Đánh giá mối quan hệ giữa các chỉ số tương tác, thông tin kênh và khả năng trở thành Trending của video;
- Xác định các đặc trưng có ảnh hưởng đáng kể đến kết quả dự đoán để phục vụ cho quá trình xây dựng mô hình học máy.

Kết quả từ bước EDA giúp hiểu rõ hơn về đặc điểm dữ liệu YouTube, đồng thời hỗ trợ quá trình lựa chọn đặc trưng, xây dựng mô hình và đánh giá các yếu tố ảnh hưởng đến khả năng video trở thành Trending trong các phần tiếp theo của đề tài.

2.3 Kho dữ liệu (Data Warehouse)

Kho dữ liệu (Data Warehouse) là hệ thống lưu trữ dữ liệu tập trung được thiết kế nhằm hỗ trợ hoạt động phân tích, báo cáo và ra quyết định. Khác với các hệ thống xử lý giao dịch trực tuyến (OLTP), kho dữ liệu tập trung vào việc lưu trữ dữ liệu lịch sử đã được tích hợp từ nhiều nguồn khác nhau và được tối ưu hóa cho các truy vấn phân tích. Dữ liệu trong kho dữ liệu thường mang tính ổn định, được tổ chức theo chủ đề và có khả năng lưu trữ trong thời gian dài nhằm phục vụ cho việc đánh giá xu hướng và hỗ trợ ra quyết định [3].

2.3.1 Mô hình hình sao (Star Schema)

Mô hình hình sao (Star Schema) là mô hình tổ chức dữ liệu phổ biến nhất trong các hệ thống kho dữ liệu. Mô hình này bao gồm một bảng sự kiện (Fact Table) ở trung tâm và các bảng chiều (Dimension Table) được liên kết trực tiếp xung quanh. Bảng sự kiện lưu trữ các dữ liệu định lượng như doanh thu, số lượng hoặc các chỉ số thống kê, trong khi các bảng chiều lưu trữ thông tin mô tả giúp hỗ trợ quá trình phân tích dữ liệu [4].

Ưu điểm của Star Schema là cấu trúc đơn giản, dễ triển khai và dễ truy vấn. Do các bảng chiều được kết nối trực tiếp với bảng sự kiện nên số lượng phép kết nối (JOIN) được giảm đáng kể, giúp nâng cao hiệu năng truy vấn và phân tích dữ liệu.

2.3.2 Mô hình bông tuyết (Snowflake Schema)

Mô hình bông tuyết (Snowflake Schema) là phiên bản chuẩn hóa của mô hình hình sao. Trong mô hình này, các bảng chiều được tách thành nhiều bảng nhỏ hơn nhằm giảm sự dư thừa dữ liệu và tăng tính nhất quán trong quá trình lưu trữ [4].

Mặc dù giúp tiết kiệm không gian lưu trữ và giảm trùng lặp dữ liệu, Snowflake Schema làm tăng số lượng bảng cũng như số lượng phép kết nối khi truy vấn. Điều này có thể làm giảm hiệu năng xử lý đối với các tác vụ phân tích dữ liệu có khối lượng lớn.

2.3.3 Mô hình chòm sao sự kiện (Galaxy Schema)

Mô hình chòm sao sự kiện (Galaxy Schema), còn được gọi là Fact Constellation Schema, là mô hình mở rộng của Star Schema. Mô hình này sử dụng nhiều bảng sự kiện cùng chia sẻ các bảng chiều chung nhằm hỗ trợ các hệ thống có nhiều quy trình nghiệp vụ và yêu cầu phân tích phức tạp [4].

Galaxy Schema phù hợp với các hệ thống kho dữ liệu quy mô lớn, nơi dữ liệu được thu thập từ nhiều hoạt động khác nhau. Tuy nhiên, việc thiết kế và quản lý mô hình này thường phức tạp hơn so với Star Schema và Snowflake Schema.

Mỗi mô hình tổ chức dữ liệu trong kho dữ liệu đều có những ưu điểm và phạm vi ứng dụng riêng. Trong phạm vi đề tài này, mô hình hình sao (Star Schema) được lựa chọn để xây dựng kho dữ liệu cho hệ thống YouTube Data Warehouse. Nguyên nhân là do dữ liệu của đề tài chủ yếu phục vụ cho việc phân tích hiệu suất video, hành vi tương tác của người dùng và dự đoán khả năng video trở thành Trending. So với Snowflake Schema và Galaxy Schema, Star Schema có cấu trúc đơn giản, dễ triển khai và phù hợp với đặc điểm dữ liệu của đề tài. Đồng thời, mô hình này giúp giảm số lượng phép kết nối giữa các bảng khi truy vấn, từ đó nâng cao hiệu năng xử lý dữ liệu và hỗ trợ hiệu quả cho các hoạt động phân tích dữ liệu, trực quan hóa dữ liệu và huấn luyện mô hình học máy.

2.4 Quy trình (Extract – Transform – Load)

ETL (Extract – Transform – Load) là quy trình trích xuất, chuyển đổi và nạp dữ liệu, đóng vai trò quan trọng trong các hệ thống kho dữ liệu. Mục tiêu của ETL là thu thập dữ liệu từ nhiều nguồn khác nhau, xử lý và chuẩn hóa dữ liệu trước khi đưa vào kho dữ liệu để phục vụ cho các hoạt động phân tích và ra quyết định [5].

2.4.1 Giai đoạn Extract (Trích xuất dữ liệu)

Extract là giai đoạn đầu tiên trong quy trình ETL, thực hiện việc thu thập dữ liệu từ các nguồn dữ liệu khác nhau. Mục tiêu của giai đoạn này là đảm bảo dữ liệu được lấy đầy đủ và chính xác từ nguồn ban đầu trước khi đưa vào quá trình xử lý.

Trong phạm vi đề tài, dữ liệu được thu thập thông qua YouTube Data API v3 bao gồm thông tin video, thông tin kênh, dữ liệu thống kê video và dữ liệu bình luận của người dùng. Dữ liệu sau khi thu thập được lưu trữ dưới dạng dữ liệu thô (raw data) để phục vụ cho các bước xử lý tiếp theo.

2.4.2 Giai đoạn Transform (Chuyển đổi dữ liệu)

Transform là giai đoạn xử lý và chuẩn hóa dữ liệu sau khi được trích xuất từ nguồn dữ liệu. Đây là bước quan trọng nhằm nâng cao chất lượng dữ liệu trước khi đưa vào kho dữ liệu.

Các công việc thường được thực hiện trong giai đoạn này bao gồm xử lý dữ liệu thiếu, loại bỏ dữ liệu trùng lặp, chuẩn hóa kiểu dữ liệu, chuyển đổi định dạng thời gian và kiểm tra tính hợp lệ của dữ liệu. Ngoài ra, một số đặc trưng mới cũng có thể được xây dựng từ dữ liệu gốc nhằm phục vụ cho các hoạt động phân tích và huấn luyện mô hình học máy.

Trong đề tài này, dữ liệu YouTube được làm sạch và chuẩn hóa trước khi đưa vào hệ thống kho dữ liệu. Các trường dữ liệu như thời gian đăng tải, số lượng lượt xem, lượt thích và bình luận được chuyển đổi về định dạng phù hợp để phục vụ quá trình phân tích.

2.4.3 Giai đoạn Load (Nạp dữ liệu)

Load là giai đoạn cuối cùng của quy trình ETL, thực hiện việc nạp dữ liệu đã được xử lý vào kho dữ liệu. Mục tiêu của giai đoạn này là đảm bảo dữ liệu được lưu trữ nhất quán và sẵn sàng cho các hoạt động truy vấn, báo cáo và phân tích.

Trong đề tài, dữ liệu sau khi hoàn thành quá trình chuyển đổi được nạp vào hệ thống PostgreSQL theo mô hình hình sao (Star Schema). Các dữ liệu mô tả được lưu trữ

trong các bảng chiều, trong khi các dữ liệu thống kê và tương tác được lưu trữ trong các bảng sự kiện. Việc tổ chức dữ liệu theo cấu trúc này giúp tối ưu hiệu năng truy vấn và hỗ trợ hiệu quả cho quá trình phân tích dữ liệu cũng như xây dựng mô hình dự đoán Trending.

2.5 Hệ quản trị cơ sở dữ liệu PostgreSQL

PostgreSQL là hệ quản trị cơ sở dữ liệu quan hệ mã nguồn mở (Open Source Relational Database Management System - RDBMS) được sử dụng rộng rãi trong các hệ thống lưu trữ và phân tích dữ liệu nhờ tính ổn định, khả năng mở rộng và hiệu năng xử lý cao [6]. PostgreSQL hỗ trợ chuẩn SQL và cung cấp nhiều tính năng nâng cao như quản lý giao dịch (Transaction), chỉ mục (Index), khóa ngoại (Foreign Key), thủ tục lưu trữ (Stored Procedure) và cơ chế đảm bảo tính toàn vẹn dữ liệu.

Một trong những ưu điểm nổi bật của PostgreSQL là khả năng xử lý hiệu quả các tập dữ liệu lớn và hỗ trợ nhiều kiểu dữ liệu khác nhau, bao gồm dữ liệu có cấu trúc và bán cấu trúc. Bên cạnh đó, PostgreSQL cho phép thực hiện các truy vấn phức tạp với hiệu năng cao, phù hợp cho các hệ thống kho dữ liệu và các ứng dụng phân tích dữ liệu.

Trong lĩnh vực phân tích dữ liệu, PostgreSQL thường được sử dụng làm nền tảng lưu trữ dữ liệu nhờ khả năng hỗ trợ các thao tác tổng hợp, thống kê và truy vấn dữ liệu hiệu quả. Ngoài ra, hệ quản trị này còn cung cấp cơ chế quản lý dữ liệu đáng tin cậy, hỗ trợ nhiều người dùng truy cập đồng thời và đảm bảo tính nhất quán của dữ liệu trong quá trình vận hành.

Trong phạm vi đề tài này, PostgreSQL được sử dụng làm hệ quản trị cơ sở dữ liệu cho hệ thống YouTube Data Warehouse. Dữ liệu sau khi trải qua quy trình ETL sẽ được lưu trữ trong PostgreSQL theo mô hình hình sao (Star Schema). Việc sử dụng PostgreSQL giúp quản lý dữ liệu tập trung, hỗ trợ truy vấn nhanh chóng và tạo nền tảng cho các hoạt động phân tích dữ liệu, phân tích cảm xúc và xây dựng mô hình dự đoán khả năng video trở thành Trending.

2.6 Phân tích cảm xúc

Phân tích cảm xúc (Sentiment Analysis) là một bài toán thuộc lĩnh vực Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP), nhằm xác định cảm xúc hoặc thái độ của người dùng thông qua dữ liệu văn bản. Mục tiêu của phân tích cảm xúc là phân loại nội dung thành các nhóm như tích cực, tiêu cực hoặc trung tính. [7]

Trong môi trường mạng xã hội và nền tảng video trực tuyến như YouTube, bình luận của người dùng phản ánh mức độ quan tâm, đánh giá và phản ứng của cộng đồng đối với nội dung video. Vì vậy, việc phân tích cảm xúc từ bình luận có thể cung cấp thêm nhiều thông tin hữu ích trong quá trình đánh giá mức độ phổ biến của video.

Trong đề tài này, dữ liệu bình luận được thu thập thông qua YouTube Data API v3, sau đó được tiền xử lý nhằm loại bỏ ký tự đặc biệt, URL, emoji và các thành phần nhiễu trước khi đưa vào mô hình phân tích cảm xúc. Kết quả phân tích cảm xúc được sử dụng như một đặc trưng bổ sung phục vụ cho bài toán dự đoán video Trending.

2.6.1 XLM-RoBERTa

XLM-RoBERTa là mô hình Transformer đa ngôn ngữ được phát triển dựa trên kiến trúc RoBERTa và được huấn luyện trên tập dữ liệu văn bản với nhiều ngôn ngữ khác nhau [8]. Mô hình có khả năng hiểu ngữ cảnh và biểu diễn ngôn ngữ hiệu quả hơn so với các phương pháp truyền thống dựa trên từ khóa hoặc từ điển cảm xúc. Nhờ khả năng hỗ trợ đa ngôn ngữ, XLM-RoBERTa phù hợp với dữ liệu bình luận YouTube vì bình luận thường chứa nhiều ngôn ngữ khác nhau và có đặc điểm ngôn ngữ không chuẩn như viết tắt, slang hoặc emoji.

Trong đề tài này, mô hình XLM-RoBERTa được sử dụng để phân loại cảm xúc của bình luận người dùng thành các nhóm tích cực, tiêu cực và trung tính. Kết quả phân tích cảm xúc giúp bổ sung thêm thông tin về phản ứng của cộng đồng đối với video, từ đó hỗ trợ cải thiện hiệu quả của mô hình Machine Learning trong bài toán dự đoán video Trending trên YouTube.

2.7 Machine Learning trong dự đoán Trending

Học máy (Machine Learning) là một lĩnh vực thuộc trí tuệ nhân tạo (Artificial Intelligence - AI), cho phép hệ thống học từ dữ liệu và đưa ra dự đoán mà không cần lập trình tường minh cho từng trường hợp cụ thể. Thay vì xây dựng các quy tắc cố định, mô hình học máy có khả năng tự tìm ra các mẫu và mối quan hệ trong dữ liệu để đưa ra kết quả dự đoán [9].

2.7.1 Bài toán phân loại

Bài toán phân loại (Classification) là một trong những bài toán phổ biến của học máy, trong đó mô hình được huấn luyện để dự đoán nhãn của một đối tượng dựa trên

các đặc trưng đầu vào. Kết quả dự đoán thường thuộc một hoặc nhiều lớp đã được xác định trước.

Trong đề tài này, bài toán được xây dựng dưới dạng phân loại nhị phân, với mục tiêu dự đoán liệu một video có trở thành Trending hay không. Dựa trên các đặc trưng thu thập từ dữ liệu YouTube, mô hình sẽ học các mẫu và mối quan hệ trong dữ liệu để đưa ra kết quả dự đoán cho từng video.

2.7.2 Thuật toán XGBoost

XGBoost (Extreme Gradient Boosting) là một thuật toán học máy thuộc nhóm Ensemble Learning, được phát triển dựa trên kỹ thuật Gradient Boosting. Thuật toán sử dụng cây quyết định (Decision Tree) làm mô hình cơ sở và xây dựng nhiều cây theo cơ chế tuần tự nhằm cải thiện độ chính xác dự đoán. Trong quá trình huấn luyện, mỗi cây mới được tạo ra để học các sai số còn lại của các cây trước đó, từ đó từng bước nâng cao hiệu quả dự đoán của toàn bộ mô hình.

Khác với các thuật toán học máy truyền thống chỉ sử dụng một mô hình duy nhất, XGBoost kết hợp kết quả của nhiều cây quyết định để tạo thành mô hình dự đoán cuối cùng. Nhờ cơ chế này, thuật toán có khả năng khai thác tốt các mối quan hệ phi tuyến giữa các đặc trưng đầu vào và biến mục tiêu, đồng thời giảm ảnh hưởng của sai số từ từng mô hình riêng lẻ.

Đối với XGBoost, giá trị dự đoán của một quan sát được xác định bằng tổng kết quả dự đoán của tất cả các cây quyết định trong mô hình. Công thức dự đoán được biểu diễn như sau:

Công thức dự đoán XGBoost:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (2.1)$$

- $\hat{y}_i$ giá trị dự đoán của quan sát thứ (i) .
- f_k cây quyết định thứ (K) trong mô hình.
- x_i là tập đặc trưng đầu vào của quan sát thứ (i) .
- K là tổng số cây quyết định được xây dựng trong mô hình.

Công thức (2.1) cho thấy kết quả dự đoán cuối cùng được tạo thành từ sự kết hợp của nhiều cây quyết định. Mỗi cây mới được xây dựng nhằm hiệu chỉnh sai số của các

cây trước đó, giúp mô hình đạt độ chính xác cao hơn so với việc sử dụng một cây quyết định đơn lẻ.

Một trong những ưu điểm nổi bật của XGBoost là việc bổ sung thành phần điều chuẩn (Regularization) vào hàm mục tiêu nhằm kiểm soát độ phức tạp của mô hình và hạn chế hiện tượng quá khớp (Overfitting). Hàm mục tiêu của XGBoost bao gồm hai thành phần chính là hàm mất mát (Loss Function) và thành phần điều chuẩn (Regularization Term). Dạng tổng quát của hàm mục tiêu được thể hiện như sau:

Hàm mục tiêu XGBoost:

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (2.2)$$

- Obj là giá trị hàm mục tiêu (Objective Function) của mô hình XGBoost.
- $l(y_i, \hat{y}_i)$ là hàm mất mát dùng để đo lường sai lệch giữa giá trị thực tế và giá trị dự đoán.
- $\Omega(f_k)$ là thành phần điều chuẩn (Regularization Term) của cây quyết định thứ (K) , giúp kiểm soát độ phức tạp của mô hình và hạn chế hiện tượng quá khớp.
- n là số lượng quan sát trong tập dữ liệu.
- K là tổng số cây quyết định được sử dụng trong mô hình.

Thông qua hàm mục tiêu này, XGBoost không chỉ tập trung vào việc giảm sai số dự đoán mà còn hướng đến việc xây dựng mô hình có khả năng tổng quát hóa tốt trên dữ liệu mới. Điều này giúp hạn chế hiện tượng mô hình học quá mức trên tập huấn luyện và cải thiện hiệu suất khi áp dụng vào dữ liệu thực tế.

Bên cạnh cơ chế Boosting và Regularization, XGBoost còn hỗ trợ nhiều kỹ thuật tối ưu khác như xử lý dữ liệu thiếu, cắt tỉa cây quyết định (Tree Pruning), tính toán song song và tối ưu hóa bộ nhớ. Nhờ đó, thuật toán có thể huấn luyện hiệu quả trên các tập dữ liệu lớn với thời gian xử lý ngắn hơn so với nhiều phương pháp Ensemble Learning khác.

Với những ưu điểm như khả năng dự đoán chính xác, xử lý tốt dữ liệu dạng bảng, hỗ trợ dữ liệu có nhiều đặc trưng và khả năng chống quá khớp hiệu quả, XGBoost được lựa chọn trong nghiên cứu này để xây dựng mô hình dự đoán khả năng video xuất hiện trong danh sách Trending trên nền tảng YouTube.

2.7.3 Feature Engineering

Feature Engineering là quá trình tạo mới, biến đổi hoặc lựa chọn các đặc trưng nhằm nâng cao chất lượng dữ liệu đầu vào cho mô hình học máy. Chất lượng của đặc trưng có ảnh hưởng trực tiếp đến hiệu quả dự đoán của mô hình.

Trong thực tế, dữ liệu thu thập được thường chưa phản ánh đầy đủ các đặc điểm cần thiết cho quá trình học. Do đó, việc xây dựng các đặc trưng mới giúp mô hình khai thác thông tin hiệu quả hơn và cải thiện khả năng dự đoán.

Trong đề tài này, một số đặc trưng được xây dựng từ dữ liệu gốc như tỷ lệ lượt thích trên lượt xem (Like Rate), tỷ lệ bình luận trên lượt xem (Comment Rate) và các đặc trưng liên quan đến thời gian đăng tải video. Ngoài ra, kết quả phân tích cảm xúc từ bình luận người dùng cũng được sử dụng như một đặc trưng bổ sung phục vụ cho quá trình huấn luyện mô hình.

2.7.4 Các chỉ số đánh giá mô hình

Đối với bài toán phân loại, việc đánh giá hiệu quả mô hình không chỉ dựa trên số lượng dự đoán đúng mà còn cần xem xét khả năng nhận diện chính xác từng lớp dữ liệu. Vì vậy, nhiều chỉ số đánh giá khác nhau được sử dụng nhằm phản ánh toàn diện hiệu suất của mô hình.

Độ chính xác (Accuracy) là tỷ lệ số lượng dự đoán đúng trên tổng số mẫu dữ liệu. Chỉ số này phản ánh mức độ chính xác tổng thể của mô hình. Tuy nhiên, Accuracy có thể không phản ánh đầy đủ hiệu quả mô hình khi dữ liệu bị mất cân bằng giữa các lớp. Ví dụ, nếu phần lớn dữ liệu thuộc lớp Non-Trending thì mô hình vẫn có thể đạt Accuracy cao mặc dù khả năng phát hiện video Trending không tốt.

Độ chính xác dương (Precision) là tỷ lệ các mẫu được dự đoán thuộc lớp Trending thực sự là Trending. Chỉ số này phản ánh độ tin cậy của các dự đoán do mô hình đưa ra. Precision cao cho thấy phần lớn các video được dự đoán là Trending đều thực sự có khả năng trở thành Trending.

Độ bao phủ (Recall) là tỷ lệ các video Trending thực tế được mô hình nhận diện đúng. Chỉ số này phản ánh khả năng phát hiện đầy đủ các video Trending trong tập dữ liệu. Recall cao giúp giảm số lượng video Trending bị bỏ sót bởi mô hình.

Điểm F1 (F1-score) là trung bình điều hòa giữa Precision và Recall. Chỉ số này được sử dụng khi cần đánh giá sự cân bằng giữa khả năng dự đoán chính xác và khả

năng phát hiện đầy đủ các mẫu thuộc lớp mục tiêu. F1-score thường được sử dụng trong các bài toán phân loại khi cần xem xét đồng thời cả Precision và Recall.

Trong đề tài này, dữ liệu được xây dựng dưới dạng bài toán phân loại nhị phân giữa video Trending và Non-Trending. Do mục tiêu của hệ thống là nhận diện chính xác các video có khả năng trở thành Trending, bên cạnh Accuracy, các chỉ số Precision, Recall và F1-score cũng được đặc biệt quan tâm. Trong đó, Recall giúp đánh giá khả năng phát hiện các video Trending, Precision phản ánh độ tin cậy của các dự đoán Trending, còn F1-score được sử dụng như một chỉ số tổng hợp để đánh giá sự cân bằng giữa hai yếu tố này. Các chỉ số trên sẽ được sử dụng trong Chương 4 để đánh giá và so sánh hiệu quả giữa các mô hình Machine Learning, từ đó lựa chọn mô hình phù hợp nhất cho hệ thống.

2.8 Trực quan hóa dữ liệu và Streamlit

2.8.1 Trực quan hóa dữ liệu

Trực quan hóa dữ liệu (Data Visualization) là quá trình biểu diễn dữ liệu dưới dạng đồ họa nhằm giúp người dùng dễ dàng quan sát, phân tích và hiểu được các thông tin quan trọng từ dữ liệu [10]. Thay vì trình bày dữ liệu dưới dạng bảng số liệu, các biểu đồ trực quan giúp phát hiện xu hướng, mẫu dữ liệu và mối quan hệ giữa các biến một cách nhanh chóng và hiệu quả hơn.

Trong quá trình phân tích dữ liệu, trực quan hóa dữ liệu đóng vai trò quan trọng trong việc khám phá dữ liệu, phát hiện các giá trị bất thường và hỗ trợ quá trình ra quyết định. Các dạng biểu đồ thường được sử dụng bao gồm biểu đồ cột, biểu đồ đường, biểu đồ phân phối, biểu đồ hộp (Boxplot) và bản đồ nhiệt (Heatmap).

Trong đề tài này, trực quan hóa dữ liệu được áp dụng trong giai đoạn phân tích khám phá dữ liệu (EDA) nhằm đánh giá đặc điểm của dữ liệu YouTube và phân tích sự khác biệt giữa nhóm video Trending và Non-Trending. Các thư viện Matplotlib và Seaborn được sử dụng để xây dựng các biểu đồ phục vụ cho quá trình phân tích và đánh giá dữ liệu.

2.8.2 Streamlit

Streamlit là một framework mã nguồn mở được phát triển dành cho ngôn ngữ Python, cho phép xây dựng các ứng dụng web và dashboard trực quan một cách nhanh chóng mà không yêu cầu nhiều kiến thức về phát triển web [11]. Streamlit hỗ trợ tích hợp trực tiếp với các thư viện phân tích dữ liệu và học máy như Pandas, NumPy,

Matplotlib, Scikit-learn và XGBoost, giúp đơn giản hóa quá trình triển khai các ứng dụng phân tích dữ liệu.

Trong đề tài này, Streamlit được sử dụng để xây dựng dashboard trực quan cho hệ thống YouTube Analytics. Dashboard hỗ trợ hiển thị các thông tin như thống kê video Trending, kết quả phân tích dữ liệu, kết quả phân tích cảm xúc và dự đoán từ mô hình học máy. Người dùng có thể tương tác trực tiếp với hệ thống thông qua giao diện web, từ đó hỗ trợ quá trình theo dõi và đánh giá dữ liệu một cách thuận tiện hơn.

CHƯƠNG 3: HIỆN THỰC HÓA NGHIÊN CỨU

3.1 Quy trình nghiên cứu tổng thể

Quy trình thực hiện đề tài được xây dựng nhằm giải quyết bài toán phân tích và dự đoán khả năng video trở thành Trending trên nền tảng YouTube thông qua việc kết hợp giữa Data Warehouse, phân tích dữ liệu, xử lý ngôn ngữ tự nhiên và Machine Learning. Toàn bộ quá trình nghiên cứu được triển khai theo một chuỗi các bước liên kết với nhau, bắt đầu từ thu thập dữ liệu, xây dựng kho dữ liệu, phân tích dữ liệu, xây dựng mô hình dự đoán và cuối cùng là triển khai ứng dụng thử nghiệm.

Dữ liệu được thu thập từ YouTube Data API v3 bằng ngôn ngữ Python. Quá trình thu thập tập trung vào các thông tin liên quan đến video, kênh và bình luận của người dùng. Các video được lựa chọn từ nhiều lĩnh vực khác nhau nhằm đảm bảo tính đa dạng của tập dữ liệu, bao gồm giải trí, công nghệ, trò chơi điện tử, âm thực và vlog. Trong quá trình thu thập, dữ liệu được lưu dưới dạng dữ liệu thô để phục vụ cho các bước xử lý tiếp theo.

Sau khi hoàn thành giai đoạn thu thập, dữ liệu được đưa vào quy trình ETL để chuẩn hóa và lưu trữ trong hệ thống Data Warehouse. Tại bước này, dữ liệu được kiểm tra và xử lý các trường hợp thiếu dữ liệu, dữ liệu trùng lặp hoặc dữ liệu không hợp lệ. Các thuộc tính được chuẩn hóa về định dạng nhằm đảm bảo tính nhất quán giữa các nguồn dữ liệu khác nhau. Kết quả sau xử lý được lưu trữ trên PostgreSQL theo mô hình Star Schema, tạo nền tảng cho việc truy vấn, phân tích và mở rộng dữ liệu trong các giai đoạn tiếp theo.

Song song với quá trình xử lý dữ liệu, dữ liệu bình luận người dùng được tách riêng để thực hiện phân tích cảm xúc. Các bình luận được làm sạch nhằm loại bỏ ký tự đặc biệt, liên kết, biểu tượng cảm xúc và các thành phần không cần thiết. Sau đó, mô hình XLM-RoBERTa được sử dụng để xác định cảm xúc của từng bình luận theo ba nhóm gồm tích cực, tiêu cực và trung lập. Kết quả phân loại cảm xúc được tổng hợp và liên kết trở lại với dữ liệu video nhằm tạo thêm các đặc trưng phục vụ cho quá trình huấn luyện mô hình.


Khi dữ liệu đã được chuẩn hóa và bổ sung đầy đủ các thuộc tính cần thiết, quá trình phân tích khám phá dữ liệu được thực hiện. Mục đích của giai đoạn này là tìm hiểu đặc điểm của tập dữ liệu, đánh giá phân bố dữ liệu và xác định các yếu tố có khả năng ảnh hưởng đến việc một video xuất hiện trong danh sách Trending. Các chỉ số như lượt

xem, lượt thích, lượt bình luận, tỷ lệ tương tác và cảm xúc người dùng được trực quan hóa thông qua nhiều dạng biểu đồ khác nhau nhằm hỗ trợ việc nhận diện xu hướng và phát hiện các đặc trưng có giá trị dự đoán.

Dựa trên kết quả phân tích, các đặc trưng phục vụ cho bài toán Machine Learning được lựa chọn và xây dựng. Bên cạnh các thuộc tính gốc thu thập từ YouTube, đề tài còn tạo thêm một số đặc trưng mới phản ánh mức độ tương tác của người dùng đối với video. Các đặc trưng này được sử dụng làm dữ liệu đầu vào cho mô hình dự đoán Trending.

Tập dữ liệu sau khi hoàn thiện được chia thành tập huấn luyện và tập kiểm tra để xây dựng mô hình Machine Learning. Trong phạm vi đề tài, thuật toán XGBoost được lựa chọn do khả năng xử lý dữ liệu dạng bảng tốt, hiệu quả dự đoán cao và phù hợp với bài toán phân loại. Quá trình huấn luyện được thực hiện trên tập dữ liệu đã xử lý, sau đó đánh giá bằng các chỉ số Accuracy, Precision, Recall và F1-score nhằm đo lường hiệu quả dự đoán của mô hình.

Kết quả của mô hình được tích hợp vào ứng dụng web xây dựng bằng Streamlit. Ứng dụng cho phép người dùng theo dõi dữ liệu thống kê, quan sát các biểu đồ phân tích và thử nghiệm chức năng dự đoán Trending thông qua các thông số đầu vào. Việc triển khai ứng dụng giúp kiểm chứng khả năng hoạt động của mô hình trong môi trường thực tế và hỗ trợ trực quan hóa kết quả nghiên cứu.



Hình 3.1 Quy trình nghiên cứu tổng thể

3.2. Thu thập dữ liệu

3.2.1. Nguồn dữ liệu

Nguồn dữ liệu chính được sử dụng trong đề tài là YouTube Data API v3. Đây là API chính thức do Google cung cấp, cho phép truy xuất các thông tin liên quan đến video, kênh và hoạt động tương tác của người dùng trên nền tảng YouTube.

Thông qua YouTube Data API v3, đề tài tiến hành thu thập dữ liệu từ nhiều nhóm nội dung khác nhau nhằm đảm bảo tính đa dạng của tập dữ liệu. Các nhóm nội dung được lựa chọn bao gồm Entertainment, Gaming, Technology, Food và Vlog. Việc thu thập dữ liệu từ nhiều lĩnh vực giúp hạn chế hiện tượng dữ liệu chỉ tập trung vào một chủ đề cụ thể, từ đó nâng cao khả năng tổng quát hóa của mô hình dự đoán.

Dữ liệu thu thập được chia thành ba nhóm chính gồm dữ liệu video, dữ liệu kênh và dữ liệu bình luận.

Dữ liệu video bao gồm các thông tin phản ánh mức độ phổ biến và tương tác của video như mã video, tiêu đề, thời gian đăng tải, số lượt xem, số lượt thích, số lượt bình luận và danh mục nội dung.

Dữ liệu kênh bao gồm các thông tin liên quan đến chủ sở hữu video như mã kênh, tên kênh, số lượng người đăng ký và tổng số video đã công bố trên kênh.

Dữ liệu bình luận bao gồm nội dung bình luận của người dùng được đăng bên dưới các video. Nhóm dữ liệu này được sử dụng cho bài toán phân tích cảm xúc nhằm đánh giá phản hồi của cộng đồng đối với từng video. Sau khi thu thập, dữ liệu được lưu trữ dưới dạng các tệp CSV và được sử dụng làm dữ liệu đầu vào cho quá trình ETL, xây dựng kho dữ liệu (Data Warehouse) và huấn luyện mô hình học máy.


3.2.2. Phương pháp thu thập dữ liệu

Quá trình thu thập dữ liệu được thực hiện bằng ngôn ngữ Python thông qua thư viện Google API Client kết hợp với YouTube Data API v3. Để xây dựng tập dữ liệu phục vụ cho bài toán phân loại, đề tài tiến hành thu thập dữ liệu từ hai nguồn khác nhau trên nền tảng YouTube.

Đối với nhóm video Trending, dữ liệu được thu thập thông qua API cung cấp danh sách các video đang nằm trong mục Trending (Most Popular) của YouTube. Các video này được gán nhãn Trending = 1 và được xem là nhóm dữ liệu mục tiêu của bài toán dự đoán.

Đối với nhóm video Non-Trending, dữ liệu được thu thập thông qua Search API bằng nhiều từ khóa thuộc các lĩnh vực như giải trí, công nghệ, trò chơi điện tử, âm thực và vlog. Các video này không xuất hiện trong danh sách Trending tại thời điểm thu thập và được gán nhãn Trending = 0.

Sau khi thu thập danh sách video từ hai nguồn trên, hệ thống tiếp tục thực hiện các truy vấn bổ sung để lấy thông tin chi tiết của từng video như lượt xem, lượt thích, lượt bình luận, thời gian đăng tải và danh mục nội dung. Những thông tin này được sử dụng làm dữ liệu đầu vào cho quá trình phân tích và xây dựng mô hình Machine Learning.



Hình 3.2 Quy trình thu thập dữ liệu từ YouTube Data API v3

3.2.3. Thống kê bộ dữ liệu thu thập

Quá trình thu thập dữ liệu được thực hiện trong khoảng thời gian từ ngày 01/05/2026 đến ngày 20/05/2026 thông qua YouTube Data API v3. Dữ liệu được thu thập từ nhiều nhóm nội dung khác nhau như Entertainment, Gaming, Technology, Food và Vlog nhằm đảm bảo tính đa dạng của tập dữ liệu. Sau quá trình thu thập, dữ liệu được lưu trữ thành bốn tập dữ liệu riêng biệt gồm Video Dataset, Channel Dataset, Video Statistics Dataset và Comment Dataset trước khi được kết hợp ở trong quy trình ETL.

Bảng 3.1 Mô tả tập dữ liệu Video

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	159.483
Số cột	12

Bảng 3.2 Chi tiết các thuộc tính của Video Dataset

Tên biến	Ý nghĩa
video_id	Mã video
title	Tiêu đề video
description	Mô tả video
channel_id	Mã kênh
channel_title	Tên kênh
publish_time	Thời gian đăng tải
thumbnail	Ảnh đại diện video
country_code	Mã quốc gia
keyword	Từ khóa thu thập
topic	Chủ đề nội dung
source	Nguồn thu thập

Bảng 3.3 Mô tả tập dữ liệu Channel

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	83.173
Số cột	9

Bảng 3.4 Chi tiết các thuộc tính của Channel Dataset

Tên biến	Ý nghĩa
channel_id	Mã kênh
channel_title	Tên kênh
custom_url	Đường dẫn của kênh
channel_description	Mô tả kênh
published_at	Ngày tạo kênh
country	Quốc gia của kênh
subscriber_count	Số lượng người đăng ký
view_count	Tổng số lượt xem của kênh
video_count	Tổng số video đã đăng tải

Bảng 3.3 Mô tả tập dữ liệu Video Statistics

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	1.171.067
Số cột	14

Bảng 3.4 Chi tiết các thuộc tính của Video Statistics Dataset

Tên biến	Ý nghĩa
video_id	Mã video
is_trending	Nhãn Trending (1: Trending, 0: Non-Trending)
views	Số lượt xem
likes	Số lượt thích
comments	Số lượt bình luận
duration_seconds	Thời lượng video (giây)
definition	Chất lượng video (HD/SD)
caption	Trạng thái phụ đề
licensed_content	Nội dung có bản quyền
category_id	Mã danh mục video
default_language	Ngôn ngữ mặc định
default_audio_language	Ngôn ngữ âm thanh mặc định
tags	Các thẻ (tags) của video
snapshot_time	Thời điểm ghi nhận thống kê

Bảng 3.5 Mô tả tập dữ liệu Comment

Thuộc tính	Mô tả
Nguồn dữ liệu	YouTube Data API v3
Định dạng	CSV
Số dòng	7.351.883
Số cột	7

Bảng 3.6 Chi tiết các thuộc tính của Comment Dataset

Tên biến	Ý nghĩa
comment_id	Mã định danh bình luận
video_id	Mã video chứa bình luận
author_name	Tên người bình luận
comment_text	Nội dung bình luận
like_count	Số lượt thích của bình luận
published_at	Thời gian đăng bình luận
updated_at	Thời gian cập nhật bình luận

Bảng 3.7 Thống kê mô tả các thuộc tính chính của bộ dữ liệu


Chỉ số	Views	Likes	Comments	Duration (s)	Subscriber Count
Count	1,171,067	1,171,067	1,171,067	1,171,067	1,171,067
Mean	8,456,134	91,403	2,534	1,565.43	2,094,982
Std	94,405,940	624,425	69,065	5,729.79	10,192,749
Min	1	0	0	0	0
25%	6,583	70	2	34	4,580
50%	83,182	1,594	59	161	97,800
75%	1,223,812	18,915	467	1,084	909,000
Max	9,025,777,000	56,253,090	15,924,940	416,704	490,000,000

3.3 Xây dựng hệ thống Data Warehouse và quy trình ETL

Dữ liệu thu thập từ YouTube bao gồm nhiều nhóm thông tin khác nhau như video, kênh và bình luận. Để phục vụ cho các bước phân tích dữ liệu và xây dựng mô hình dự đoán, đề tài xây dựng hệ thống Data Warehouse theo mô hình Star Schema kết hợp với quy trình ETL. Việc tổ chức dữ liệu theo mô hình này giúp giảm sự phân tán dữ liệu, hỗ trợ truy vấn nhanh hơn và tạo nguồn dữ liệu ổn định cho các giai đoạn xử lý tiếp theo.

3.3.1 Thiết kế Star Schema

Để phục vụ cho nhu cầu lưu trữ và phân tích dữ liệu YouTube, đề tài xây dựng Data Warehouse theo mô hình Star Schema. Đây là mô hình được sử dụng phổ biến trong các hệ thống kho dữ liệu nhờ cấu trúc đơn giản, dễ mở rộng và tối ưu cho các truy vấn phân tích. Trong mô hình này, dữ liệu được tổ chức thành một bảng sự kiện (Fact Table) nằm ở trung tâm và các bảng chiều (Dimension Tables) bao quanh, giúp giảm độ phức tạp khi truy vấn và hỗ trợ tổng hợp dữ liệu hiệu quả.



Hình 3.3 Sơ đồ Schema được xây dựng cho hệ thống

Bảng `fact_video_metrics` trong hệ thống đóng vai trò là bảng sự kiện trung tâm. Bảng này lưu trữ các chỉ số phản ánh hiệu suất hoạt động của video tại thời điểm thu thập dữ liệu như số lượt xem, số lượt thích, số lượt bình luận và trạng thái Trending của video. Ngoài ra, bảng còn lưu thông tin về thời điểm ghi nhận dữ liệu và nguồn dữ liệu phục vụ cho quá trình phân tích sau này. Các khóa ngoại trong bảng được sử dụng để liên kết với các bảng chiều tương ứng.

Bảng `dim_video` lưu trữ các thông tin mô tả liên quan đến video. Dữ liệu bao gồm tiêu đề video, mô tả, thời gian đăng tải, thời lượng, danh mục nội dung, ngôn ngữ mặc định và các thông tin đặc trưng khác của video. Đây là bảng chiều có số lượng thuộc tính lớn nhất trong hệ thống vì chứa phần lớn thông tin mô tả phục vụ cho quá trình phân tích nội dung video.

Bảng `dim_channel` lưu trữ thông tin về kênh sở hữu video như tên kênh, mô tả kênh, ngày tạo kênh, số lượng người đăng ký, tổng số lượt xem và số lượng video đã công bố. Các thông tin này được sử dụng để đánh giá mức độ ảnh hưởng của kênh đối với khả năng xuất hiện trong danh sách Trending.

Bảng `dim_time` được xây dựng nhằm hỗ trợ phân tích dữ liệu theo yếu tố thời gian. Thay vì lưu trực tiếp các thuộc tính thời gian trong bảng sự kiện, hệ thống tách riêng

thành bảng chiều thời gian với các thuộc tính như năm, quý, tháng, tuần, ngày và giờ. Cách tổ chức này giúp thực hiện các truy vấn thống kê theo từng mốc thời gian thuận tiện hơn.

Bảng `dim_topic` lưu trữ thông tin về chủ đề nội dung của video. Việc tách riêng chủ đề thành một bảng chiều giúp hệ thống dễ dàng mở rộng số lượng chủ đề trong tương lai và hỗ trợ phân tích mức độ phổ biến của từng nhóm nội dung trên nền tảng YouTube.


Bảng `fact_comment` trong hệ thống còn sử dụng bảng để lưu trữ dữ liệu bình luận của người dùng. Bảng này chứa nội dung bình luận, thông tin tác giả bình luận, số lượng lượt thích và thời gian đăng bình luận. Dữ liệu từ bảng này được sử dụng cho quá trình phân tích cảm xúc và xây dựng các đặc trưng liên quan đến phản hồi của người dùng đối với video.

Thông qua mô hình Star Schema, dữ liệu được tổ chức theo hướng tách biệt giữa dữ liệu mô tả và dữ liệu sự kiện, giúp giảm sự dư thừa dữ liệu và nâng cao hiệu quả truy vấn. Cấu trúc này cũng tạo điều kiện thuận lợi cho các bước phân tích khám phá dữ liệu, phân tích cảm xúc và xây dựng mô hình Machine Learning được trình bày trong các phần tiếp theo của đề tài.

3.3.2 Quy trình ETL

Sau khi dữ liệu được thu thập từ YouTube Data API v3, các dữ liệu thô được lưu trữ dưới dạng các tệp CSV bao gồm thông tin video, kênh, thống kê video và bình luận. Để dữ liệu có thể sử dụng trong hệ thống Data Warehouse, đề tài xây dựng quy trình ETL (Extract – Transform – Load) nhằm chuyển đổi dữ liệu từ dạng thu thập ban đầu sang cấu trúc Star Schema đã thiết kế.

ETL Process



Hình 3.4 Sơ đồ quy trình ETL

Ở giai đoạn Extract, dữ liệu được trích xuất từ các tệp dữ liệu nguồn gồm `raw_video.csv`, `raw_channel.csv`, `raw_comment.csv` và `raw_video_stats.csv`. Đây là các tệp dữ liệu được tạo ra sau quá trình thu thập dữ liệu từ YouTube Data API v3 và đóng vai trò là nguồn dữ liệu đầu vào cho toàn bộ hệ thống.

Tiếp theo, dữ liệu được đưa vào giai đoạn Transform. Tại bước này, các tiến trình chuyển đổi được xây dựng nhằm tạo ra các bảng chiều và bảng sự kiện phục vụ cho Data Warehouse. Dữ liệu video được xử lý để xây dựng bảng `dim_video`, dữ liệu kênh được chuyển đổi thành bảng `dim_channel`, dữ liệu thời gian được tách thành bảng `dim_time` và thông tin chủ đề nội dung được sử dụng để xây dựng bảng `dim_topic`. Đồng thời, dữ liệu thống kê video được tổng hợp để tạo thành bảng `fact_video_metrics`.

Trong quá trình chuyển đổi, hệ thống thực hiện một số thao tác xử lý dữ liệu như loại bỏ các bản ghi trùng lặp, chuẩn hóa kiểu dữ liệu, chuyển đổi định dạng thời gian và kiểm tra tính hợp lệ của dữ liệu trước khi tạo các bảng trong kho dữ liệu. Các bước này giúp đảm bảo tính nhất quán giữa các bảng và hạn chế sai lệch trong quá trình phân tích.

Sau khi hoàn thành việc xây dựng các bảng chiều và bảng sự kiện, dữ liệu được nạp vào PostgreSQL ở giai đoạn Load. Các bảng được lưu trữ theo cấu trúc Star Schema và được sử dụng làm nguồn dữ liệu chính cho các hoạt động phân tích, trực quan hóa và xây dựng mô hình dự đoán.

Việc tổ chức dữ liệu thông qua quy trình ETL giúp tách biệt dữ liệu thu thập ban đầu với dữ liệu phục vụ phân tích, đồng thời tạo ra một cấu trúc dữ liệu thống nhất cho toàn bộ hệ thống.

3.3.3 Lưu trữ dữ liệu trên PostgreSQL

Sau khi hoàn thành quá trình xây dựng các bảng chiều và bảng sự kiện thông qua quy trình ETL, dữ liệu được nạp vào hệ quản trị cơ sở dữ liệu PostgreSQL để hình thành kho dữ liệu phục vụ cho đề tài.

PostgreSQL được lựa chọn do là hệ quản trị cơ sở dữ liệu mã nguồn mở, có khả năng lưu trữ dữ liệu lớn, hỗ trợ tốt các truy vấn phân tích và dễ dàng tích hợp với các công cụ xử lý dữ liệu trong Python. Bên cạnh đó, PostgreSQL cũng hỗ trợ đầy đủ các cơ chế khóa chính, khóa ngoại và chỉ mục, giúp đảm bảo tính toàn vẹn dữ liệu trong quá trình vận hành hệ thống.

Dữ liệu sau khi xử lý được nạp vào các bảng tương ứng trong Data Warehouse bao gồm các bảng chiều `dim_video`, `dim_channel`, `dim_time`, `dim_topic` và bảng sự kiện `fact_video_metrics`. Ngoài ra, dữ liệu bình luận được lưu trữ trong bảng `fact_comment` nhằm phục vụ cho các bài toán phân tích cảm xúc và khai thác phản hồi của người dùng.

Việc tổ chức dữ liệu theo mô hình Star Schema giúp đơn giản hóa các truy vấn phân tích và giảm mức độ dư thừa dữ liệu. Thông qua các mối quan hệ giữa bảng sự kiện và các bảng chiều, hệ thống có thể dễ dàng thực hiện các truy vấn thống kê theo thời gian, chủ đề nội dung, kênh YouTube hoặc các chỉ số tương tác của video.

Sau khi được lưu trữ trong PostgreSQL, dữ liệu trở thành nguồn dữ liệu tập trung cho toàn bộ hệ thống. Các bước phân tích khám phá dữ liệu, phân tích cảm xúc bình luận và xây dựng mô hình Machine Learning đều sử dụng dữ liệu được truy xuất trực tiếp từ Data Warehouse.

3.4 Tiền xử lý và xây dựng đặc trưng

Sau khi dữ liệu được thu thập và lưu trữ trong hệ thống Data Warehouse, dữ liệu vẫn cần được xử lý trước khi đưa vào quá trình phân tích và xây dựng mô hình Machine Learning. Dữ liệu thu thập từ YouTube bao gồm nhiều loại thông tin khác nhau như dữ liệu video, dữ liệu kênh và dữ liệu bình luận. Trong quá trình thu thập, một số trường dữ liệu có thể tồn tại sự không nhất quán về định dạng, dữ liệu trùng lặp hoặc các thuộc tính chưa phù hợp để sử dụng trực tiếp cho bài toán dự đoán.

Bên cạnh việc làm sạch và chuẩn hóa dữ liệu, đề tài còn thực hiện phân tích cảm xúc đối với dữ liệu bình luận người dùng nhằm khai thác thêm thông tin về phản hồi của cộng đồng đối với từng video. Kết quả phân tích cảm xúc được sử dụng để xây dựng các đặc trưng mới, góp phần bổ sung thêm thông tin cho mô hình dự đoán Trending.

3.4.1 Làm sạch và chuẩn hóa dữ liệu

Dữ liệu thu thập từ YouTube Data API v3 được lưu trữ dưới nhiều nhóm dữ liệu khác nhau bao gồm dữ liệu video, dữ liệu kênh, dữ liệu thống kê video và dữ liệu bình luận. Trước khi sử dụng cho quá trình phân tích và xây dựng mô hình, dữ liệu cần được kiểm tra và chuẩn hóa nhằm đảm bảo tính nhất quán giữa các nguồn dữ liệu.

Một trong những bước đầu tiên được thực hiện là loại bỏ các bản ghi trùng lặp. Trong quá trình thu thập dữ liệu, cùng một video hoặc kênh có thể xuất hiện nhiều lần do được thu thập từ nhiều nguồn khác nhau hoặc được cập nhật ở nhiều thời điểm khác nhau. Các bản ghi trùng lặp được phát hiện dựa trên khóa định danh của từng đối tượng như video_id, channel_id hoặc comment_id. Sau khi kiểm tra, hệ thống chỉ giữ lại một bản ghi hợp lệ cho mỗi đối tượng nhằm tránh ảnh hưởng đến kết quả phân tích.

Bên cạnh việc loại bỏ dữ liệu trùng lặp, các thuộc tính số cũng được chuẩn hóa về cùng một kiểu dữ liệu. Các trường như số lượt xem, số lượt thích, số lượt bình luận, số lượng người đăng ký và số lượng video của kênh được chuyển đổi sang kiểu dữ liệu số nguyên nhằm đảm bảo khả năng tính toán và thống kê trong các bước tiếp theo.

Đối với các thuộc tính thời gian, dữ liệu được chuẩn hóa về định dạng datetime để thuận tiện cho việc phân tích theo thời gian. Các trường như thời gian đăng video, thời gian thu thập dữ liệu và thời gian đăng bình luận được chuyển đổi về cùng định dạng nhằm đảm bảo tính nhất quán trong toàn bộ hệ thống.

Thuộc tính duration được YouTube cung cấp dưới dạng chuỗi ký tự theo chuẩn ISO 8601 như PT5M30S hoặc PT1H15M. Trong quá trình xử lý dữ liệu, các giá trị này được chuyển đổi sang trường duration_seconds nhằm biểu diễn thời lượng video dưới dạng số nguyên. Việc chuẩn hóa này giúp mô hình có thể khai thác trực tiếp thông tin về độ dài video trong quá trình huấn luyện.

Trong quá trình xử lý dữ liệu, trạng thái Trending của video cũng được xác định dựa trên nguồn dữ liệu thu thập. Các video được lấy từ danh sách Trending của YouTube được gán nhãn Trending bằng 1, trong khi các video thu thập từ Search API theo từ khóa

được gán nhãn bằng 0. Nhãn này được sử dụng làm biến mục tiêu cho bài toán phân loại trong giai đoạn xây dựng mô hình Machine Learning.

Sau khi hoàn thành các bước làm sạch và chuẩn hóa, dữ liệu từ Video Dataset, Channel Dataset và Video Statistics Dataset được liên kết thông qua các khóa định danh như video_id và channel_id để tạo thành tập dữ liệu thống nhất, làm cơ sở cho các bước phân tích cảm xúc bình luận, xây dựng đặc trưng và huấn luyện mô hình dự đoán ở các giai đoạn tiếp theo.

Bảng 3.8 Dữ liệu Video sau bước tiền xử lý

Thành phần	Giá trị
Dataset nguồn	Video, Channel, Video Statistics
Khóa liên kết	video_id, channel_id
Tổng số bản ghi	1.171.067
Số thuộc tính sau xử lý	45
Video unique	158,068
Channel	83,173
Đặc trưng mới	duration_seconds, like_rate, comment_rate, country_region

3.4.2 Phân tích cảm xúc bình luận

3.4.2.1 Tiền xử lý văn bản

Trước khi thực hiện phân tích cảm xúc, dữ liệu bình luận được tiền xử lý nhằm loại bỏ các thành phần không cần thiết và chuẩn hóa nội dung văn bản. Bước này giúp giảm nhiễu trong dữ liệu đầu vào và cải thiện chất lượng dự đoán của mô hình.

Các bình luận được chuẩn hóa Unicode về định dạng NFC để đảm bảo tính nhất quán trong quá trình xử lý văn bản. Bên cạnh đó, các ký tự HTML, đường dẫn URL và ký hiệu đề cập người dùng được loại bỏ khỏi nội dung bình luận. Những ký tự điều khiển không hiển thị cũng được loại bỏ nhằm hạn chế các trường hợp gây ảnh hưởng đến quá trình phân tích.

Sau khi làm sạch dữ liệu, các khoảng trắng dư thừa được chuẩn hóa về một khoảng trắng duy nhất. Những bình luận quá ngắn hoặc không còn đủ nội dung sau khi xử lý sẽ

bị loại bỏ khỏi tập dữ liệu. Kết quả của bước này là tập dữ liệu văn bản đã được chuẩn hóa và sẵn sàng cho quá trình phân tích cảm xúc.

Bảng 3.9 Các bước xử lý và mục đích của tiền xử lý văn bản

Bước xử lý	Mục đích
Chuẩn hóa Unicode NFC	Đồng nhất cách biểu diễn ký tự
Loại bỏ HTML entities	Loại bỏ ký tự sinh ra từ HTML
Loại bỏ URL	Giảm nhiễu dữ liệu
Loại bỏ Mention	Loại bỏ thông tin không mang ý nghĩa cảm xúc
Chuẩn hóa khoảng trắng	Chuẩn hóa văn bản
Loại bỏ bình luận quá ngắn	Giảm dữ liệu ít giá trị

3.4.2.2 Phân loại cảm xúc bằng XLM-RoBERTa

Sau khi hoàn thành bước tiền xử lý, dữ liệu bình luận được đưa vào mô hình XLM-RoBERTa để thực hiện phân loại cảm xúc. Mô hình được lựa chọn do bộ dữ liệu bình luận YouTube trong nghiên cứu bao gồm nhiều ngôn ngữ khác nhau đến từ nhiều quốc gia và khu vực. So với các mô hình chỉ hỗ trợ một ngôn ngữ hoặc các phương pháp dựa trên từ điển, XLM-RoBERTa có khả năng xử lý dữ liệu đa ngôn ngữ tốt hơn và duy trì độ chính xác cao trong các tác vụ phân loại cảm xúc.

Quá trình phân loại được thực hiện trên Google Colab nhằm tận dụng tài nguyên GPU để xử lý khối lượng lớn dữ liệu bình luận. Đối với mỗi bình luận, mô hình dự đoán một trong ba nhãn cảm xúc gồm tích cực (Positive), trung lập (Neutral) hoặc tiêu cực (Negative), đồng thời trả về xác suất dự đoán tương ứng.

Kết quả phân loại cảm xúc được sử dụng để xây dựng các chỉ số tổng hợp ở cấp độ video như tỷ lệ bình luận tích cực, tỷ lệ bình luận trung lập và tỷ lệ bình luận tiêu cực. Các chỉ số này sau đó được tích hợp vào Video Dataset và được sử dụng như các đặc trưng đầu vào trong quá trình phân tích dữ liệu và xây dựng mô hình dự đoán video Trending.

3.4.2.3 Kết quả phân tích cảm xúc

Sau khi hoàn thành quá trình suy luận, tập dữ liệu bình luận được bổ sung thêm hai thuộc tính mới gồm sentiment_label và sentiment_score. Trong đó, sentiment_label thể hiện nhãn cảm xúc do mô hình dự đoán, còn sentiment_score biểu diễn độ tin cậy tương ứng của kết quả dự đoán.

Bảng 3.10 Các thuộc tính của Comment Dataset sau phân tích cảm xúc

Thuộc tính	Mô tả
comment_id	Mã định danh bình luận
video_id	Mã định danh video
comment_text	Nội dung bình luận
like_count	Số lượt thích của bình luận
published_at	Thời gian đăng bình luận
sentiment_label	Nhãn cảm xúc dự đoán
sentiment_score	Độ tin cậy của dự đoán

3.4.3 Xây dựng đặc trưng

Việc lựa chọn và xây dựng đặc trưng đóng vai trò quan trọng đối với hiệu quả của mô hình Machine Learning. Các đặc trưng được sử dụng trong đề tài được xây dựng dựa trên giả thuyết rằng khả năng một video xuất hiện trong danh sách Trending không chỉ phụ thuộc vào nội dung video mà còn chịu ảnh hưởng bởi mức độ tương tác của người dùng, quy mô kênh đăng tải và phản hồi của cộng đồng thông qua các bình luận.

Đặc trưng đầu tiên được sử dụng là duration_seconds. Thời lượng video có thể ảnh hưởng đến khả năng tiếp cận và mức độ tương tác của người xem. Một số nội dung có xu hướng đạt hiệu quả tốt với thời lượng ngắn, trong khi các nội dung chuyên sâu thường yêu cầu thời lượng dài hơn. Do đó, thời lượng video được đưa vào mô hình để đánh giá mức độ ảnh hưởng đến khả năng trở thành Trending.

Đặc trưng topic được sử dụng nhằm phản ánh chủ đề nội dung của video. Trên YouTube, mức độ phổ biến của các chủ đề có thể thay đổi theo thời gian và theo từng khu vực. Một số chủ đề như giải trí, âm nhạc hoặc tin tức thường có khả năng thu hút lượng lớn người xem hơn các chủ đề khác. Vì vậy, việc đưa thông tin chủ đề vào mô hình giúp phản ánh đặc điểm nội dung của video.

Đặc trưng country_region được xây dựng nhằm thể hiện khu vực hoặc quốc gia nơi dữ liệu được thu thập. Danh sách Trending của YouTube được xác định riêng cho từng quốc gia, do đó cùng một video có thể trở thành Trending ở khu vực này nhưng không xuất hiện trong danh sách Trending của khu vực khác. Đặc trưng này giúp mô hình xem xét yếu tố địa lý trong quá trình dự đoán.

Đối với các chỉ số tương tác, thay vì chỉ sử dụng số lượt thích hoặc số lượt bình luận, đề tài xây dựng hai đặc trưng like_rate và comment_rate. Các đặc trưng này được tính dựa trên tỷ lệ giữa số lượt tương tác và số lượt xem của video. Việc sử dụng tỷ lệ tương tác giúp giảm ảnh hưởng của quy mô video và phản ánh chính xác hơn mức độ quan tâm của người dùng đối với nội dung.

Bên cạnh đó, view_count được sử dụng để phản ánh mức độ tiếp cận của video trên nền tảng. Đây là một trong những chỉ số quan trọng thể hiện mức độ lan truyền của nội dung và thường có mối liên hệ trực tiếp với khả năng xuất hiện trong danh sách Trending.

Ngoài các đặc trưng liên quan đến video, đề tài còn sử dụng subscriber_count và video_count để mô tả quy mô hoạt động của kênh đăng tải. Số lượng người đăng ký phản ánh mức độ ảnh hưởng của kênh đối với cộng đồng người xem, trong khi số lượng video thể hiện mức độ hoạt động và kinh nghiệm xây dựng nội dung của kênh.

Sau khi hoàn thành quá trình phân tích cảm xúc bình luận, các kết quả dự đoán được tổng hợp theo từng video để xây dựng các đặc trưng cảm xúc. Cụ thể, đề tài tính toán tỷ lệ bình luận tích cực (positive_ratio), tỷ lệ bình luận trung lập (neutral_ratio) và tỷ lệ bình luận tiêu cực (negative_ratio) trên tổng số bình luận của mỗi video.

Việc sử dụng các đặc trưng cảm xúc xuất phát từ giả thuyết rằng phản hồi của cộng đồng có thể ảnh hưởng đến mức độ lan truyền của video. Những video nhận được nhiều phản hồi tích cực có khả năng thu hút thêm người xem và gia tăng tương tác, trong khi các phản hồi tiêu cực có thể làm giảm sức lan tỏa của nội dung. Do đó, các chỉ số cảm

xúc được đưa vào mô hình nhằm bổ sung thêm thông tin về phản ứng của người dùng đối với video.

Bảng 3.11 Các đặc trưng được sử dụng trong mô hình dự đoán Trending

Đặc trưng	Ý nghĩa
duration_seconds	Thời lượng video
topic	Chủ đề nội dung
country_region	Quốc gia hoặc khu vực
view_count	Tổng số lượt xem
like_rate	Tỷ lệ lượt thích trên lượt xem
comment_rate	Tỷ lệ bình luận trên lượt xem
subscriber_count	Số người đăng ký kênh
video_count	Tổng số video của kênh
positive_ratio	Tỷ lệ bình luận tích cực
neutral_ratio	Tỷ lệ bình luận trung lập
negative_ratio	Tỷ lệ bình luận tiêu cực

3.5 Phân tích khám phá dữ liệu (EDA)

3.5.1 Phân tích tổng quan dữ liệu

Sau quá trình thu thập, làm sạch và tích hợp dữ liệu từ YouTube Data API v3, bộ dữ liệu được hình thành từ nhiều nguồn khác nhau bao gồm dữ liệu video, dữ liệu kênh và dữ liệu bình luận. Việc phân tích tổng quan dữ liệu được thực hiện nhằm đánh giá đặc điểm chung của tập dữ liệu, kiểm tra quy mô dữ liệu cũng như xác định sự phân bố của các nhóm dữ liệu trước khi tiến hành các bước phân tích chuyên sâu và xây dựng mô hình Machine Learning.

Đối với dữ liệu video, quá trình phân tích tập trung vào việc thống kê số lượng bản ghi, số lượng video, số lượng kênh, số lượng thuộc tính và các đặc trưng chính được sử dụng trong nghiên cứu. Bên cạnh đó, biến mục tiêu trạng thái xu hướng (is_trending) cũng được phân tích nhằm đánh giá sự phân bố giữa hai nhóm video Trending và Non-

Trending. Kết quả phân tích giúp xác định mức độ cân bằng của dữ liệu và cung cấp cơ sở cho quá trình xây dựng mô hình dự đoán.

Đối với dữ liệu bình luận, quá trình phân tích được thực hiện nhằm đánh giá quy mô và mức độ bao phủ của dữ liệu người dùng trên nền tảng YouTube. Các chỉ tiêu được xem xét bao gồm tổng số bình luận thu thập được, số lượng video có bình luận và các đặc điểm liên quan đến dữ liệu phản hồi của người xem. Việc phân tích dữ liệu bình luận giúp đánh giá mức độ tương tác của người dùng cũng như khả năng khai thác thông tin cảm xúc phục vụ cho các bước phân tích tiếp theo.

3.5.2 Phân tích đặc trưng tương tác

Sau khi thực hiện phân tích tổng quan dữ liệu, nghiên cứu tiếp tục phân tích các đặc trưng tương tác của video nhằm đánh giá sự khác biệt giữa nhóm video Trending và Non-Trending. Đây là nhóm thuộc tính phản ánh mức độ tiếp cận và tương tác của người dùng đối với nội dung video trên nền tảng YouTube.

Các thuộc tính được lựa chọn phân tích bao gồm số lượt xem (View Count), tỷ lệ lượt thích (Like Rate), tỷ lệ bình luận (Comment Rate), thời lượng video (Duration) và số lượng người đăng ký của kênh (Subscriber Count). Đây là những chỉ số thường được sử dụng trong các nghiên cứu về mức độ phổ biến của nội dung số và được kỳ vọng có ảnh hưởng đến khả năng xuất hiện trong danh sách Trending.

Để đánh giá đặc điểm phân bố của các thuộc tính, nghiên cứu sử dụng các chỉ số thống kê mô tả như giá trị trung bình, trung vị, độ lệch chuẩn, giá trị lớn nhất và nhỏ nhất. Bên cạnh đó, các biểu đồ Histogram được sử dụng để quan sát phân bố dữ liệu, trong khi Boxplot được sử dụng để so sánh sự khác biệt giữa hai nhóm video Trending và Non-Trending cũng như phát hiện các giá trị ngoại lệ.

Thông qua quá trình phân tích này, nghiên cứu đánh giá khả năng phân biệt của từng đặc trưng đối với biến mục tiêu, từ đó làm cơ sở cho việc lựa chọn và xây dựng tập đặc trưng phục vụ mô hình học máy ở các bước tiếp theo.

3.5.3 Phân tích cảm xúc người dùng

Bên cạnh các chỉ số tương tác, nghiên cứu tiến hành phân tích cảm xúc người dùng dựa trên dữ liệu bình luận thu thập từ YouTube nhằm đánh giá phản ứng của khán giả đối với nội dung video. Việc phân tích cảm xúc giúp bổ sung góc nhìn về chất lượng tương tác, không chỉ dựa trên số lượng mà còn dựa trên thái độ và cảm nhận của người xem.

Dữ liệu bình luận sau khi được làm sạch sẽ được xử lý bằng mô hình XLM-RoBERTa để phân loại cảm xúc thành ba nhóm gồm tích cực (Positive), trung lập (Neutral) và tiêu cực (Negative). Kết quả phân loại được tổng hợp ở cấp độ video để tạo ra các đặc trưng phản ánh xu hướng cảm xúc của người dùng đối với từng video.

Để thực hiện phân tích, nghiên cứu sử dụng các biểu đồ cột và biểu đồ phân bố nhằm khảo sát tỷ lệ xuất hiện của từng nhóm cảm xúc. Đồng thời, nghiên cứu cũng tiến hành so sánh sự khác biệt về phân bố cảm xúc giữa nhóm video Trending và Non-Trending nhằm đánh giá mức độ liên quan giữa phản hồi của người dùng và khả năng trở thành video xu hướng.

3.5.4 Phân tích tương quan dữ liệu

Sau khi khảo sát các đặc trưng riêng lẻ, nghiên cứu tiến hành phân tích tương quan dữ liệu nhằm đánh giá mức độ liên hệ giữa các thuộc tính trong tập dữ liệu cũng như xác định các đặc trưng có khả năng ảnh hưởng đến biến mục tiêu `is_trending`.

Phân tích tương quan được thực hiện trên các thuộc tính số như số lượt xem (View Count), tỷ lệ lượt thích (Like Rate), tỷ lệ bình luận (Comment Rate), thời lượng video (Duration), số lượng người đăng ký kênh (Subscriber Count), số lượng video của kênh (Video Count) và các đặc trưng được tạo ra trong quá trình tiền xử lý dữ liệu. Hệ số tương quan Pearson được sử dụng để đo lường mức độ tương quan tuyến tính giữa các biến với giá trị nằm trong khoảng từ -1 đến 1.

Để trực quan hóa kết quả, nghiên cứu sử dụng biểu đồ Heatmap tương quan. Công cụ này cho phép quan sát nhanh các mối quan hệ giữa các thuộc tính, xác định các cặp biến có tương quan mạnh và phát hiện hiện tượng đa cộng tuyến (Multicollinearity) có thể ảnh hưởng đến hiệu quả của mô hình học máy.

Ngoài việc đánh giá mối quan hệ giữa các thuộc tính đầu vào và cũng xem xét được mức độ liên hệ giữa từng đặc trưng và biến mục tiêu nhằm hỗ trợ quá trình lựa chọn đặc trưng.

3.5.5 Nhận xét và lựa chọn đặc trưng

Dựa trên các kết quả thu được từ quá trình phân tích tổng quan dữ liệu, phân tích đặc trưng tương tác, phân tích cảm xúc người dùng và phân tích tương quan dữ liệu, nghiên cứu tiến hành đánh giá mức độ phù hợp của các thuộc tính trước khi đưa vào mô hình học máy.

Quá trình lựa chọn đặc trưng được thực hiện dựa trên nhiều tiêu chí khác nhau như mức độ liên quan đến biến mục tiêu, khả năng phân biệt giữa nhóm Trending và Non-Trending, mức độ ổn định của dữ liệu, khả năng giải thích của đặc trưng và hiện tượng tương quan cao giữa các biến. Các đặc trưng không mang nhiều ý nghĩa dự đoán hoặc có khả năng gây nhiễu cho mô hình sẽ được xem xét loại bỏ nhằm giảm độ phức tạp và cải thiện hiệu quả huấn luyện.

Bên cạnh đó, nghiên cứu cũng xem xét các đặc trưng được xây dựng từ quá trình tiền xử lý và biến đổi dữ liệu nhằm đánh giá khả năng đóng góp của chúng đối với bài toán dự đoán. Tập đặc trưng cuối cùng được lựa chọn sẽ được sử dụng để xây dựng và đánh giá các mô hình học máy trong giai đoạn tiếp theo.

3.6 Xây dựng và đánh giá mô hình dự đoán Trending

Sau khi hoàn thành quá trình tiền xử lý dữ liệu, phân tích cảm xúc và xây dựng đặc trưng, đề tài tiến hành xây dựng mô hình Machine Learning nhằm dự đoán khả năng video xuất hiện trong danh sách Trending trên nền tảng YouTube. Đây là bài toán phân loại nhị phân, trong đó mô hình cần xác định một video thuộc nhóm Trending hay Non-Trending dựa trên các đặc trưng đã được xây dựng từ dữ liệu video, dữ liệu kênh và dữ liệu cảm xúc người dùng.

Quá trình xây dựng mô hình bao gồm các bước chuẩn bị dữ liệu, lựa chọn thuật toán, huấn luyện mô hình và lưu trữ mô hình phục vụ cho việc triển khai ứng dụng dự đoán.

3.6.1 Chuẩn bị dữ liệu huấn luyện

Sau khi hoàn thành quá trình xây dựng đặc trưng, tập dữ liệu được sử dụng làm đầu vào cho mô hình dự đoán khả năng video xuất hiện trong danh sách Trending. Mục tiêu của giai đoạn này là chuyển đổi dữ liệu về định dạng phù hợp với thuật toán học máy, đồng thời đảm bảo các đặc trưng có thể phản ánh được những yếu tố ảnh hưởng đến khả năng trở thành Trending của video.

Biến mục tiêu được sử dụng trong nghiên cứu là `is_trending`. Đây là biến nhị phân được xây dựng trong giai đoạn thu thập dữ liệu, trong đó giá trị 1 đại diện cho các video thuộc danh sách Trending của YouTube và giá trị 0 đại diện cho các video không thuộc danh sách Trending. Việc sử dụng biến mục tiêu dạng nhị phân giúp bài toán được xây dựng dưới dạng bài toán phân loại hai lớp.

Tập dữ liệu đầu vào bao gồm các đặc trưng được xây dựng từ nhiều nguồn dữ liệu khác nhau như thông tin video, thông tin kênh và kết quả phân tích cảm xúc bình luận. Các đặc trưng này phản ánh nhiều khía cạnh liên quan đến video, bao gồm nội dung, mức độ tương tác của người dùng, quy mô kênh đăng tải và phản hồi của cộng đồng người xem. Việc kết hợp các nhóm đặc trưng giúp mô hình có khả năng khai thác được nhiều thông tin hơn thay vì chỉ dựa trên một nhóm chỉ số riêng lẻ.

Đối với các thuộc tính dạng phân loại như topic và country_region, dữ liệu được chuyển đổi sang dạng số bằng phương pháp Label Encoding. Quá trình mã hóa này giúp mô hình có thể xử lý các thuộc tính phân loại trong quá trình huấn luyện mà vẫn giữ được sự khác biệt giữa các nhóm dữ liệu. Kết quả mã hóa được lưu lại để sử dụng nhất quán trong giai đoạn dự đoán của ứng dụng.

Bên cạnh đó, dữ liệu thu thập từ YouTube có sự chênh lệch khá lớn giữa các video. Một số video chỉ đạt vài nghìn lượt xem, trong khi nhiều video khác có thể đạt hàng triệu hoặc hàng chục triệu lượt xem. Tương tự, số lượng người đăng ký kênh và số lượng video của mỗi kênh cũng có sự khác biệt đáng kể. Nếu sử dụng trực tiếp các giá trị này, mô hình có thể bị ảnh hưởng bởi các giá trị quá lớn và khó học được mối quan hệ thực sự giữa các đặc trưng.

Để giảm ảnh hưởng của hiện tượng phân bố lệch và các giá trị ngoại lệ, đề tài áp dụng phép biến đổi logarit tự nhiên thông qua hàm $\log_{1p}()$ đối với các thuộc tính view_count, subscriber_count, video_count và duration_seconds. Phương pháp này giúp thu hẹp khoảng cách giữa các giá trị lớn và nhỏ, đồng thời làm cho phân bố dữ liệu trở nên ổn định hơn. Nhờ đó, mô hình có thể học hiệu quả hơn và giảm nguy cơ bị chi phối bởi một số ít bản ghi có giá trị quá lớn.

Sau khi hoàn thành các bước tiền xử lý, tập dữ liệu được tách thành hai phần gồm tập huấn luyện và tập kiểm tra theo tỷ lệ 80:20. Trong đó, 80% dữ liệu được sử dụng để huấn luyện mô hình và 20% dữ liệu còn lại được sử dụng để đánh giá hiệu suất sau khi huấn luyện. Việc tách riêng dữ liệu kiểm tra giúp đánh giá khách quan khả năng dự đoán của mô hình trên các dữ liệu chưa từng xuất hiện trong quá trình học.

Do số lượng video Trending và Non-Trending trong tập dữ liệu không hoàn toàn cân bằng, quá trình chia dữ liệu được thực hiện theo phương pháp phân tầng (Stratified Sampling). Phương pháp này giúp duy trì tỷ lệ phân bố giữa hai lớp trên cả tập huấn

luyện và tập kiểm tra, từ đó hạn chế hiện tượng thiên lệch dữ liệu và đảm bảo kết quả đánh giá phản ánh đúng năng lực của mô hình.

Kết quả của giai đoạn chuẩn bị dữ liệu là hai tập dữ liệu X_{train} , y_{train} và X_{test} , y_{test} sẵn sàng cho quá trình huấn luyện mô hình XGBoost được trình bày trong mục tiếp theo.

3.6.2 Xây dựng mô hình XGBoost

3.6.2.1 Áp dụng mô hình XGBoost trong bài toán dự đoán

Sau khi xây dựng tập dữ liệu huấn luyện, mô hình XGBoost được áp dụng để giải quyết bài toán dự đoán khả năng video xuất hiện trong danh sách Trending trên nền tảng YouTube. Đây là bài toán phân loại nhị phân, trong đó mô hình có nhiệm vụ xác định một video thuộc nhóm Trending hay Non-Trending dựa trên các đặc trưng được xây dựng từ dữ liệu thu thập.

Biến mục tiêu của mô hình là $is_trending$. Trong đó, giá trị 1 đại diện cho video thuộc danh sách Trending và giá trị 0 đại diện cho video không thuộc danh sách Trending. Quá trình huấn luyện nhằm giúp mô hình học được mối quan hệ giữa các đặc trưng đầu vào và trạng thái Trending của video.

Dữ liệu đầu vào của mô hình bao gồm các đặc trưng được xây dựng từ nhiều nguồn dữ liệu khác nhau như thông tin video, thông tin kênh và dữ liệu cảm xúc bình luận. Sau quá trình lựa chọn đặc trưng, các biến được sử dụng trong nghiên cứu bao gồm:

Bảng 3.12 Đặc trưng được sử dụng cho mô hình XGBoost

Đặc trưng	Ý nghĩa
duration_seconds	Thời lượng video
topic	Chủ đề nội dung của video
country_region	Quốc gia hoặc khu vực thu thập dữ liệu
view_count	Tổng số lượt xem của video
subscriber_count	Số lượng người đăng ký của kênh
video_count	Tổng số video đã đăng tải trên kênh
like_rate	Tỷ lệ lượt thích trên lượt xem

Đặc trưng	Ý nghĩa
comment_rate	Tỷ lệ bình luận trên lượt xem
positive_ratio	Tỷ lệ bình luận tích cực
neutral_ratio	Tỷ lệ bình luận trung lập
negative_ratio	Tỷ lệ bình luận tiêu cực

Các đặc trưng trên phản ánh nhiều khía cạnh khác nhau của video, bao gồm nội dung, mức độ tương tác của người xem, quy mô kênh đăng tải và phản hồi từ cộng đồng người dùng. Việc kết hợp nhiều nhóm đặc trưng giúp mô hình có thể khai thác được nhiều yếu tố ảnh hưởng đến khả năng trở thành Trending thay vì chỉ dựa trên một chỉ số đơn lẻ.

Trước khi huấn luyện, các thuộc tính dạng phân loại như topic và country_region được chuyển đổi sang dạng số bằng phương pháp Label Encoding. Đồng thời, các thuộc tính có phạm vi giá trị lớn như view_count, subscriber_count, video_count và duration_seconds được biến đổi bằng hàm log1p() nhằm giảm ảnh hưởng của các giá trị ngoại lệ và cải thiện khả năng học của mô hình.

Trong quá trình huấn luyện, tập dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80:20. Để giảm ảnh hưởng của hiện tượng mất cân bằng dữ liệu giữa hai lớp Trending và Non-Trending, tham số scale_pos_weight được áp dụng nhằm điều chỉnh trọng số của lớp thiểu số trong quá trình học.

Mô hình được triển khai bằng thư viện XGBoost trong Python với các tham số chính gồm n_estimators = 300, max_depth = 5, learning_rate = 0.05, subsample = 0.8 và colsample_bytree = 0.8. Các tham số này được lựa chọn sau quá trình thử nghiệm nhằm cân bằng giữa khả năng học của mô hình và thời gian huấn luyện.

Sau khi hoàn tất quá trình huấn luyện, mô hình được lưu dưới dạng tệp xgb_trending_model.json để phục vụ cho việc đánh giá hiệu suất và triển khai vào ứng dụng dự đoán Trending được xây dựng trong nghiên cứu.

3.7 Xây dựng ứng dụng dự đoán Trending


Sau khi hoàn thành quá trình xây dựng Data Warehouse, tiền xử lý dữ liệu và huấn luyện mô hình dự đoán, đề tài tiến hành xây dựng ứng dụng dự đoán Trending nhằm hỗ trợ người dùng khai thác kết quả nghiên cứu một cách trực quan. Ứng dụng được phát

triển bằng thư viện Streamlit trong Python, cho phép tích hợp mô hình Machine Learning với giao diện web tương tác mà không yêu cầu triển khai các framework web phức tạp.

Mục tiêu của ứng dụng là cung cấp môi trường trực quan để người dùng theo dõi dữ liệu Trending, phân tích các đặc trưng của video và thực hiện dự đoán khả năng xuất hiện trong danh sách Trending dựa trên các thông tin đầu vào.

3.7.1 Kiến trúc ứng dụng

Ứng dụng phân tích và dự đoán video Trending được phát triển bằng thư viện Streamlit, cho phép xây dựng giao diện web tương tác trực tiếp với người dùng. Hệ thống được thiết kế theo mô hình phân chia chức năng thành các module độc lập nhằm hỗ trợ việc theo dõi xu hướng video Trending và dự đoán khả năng xuất hiện trong danh sách Trending của YouTube.



Hình 3.5 Kiến trúc tổng thể của ứng dụng dự đoán Trending

Người dùng tương tác với hệ thống thông qua giao diện Streamlit Web Application. Từ giao diện chính, người dùng có thể truy cập các chức năng Home, Trending Analytics và Predict.

Phân hệ Home đóng vai trò là trang giới thiệu hệ thống, cung cấp thông tin tổng quan về mục tiêu, chức năng và phạm vi dữ liệu được sử dụng trong ứng dụng. Đây là

điểm truy cập đầu tiên giúp người dùng làm quen với hệ thống trước khi sử dụng các chức năng phân tích và dự đoán.

Phân hệ Trending Analytics sử dụng YouTube Data API v3 để truy xuất danh sách video đang thịnh hành theo từng quốc gia hoặc khu vực. Dữ liệu được lấy trực tiếp từ nền tảng YouTube và được sử dụng để xây dựng các chỉ số thống kê, biểu đồ trực quan và bảng xếp hạng video Trending. Thông qua chức năng này, người dùng có thể theo dõi các video nổi bật, kênh phổ biến, danh mục nội dung thịnh hành và các chỉ số tương tác theo thời gian thực.

Đối với chức năng Predict, người dùng cung cấp đường dẫn của video YouTube cần dự đoán. Hệ thống sử dụng YouTube Data API v3 để thu thập các thông tin liên quan đến video như số lượt xem, lượt thích, số bình luận, thời lượng video, chủ đề nội dung và thông tin kênh. Sau đó, các đặc trưng đầu vào được xử lý và đưa vào mô hình XGBoost đã được huấn luyện trước để dự đoán khả năng video xuất hiện trong danh sách Trending.

Kết quả dự đoán được trả về dưới dạng nhãn phân loại Trending hoặc Not Trending cùng với xác suất dự đoán tương ứng. Điều này giúp người dùng đánh giá tiềm năng lan truyền của video dựa trên các đặc trưng đã được mô hình học từ dữ liệu lịch sử.

3.7.2 Chức năng Trending Analytics

Chức năng Trending Analytics được xây dựng nhằm hỗ trợ người dùng theo dõi và phân tích các video đang thịnh hành trên nền tảng YouTube theo thời gian thực. Dữ liệu được truy xuất trực tiếp từ YouTube Data API v3, cho phép hệ thống cập nhật danh sách video Trending mới nhất theo từng quốc gia hoặc khu vực.


Người dùng có thể lựa chọn quốc gia hoặc khu vực cần theo dõi thông qua bộ lọc ở phía trên giao diện. Đồng thời, hệ thống cho phép lựa chọn số lượng video Trending hiển thị như Top 10, Top 20 hoặc Top 30.

Sau khi dữ liệu được tải về từ YouTube Data API, hệ thống thực hiện tổng hợp và trực quan hóa các chỉ số quan trọng bao gồm tổng số video Trending, tổng lượt xem, tổng lượt thích, tổng lượt bình luận và mức độ tăng trưởng tương tác. Các chỉ số này được hiển thị dưới dạng KPI Cards nhằm giúp người dùng nhanh chóng nắm bắt tình hình xu hướng hiện tại.

Bên cạnh các chỉ số tổng quan, hệ thống còn cung cấp bảng xếp hạng các video Trending với đầy đủ thông tin như tiêu đề video, tên kênh, số lượt xem, số lượt thích và

số lượt bình luận. Danh sách này giúp người dùng xác định các nội dung đang nhận được sự quan tâm lớn từ cộng đồng người xem.

Ngoài ra, chức năng Trending Analytics còn cung cấp các biểu đồ trực quan nhằm hỗ trợ phân tích dữ liệu. Biểu đồ phân bố danh mục nội dung giúp người dùng nhận biết các chủ đề đang chiếm ưu thế trong danh sách Trending. Biểu đồ xu hướng theo thời gian thể hiện sự thay đổi của mức độ tương tác giữa các video Trending. Đồng thời, hệ thống cũng hiển thị danh sách các kênh nổi bật và bản đồ khu vực nhằm cung cấp góc nhìn tổng quan về sự phân bố của các nội dung thịnh hành.



Hình 3.6 Phác thảo bố cục trang Trending Analytics

3.7.3 Chức năng dự đoán Trending

Chức năng dự đoán Trending được xây dựng nhằm hỗ trợ người dùng đánh giá khả năng một video xuất hiện trong danh sách Trending của YouTube dựa trên mô hình học máy XGBoost đã được huấn luyện từ dữ liệu lịch sử.

Khi truy cập trang Predict, người dùng có thể lựa chọn hai phương thức dự đoán:

- Dự đoán bằng URL video YouTube.
- Dự đoán bằng cách nhập thủ công các thông số của video.


Đối với phương thức nhập URL, hệ thống sử dụng YouTube Data API v3 để tự động thu thập các thông tin cần thiết của video và kênh như lượt xem, lượt thích, số bình luận, thời lượng video, số lượng người đăng ký kênh và các thông tin liên quan khác. Sau khi dữ liệu được thu thập, hệ thống tiến hành tiền xử lý và tính toán các đặc trưng đầu vào tương ứng với mô hình.

Đối với phương thức nhập thủ công, người dùng có thể trực tiếp cung cấp các giá trị của các đặc trưng được sử dụng trong mô hình dự đoán. Cách tiếp cận này cho phép người dùng đánh giá khả năng Trending của một video giả định trước khi đăng tải hoặc khi chưa có đủ dữ liệu thực tế từ YouTube.

Sau khi nhận dữ liệu đầu vào, hệ thống thực hiện các bước xử lý gồm chuẩn hóa dữ liệu, mã hóa các thuộc tính phân loại và xây dựng vector đặc trưng đầu vào cho mô hình XGBoost. Kết quả dự đoán được trả về dưới dạng xác suất xuất hiện trong danh sách Trending cùng với nhãn phân loại Trending hoặc Non-Trending.

Ngoài việc hiển thị kết quả dự đoán, hệ thống còn cung cấp cơ chế giải thích kết quả dựa trên mức độ ảnh hưởng của các đặc trưng trong mô hình. Các đặc trưng quan trọng như tỷ lệ lượt thích (Like Rate), tỷ lệ bình luận (Comment Rate), số lượng người đăng ký kênh (Subscriber Count), chủ đề video (Topic) và khu vực quốc gia (Country Region) được hiển thị dưới dạng biểu đồ mức độ ảnh hưởng nhằm giúp người dùng hiểu rõ nguyên nhân dẫn đến kết quả dự đoán.

Bên cạnh đó, hệ thống cũng đưa ra các gợi ý cải thiện dựa trên các đặc trưng đầu vào của video. Các đề xuất này giúp nhà sáng tạo nội dung có thể điều chỉnh chiến lược phát triển video nhằm nâng cao khả năng xuất hiện trong danh sách Trending của YouTube.



Hình 3.7 Phác thảo bố cục trang Trending Analytics

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1. Kết quả phân tích khám phá dữ liệu (EDA)


4.1.1 Phân tích tổng quan dữ liệu

4.1.1.1 Phân bố trạng thái Trending

Biến mục tiêu `is_trending` được sử dụng để xác định một video có thuộc danh sách Trending hay không. Việc khảo sát phân bố của biến này giúp đánh giá mức độ cân bằng giữa các lớp trong tập dữ liệu trước khi tiến hành xây dựng mô hình phân loại.

Kết quả cho thấy số lượng video không thuộc danh sách Trending chiếm tỷ lệ lớn hơn so với nhóm video Trending. Cụ thể, nhóm Non-Trending chiếm khoảng 76,7% tổng số video, trong khi nhóm Trending chiếm khoảng 23,3%. Mặc dù tồn tại sự chênh lệch giữa hai lớp, tỷ lệ này chưa tạo ra tình trạng mất cân bằng nghiêm trọng và vẫn đảm bảo đủ dữ liệu cho mô hình học được đặc điểm của cả hai nhóm.

Phân bố này phản ánh đúng thực tế khi chỉ một phần nhỏ video trên nền tảng YouTube có khả năng xuất hiện trong danh sách Trending, trong khi phần lớn video còn lại không đạt được mức độ phổ biến tương ứng.




Hình 4.1 Phân bố trạng thái Trending

4.1.1.2 Phân bố chủ đề video

Chủ đề nội dung là một trong những yếu tố quan trọng ảnh hưởng đến khả năng tiếp cận và mức độ tương tác của video trên nền tảng YouTube. Việc phân tích phân bố chủ đề giúp đánh giá mức độ đa dạng của tập dữ liệu cũng như xác định các nhóm nội dung chiếm ưu thế trong quá trình thu thập dữ liệu.

Kết quả thống kê cho thấy tập dữ liệu bao gồm nhiều nhóm nội dung khác nhau như Gaming, Music, Entertainment, Education, Vlog, Food, Fitness, Sports, Technology và Beauty. Trong đó, Gaming là chủ đề xuất hiện nhiều nhất, tiếp theo là Music và Entertainment. Đây đều là những nhóm nội dung có lượng người xem lớn và mức độ tương tác cao trên nền tảng YouTube.

Bên cạnh các nhóm giải trí, tập dữ liệu còn bao gồm các chủ đề thuộc lĩnh vực giáo dục, công nghệ, thể thao, sức khỏe và đời sống. Điều này cho thấy dữ liệu được thu thập từ nhiều lĩnh vực khác nhau thay vì chỉ tập trung vào một nhóm nội dung cụ thể. Sự đa dạng về chủ đề giúp mô hình có khả năng học được nhiều đặc điểm khác nhau của video, từ đó nâng cao khả năng tổng quát hóa khi dự đoán xu hướng Trending.



Hình 4.2 Top 10 thể loại có nhiều video nhất


4.1.1.2 Phân bố cảm xúc bình luận

Bên cạnh các chỉ số tương tác của video, phản hồi của người dùng trong phần bình luận cũng là một nguồn thông tin quan trọng phản ánh mức độ tiếp nhận nội dung trên nền tảng YouTube. Để khai thác yếu tố này, các bình luận được phân loại thành ba nhóm cảm xúc gồm tích cực (Positive), trung lập (Neutral) và tiêu cực (Negative).

Kết quả phân tích cho thấy nhóm bình luận mang cảm xúc tích cực chiếm tỷ lệ lớn nhất trong tập dữ liệu. Điều này cho thấy phần lớn người dùng có xu hướng phản hồi theo hướng tích cực đối với các video được thu thập. Nhóm bình luận trung lập đứng thứ hai, trong khi nhóm bình luận tiêu cực chiếm tỷ lệ thấp hơn đáng kể.

Sự phân bố này phản ánh đặc điểm phổ biến của các nền tảng chia sẻ nội dung, nơi người dùng thường thể hiện sự yêu thích, đồng tình hoặc ủng hộ đối với những nội dung mà họ lựa chọn tương tác. Đồng thời, sự tồn tại của cả ba nhóm cảm xúc cho thấy dữ liệu bình luận có tính đa dạng và chứa nhiều thông tin hữu ích về phản ứng của người xem.

Kết quả phân tích cảm xúc là cơ sở để xây dựng các đặc trưng liên quan đến tỷ lệ bình luận tích cực, trung lập và tiêu cực. Những đặc trưng này sẽ được sử dụng trong các bước phân tích tiếp theo nhằm đánh giá mức độ ảnh hưởng của phản hồi người dùng đến khả năng trở thành video Trending.



Hình 4.3 Phân bố cảm xúc bình luận


4.1.2 Phân tích đặc trưng tương tác

4.1.2.1 Phân tích View Count theo trạng thái Trending

Số lượt xem (View Count) là một trong những chỉ số quan trọng phản ánh mức độ tiếp cận và phổ biến của video trên nền tảng YouTube. Do dữ liệu View Count có sự chênh lệch rất lớn giữa các video, với nhiều giá trị ngoại lệ có số lượt xem cực cao, nghiên cứu sử dụng phép biến đổi logarit cơ số 10 theo công thức $\log_{10}(\text{View Count} + 1)$ trước khi trực quan hóa. Việc cộng thêm 1 giúp xử lý các trường hợp video có số lượt xem bằng 0 và tránh lỗi khi thực hiện phép biến đổi logarit.

Kết quả cho thấy nhóm video Trending có phân bố View Count cao hơn so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 89,6 triệu lượt xem, cao hơn đáng kể so với nhóm Non-Trending với khoảng 24,8 triệu lượt xem. Đồng thời, phần lớn các quan sát của nhóm Trending cũng tập trung ở mức lượt xem cao hơn. Điều này cho thấy các video xuất hiện trong danh sách Trending thường đạt được khả năng tiếp cận và thu hút người xem tốt hơn so với các video thông thường.

Mặc dù vẫn tồn tại sự chồng lấp giữa hai nhóm dữ liệu, sự khác biệt về phân bố cho thấy số lượt xem (View Count) có mối liên hệ nhất định với trạng thái Trending của video. Do đó, đặc trưng này được xem là một trong những yếu tố quan trọng và được giữ lại trong quá trình xây dựng mô hình dự đoán.



Hình 4.5 So sánh phân bố lượt xem giữa video Trending và Non-Trending


4.1.2.2 Phân bố Like Rate theo trạng thái Trending

Phân bố chỉ số tỷ lệ lượt thích (Like Rate) giữa nhóm video Trending và Non-Trending. Khác với các biến đếm như lượt xem (View Count) hay đăng ký (Subscriber Count) có phạm vi giá trị rất lớn và phân bố lệch phải mạnh, tỷ lệ lượt thích (Like Rate) là biến tỷ lệ được giới hạn trong khoảng từ 0 đến 1 nên không cần áp dụng phép biến đổi logarit. Việc giữ nguyên giá trị gốc giúp kết quả trực quan và dễ diễn giải hơn dưới dạng phần trăm tương tác của người dùng.

Để cải thiện khả năng quan sát sự khác biệt giữa hai nhóm dữ liệu, các giá trị nằm trên phân vị thứ 99 (99th percentile) được loại bỏ khỏi biểu đồ. Những giá trị này chiếm tỷ lệ rất nhỏ nhưng có độ lớn bất thường, làm thu hẹp phần lớn dữ liệu còn lại và gây khó khăn cho việc quan sát phân bố trung tâm. Việc loại bỏ chỉ được thực hiện trong quá trình trực quan hóa nhằm giảm ảnh hưởng của các ngoại lệ (outliers), không làm thay đổi tập dữ liệu gốc và không ảnh hưởng đến quá trình huấn luyện hay đánh giá mô hình.

Kết quả cho thấy nhóm video Trending có phân bố tỷ lệ lượt thích (Like Rate) cao hơn rõ rệt so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 2,62%, trong khi nhóm Non-Trending chỉ đạt khoảng 1,65%. Đồng thời, khoảng tứ phân

vị của nhóm Trending cũng rộng hơn, cho thấy các video Trending thường nhận được mức độ yêu thích và tương tác tích cực từ người xem cao hơn. Điều này cho thấy tỷ lệ lượt thích (Like Rate) là một chỉ số phản ánh mức độ hấp dẫn của nội dung và có khả năng đóng góp vào việc nhận diện các video có xu hướng xuất hiện trong danh sách Trending.



Hình 4.6 So sánh phân bố tỷ lệ lượt thích giữa video Trending và Non-Trending


4.1.2.3 Phân bố Comment Rate theo trạng thái Trending

Comment Rate được tính bằng tỷ lệ số lượng bình luận trên tổng lượt xem của video, phản ánh mức độ tham gia thảo luận của người xem đối với nội dung được đăng tải. Do đây là biến tỷ lệ có giá trị tương đối nhỏ và dễ diễn giải dưới dạng phần trăm nên không áp dụng phép biến đổi logarit trong quá trình trực quan hóa dữ liệu đồng thời loại bỏ các giá trị nằm trên phân vị thứ 99 của Comment Rate.

Kết quả cho thấy nhóm video Trending có Comment Rate cao hơn đáng kể so với nhóm Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 0,1402%, trong khi nhóm Non-Trending chỉ đạt khoảng 0,0262%. Điều này cho thấy tỷ lệ bình luận trên lượt xem của các video Trending cao hơn hơn năm lần so với các video không thuộc danh sách Trending.

Ngoài ra, khoảng tứ phân vị của nhóm Trending cũng lớn hơn, phản ánh mức độ tương tác thảo luận sôi nổi hơn từ cộng đồng người xem. Khác với lượt thích chỉ thể hiện phản hồi tích cực đơn giản, hành vi bình luận thường đòi hỏi người dùng dành nhiều thời gian và sự quan tâm hơn đối với nội dung video. Do đó, Comment Rate không chỉ phản ánh mức độ tương tác mà còn cho thấy khả năng thu hút sự chú ý và kích thích trao đổi của video trên nền tảng YouTube.

Kết quả này cho thấy các video có khả năng tạo ra nhiều cuộc thảo luận từ người xem thường có xu hướng xuất hiện trong danh sách Trending nhiều hơn, qua đó khẳng định vai trò của Comment Rate như một đặc trưng quan trọng trong bài toán dự đoán video Trending.



Hình 4.7 So sánh phân bố tỷ lệ bình luận giữa video Trending và Non-Trending

4.1.2.4 Phân bố Duration theo trạng thái Trending


Thuộc tính Duration được làm sạch bằng cách loại bỏ các bản ghi có thời lượng bằng 0 giây và các video có thời lượng vượt quá 30 ngày nhằm hạn chế ảnh hưởng của các giá trị bất thường trong dữ liệu. Sau đó, phép biến đổi logarit cơ số 10 được áp dụng để giảm độ lệch của phân bố và hỗ trợ việc so sánh giữa hai nhóm video.

Kết quả cho thấy thời lượng video có sự khác biệt rõ rệt giữa nhóm Trending và Non-Trending. Giá trị trung vị của nhóm Trending đạt khoảng 1.044 giây (17,4 phút),

trong khi nhóm Non-Trending chỉ đạt khoảng 60 giây (1 phút). Đồng thời, khoảng tứ phân vị của nhóm Trending cũng cao hơn đáng kể, cho thấy phần lớn các video Trending đều có thời lượng dài hơn so với các video không thuộc danh sách Trending.

Sự khác biệt này cho thấy các video Trending thường chứa lượng nội dung lớn hơn và có khả năng duy trì sự quan tâm của người xem trong thời gian dài hơn. Nhiều nội dung phổ biến trên YouTube như podcast, chương trình giải trí, video giáo dục, phỏng vấn hoặc livestream thường có thời lượng tương đối dài và có xu hướng xuất hiện trong danh sách Trending nhiều hơn so với các video ngắn.

Qua kết quả phân tích cho thấy đây là một đặc trưng có khả năng phân biệt tốt giữa hai nhóm dữ liệu. Do đó, Duration được xem là một thuộc tính quan trọng và có tiềm năng đóng góp tích cực vào hiệu quả của mô hình dự đoán video Trending.



Hình 4.8 So sánh phân bố thời lượng giữa video Trending và Non-Trending

4.1.2.5 Phân bố Subscriber Count theo trạng thái Trending


Thuộc tính số lượng người đăng ký (Subscriber Count) có phạm vi giá trị rất lớn, dao động từ vài người đăng ký đến hàng trăm triệu người đăng ký. Do đó, phép biến đổi logarit cơ số 10 được áp dụng nhằm giảm độ lệch của dữ liệu và hỗ trợ việc so sánh phân bố giữa hai nhóm video. Trước khi thực hiện biến đổi logarit, các bản ghi có số

lượng người đăng ký bằng 0 được loại bỏ. Nhóm dữ liệu này chỉ chiếm khoảng 0,2% tổng số quan sát nên không ảnh hưởng đáng kể đến phân bố chung của tập dữ liệu.

Kết quả cho thấy các video thuộc nhóm Trending thường đến từ những kênh có quy mô người đăng ký lớn hơn. Giá trị trung vị của nhóm Trending đạt khoảng 224.000 người đăng ký, trong khi nhóm Non-Trending chỉ đạt khoảng 63.400 người đăng ký. Sự khác biệt này cho thấy các kênh sở hữu lượng người theo dõi lớn thường có lợi thế trong việc tiếp cận người xem và tạo ra mức độ lan truyền cao hơn cho nội dung được đăng tải.

Tuy nhiên, sự phân bố giữa hai số lượng người đăng ký (Subscriber Count) không phải là yếu tố duy nhất quyết định khả năng xuất hiện trong danh sách Trending. Trên thực tế vẫn tồn tại nhiều video Trending đến từ các kênh có quy mô nhỏ, phản ánh vai trò quan trọng của các yếu tố khác như chất lượng nội dung, mức độ tương tác của người xem và khả năng lan truyền của video.

Nhìn chung, số lượng người đăng ký (Subscriber Count) thể hiện sự khác biệt tương đối rõ giữa hai nhóm dữ liệu và có thể được xem là một đặc trưng có thể cân nhắc trong bài toán dự đoán video Trending trên nền tảng YouTube.




Hình 4.9 So sánh phân bố lượng người đăng ký giữa video Trending và Non-Trending

4.1.2.6 Phân bố Sentiment theo trạng thái Trending

Để đánh giá mối quan hệ giữa cảm xúc bình luận và khả năng trở thành Trending của video, nghiên cứu tiến hành tổng hợp tỷ lệ bình luận tích cực (Positive), trung tính (Neutral) và tiêu cực (Negative) cho từng video dựa trên kết quả phân loại cảm xúc từ mô hình XLM-RoBERTa. Quá trình phân tích được thực hiện trên 124.293 video có dữ liệu bình luận, sau khi loại bỏ các video không có dữ liệu sentiment.

Bảng 4.1 Tỷ lệ cảm xúc trung bình theo trạng thái Trending

Trạng thái	Positive Ratio	Neutral Ratio	Negative Ratio	Avg Sentiment Score
Non-Trending	0.529	0.270	0.200	0.678
Trending	0.476	0.323	0.201	0.661



Hình 4.10 Phân bố cảm xúc bình luận theo trạng thái Trending

Kết quả cho thấy nhóm video không Trending có tỷ lệ bình luận tích cực trung bình đạt khoảng 52,9%, cao hơn so với nhóm Trending với 47,6%. Ngược lại, tỷ lệ bình luận trung tính của nhóm Trending đạt 32,3%, cao hơn mức 27,0% của nhóm không

Trending. Tỷ lệ bình luận tiêu cực giữa hai nhóm gần như tương đương, dao động quanh mức 20%.


Bên cạnh đó, chỉ số cảm xúc trung bình (Average Sentiment Score) của nhóm không Trending đạt 0,678, trong khi nhóm Trending đạt 0,661. Mức chênh lệch chỉ khoảng 0,017 điểm cho thấy sự khác biệt về cảm xúc tổng thể giữa hai nhóm là không lớn.

Kết quả này cho thấy các video Trending không nhất thiết nhận được tỷ lệ phản hồi tích cực cao hơn các video thông thường. Thay vào đó, nhóm video Trending có xu hướng thu hút nhiều đối tượng người xem với các quan điểm đa dạng hơn, làm gia tăng tỷ lệ bình luận trung tính. Điều này cho thấy cảm xúc bình luận có thể phản ánh một phần mức độ tương tác của người xem, tuy nhiên không phải là yếu tố quyết định trực tiếp đến khả năng trở thành Trending của video.

4.1.3 Phân tích tương quan dữ liệu

4.1.3.1 Ma trận tương quan giữa các biến

Để đánh giá mức độ liên hệ giữa các đặc trưng và trạng thái Trending của video, nghiên cứu tiến hành tính toán hệ số tương quan Pearson giữa các biến định lượng trong tập dữ liệu.



Hình 4.11 Hệ số tương quan với biến Trending

Kết quả phân tích tương quan cho thấy phần lớn các đặc trưng có mức tương quan thấp đến trung bình với trạng thái Trending. Trong số các biến được khảo sát, thời lượng video (log_duration) có hệ số tương quan cao nhất với biến mục tiêu, đạt 0,47. Điều này cho thấy các video có thời lượng dài hơn có xu hướng xuất hiện trong danh sách Trending nhiều hơn so với các video có thời lượng ngắn.

Bên cạnh đó, tỷ lệ lượt thích (Like Rate) cũng thể hiện mối tương quan dương với trạng thái Trending ($r = 0,23$), phản ánh rằng những video nhận được mức độ yêu thích

cao từ người xem có khả năng trở thành Trending lớn hơn. Số lượng người đăng ký kênh ($\log_subscriber_count$) có hệ số tương quan dương ở mức thấp ($r = 0,17$), cho thấy quy mô kênh có ảnh hưởng nhất định đến khả năng tiếp cận và lan tỏa nội dung.

Ngược lại, điểm cảm xúc trung bình của bình luận (Average Sentiment Score) có hệ số tương quan rất thấp với trạng thái Trending ($r = -0,08$). Kết quả này phù hợp với phân tích ở mục 4.1.2.6, khi sự khác biệt về cảm xúc bình luận giữa nhóm Trending và Non-Trending không đáng kể. Ngoài ra, Comment Rate gần như không có mối tương quan với biến mục tiêu ($r = 0,01$), cho thấy mức độ bình luận trên mỗi lượt xem không phải là yếu tố quyết định trực tiếp đến khả năng trở thành Trending của video.

4.2 Xây dựng mô hình dự đoán video Trending

4.2.1 Chuẩn bị dữ liệu cho mô hình

4.2.2 Chia tập dữ liệu

4.2.3 Xây dựng và huấn luyện mô hình

4.2.4 Đánh giá kết quả mô hình

4.2.5 Phân tích mức độ quan trọng của đặc trưng

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] T. H. Davenport and J. G. Harris, *Competing on Analytics: The New Science of Winning*. Boston, MA, USA: Harvard Business School Press, 2007.
- [2] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.
- [3] W. H. Inmon, *Building the Data Warehouse*, 4th ed. Hoboken, NJ, USA: Wiley, 2005.
- [4] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Hoboken, NJ, USA: Wiley, 2013.
- [5] R. Kimball and J. Caserta, *The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data*. Indianapolis, IN, USA: Wiley Publishing, 2004.
- [6] R. Obe and L. Hsu, *PostgreSQL: Up and Running: A Practical Guide to the Advanced Open Source Database*, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2019.
- [7] B. Liu, *Sentiment Analysis and Opinion Mining*. San Rafael, CA, USA: Morgan & Claypool Publishers, 2012.
- [8] A. Conneau et al., "Unsupervised Cross-lingual Representation Learning at Scale," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.
- [9] T. M. Mitchell, *Machine Learning*. New York, NY, USA: McGraw-Hill, 1997.
- [10] C. N. Knaflitz, *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Hoboken, NJ, USA: Wiley, 2015.
- [11] Streamlit Inc., *Streamlit Documentation*. [Online]. Available: <https://docs.streamlit.io/>. [Accessed: Jun. 2026].